

现代概率论基础

Modern Foundations of Probability

shenhan

2026 年 6 月 6 日

未来可能人类的智力会受
得十分广泛。但是我们依然
拥有对信息的流不尽的权力。

目录

第一章 数学语言与可测结构	1
1.1 集合、映射与概率论的形式语言	1
1.2 拓扑空间与度量空间回顾	11
1.3 Borel σ -代数	22
1.4 生成类、 π -系统与 λ -系统	33
1.5 可测空间与可测映射	41
1.6 Polish 空间与标准 Borel 空间	57
1.7 乘积空间与乘积 σ -代数	65
1.8 函数空间的可测结构	75
1.9 可测选择与正则化思想入门	84
1.10 模块总结：概率论为何从可测结构开始	92
第二章 测度与积分	103
2.1 外测度与 Carathéodory 构造	103
2.2 测度空间与测度的基本性质	109
2.3 简单函数与非负可测函数积分	118
2.4 Lebesgue 积分与可积函数	125
2.5 单调收敛、Fatou 引理与控制收敛	134
2.6 Fubini-Tonelli 定理	134
2.7 Radon-Nikodym 定理	134
2.8 L_p 空间与基本不等式	134
2.9 测度分解与变换公式	134
2.10 模块总结：期望、密度与分布的统一	134
第三章 Kolmogorov 公理与概率空间	135
3.1 Kolmogorov 概率公理	135
3.2 随机变量与分布	135
3.3 事件、独立性与条件概率初步	135
3.4 乘积概率空间	135
3.5 无穷乘积与 Kolmogorov 扩张定理	135
3.6 Borel-Cantelli 引理	135
3.7 Kolmogorov 零一律	135

3.8	随机级数与三系定理导论	135
3.9	分布变换与特征函数初步	135
3.10	模块总结：从公理到随机对象构造	135
第四章	条件期望、正则条件分布与 Bayes 结构	136
4.1	条件期望的 Radon-Nikodym 定义	136
4.2	条件期望作为投影	136
4.3	塔式性质与条件 Jensen 不等式	136
4.4	条件独立	136
4.5	正则条件概率	136
4.6	Disintegration theorem 入门	136
4.7	Bayes 反问题的概率结构	136
4.8	条件期望与 Markov 核	136
4.9	条件期望的反例与技术边界	136
4.10	模块总结：条件化作为概率论核心操作	136
第五章	收敛方式与弱收敛语言	137
5.1	几乎处处收敛与依概率收敛	137
5.2	L_p 收敛与一致可积性	137
5.3	依分布收敛	137
5.4	Portmanteau 定理	137
5.5	连续映射定理与 Slutsky 定理	137
5.6	紧性与 Prokhorov 定理	137
5.7	特征函数与弱收敛	137
5.8	Wasserstein 距离入门	137
5.9	随机元素的弱收敛	137
5.10	模块总结：极限语言与人工智能大极限	137
第六章	大数律、中心极限定理与三角阵列	138
6.1	弱大数律	138
6.2	强大数律	138
6.3	Kolmogorov 最大不等式	138
6.4	中心极限定理的特征函数证明	138
6.5	Lindeberg-Feller 中心极限定理	138
6.6	Lyapunov 条件与 Berry-Esseen 估计	138
6.7	Poisson 逼近与稀有事件极限	138
6.8	稳定分布与重尾极限	138
6.9	不变性原理预告	138
6.10	模块总结：极限定理作为概率论发动机	138

第七章 鞅理论	139
7.1 滤过与适应过程	139
7.2 鞅、下鞅与上鞅	139
7.3 停时与可选采样	139
7.4 Doob 分解	139
7.5 Doob 最大不等式	139
7.6 鞅收敛定理	139
7.7 Azuma-Hoeffding 不等式	139
7.8 Freedman 与 Bernstein 型鞅不等式	139
7.9 鞅中心极限定理	139
7.10 模块总结：随机演化中的信息与公平性	139
第八章 Markov 链、概率核与遍历性	140
8.1 Markov 核与 Chapman-Kolmogorov 方程	140
8.2 离散时间 Markov 链基础	140
8.3 不变分布与遍历定理	140
8.4 可逆性与 detailed balance	140
8.5 耦合方法	140
8.6 谱间隙与混合时间	140
8.7 Harris recurrence 入门	140
8.8 MCMC 与 Gibbs sampler	140
8.9 Markov 链大数律与中心极限定理	140
8.10 模块总结：随机转移与平衡	140
第九章 函数空间弱收敛与 Brownian motion 构造	141
9.1 $C[0,1]$ 上的随机元素	141
9.2 $D[0,1]$ 与 Skorokhod 拓扑	141
9.3 Kolmogorov 连续性定理	141
9.4 Brownian motion 的定义与构造	141
9.5 Brownian motion 的基本性质	141
9.6 Donsker 不变性原理	141
9.7 紧性判别与模连续性	141
9.8 Brownian hitting time 与极值分布	141
9.9 迭代对数律入门	141
9.10 模块总结：从随机变量到随机函数	141
第十章 Brownian motion 与 Itô calculus	142
10.1 二次变差	142
10.2 Itô 积分的构造	142

10.3 Itô 公式	142
10.4 指数鞅与 Novikov 条件	142
10.5 Girsanov 定理	142
10.6 局部鞅与 localization	142
10.7 Brownian local time 入门	142
10.8 鞅表示定理	142
10.9 随机积分的典型估计	142
10.10 模块总结：连续时间随机分析语言	142
第十一章 SDE、生成元、Markov 半群与 PDE	143
11.1 随机微分方程的定义	143
11.2 存在唯一性定理	143
11.3 强解、弱解与路径唯一性	143
11.4 生成元与 Itô diffusion	143
11.5 Feller 半群与 martingale problem	143
11.6 Feynman-Kac 公式	143
11.7 Ornstein-Uhlenbeck 过程	143
11.8 Langevin diffusion 与不变分布	143
11.9 扩散过程的遍历性	143
11.10 模块总结：随机动力系统与 PDE 互译	143
第十二章 Poisson 过程、Lévy 过程与跳过程	144
12.1 Poisson 过程	144
12.2 更新过程	144
12.3 Poisson 随机测度	144
12.4 复合 Poisson 过程	144
12.5 无限可分分布	144
12.6 Lévy-Khintchine 公式	144
12.7 Lévy-Itô 分解	144
12.8 稳定过程与重尾跳跃	144
12.9 分支过程与随机图过程导论	144
12.10 模块总结：非连续路径与非 Gaussian 世界	144
第十三章 大偏差理论	145
13.1 大偏差原理的定义	145
13.2 Cramér 定理	145
13.3 Gärtner-Ellis 定理	145
13.4 Sanov 定理	145
13.5 收缩原理	145

13.6 Laplace 原理	145
13.7 Varadhan 引理	145
13.8 Gibbs 变分原理	145
13.9 经验风险的大偏差视角	145
13.10 模块总结：典型行为与指数小概率	145
第十四章 信息论、熵方法与函数不等式	146
14.1 相对熵与互信息	146
14.2 Pinsker 不等式与 data processing	146
14.3 熵方法与 Herbst argument	146
14.4 Poincaré 不等式	146
14.5 Log-Sobolev 不等式	146
14.6 Talagrand transport inequality	146
14.7 Efron-Stein 与方差代理	146
14.8 信息论泛化界	146
14.9 PAC-Bayes 的熵结构	146
14.10 模块总结：熵、几何与学习的统一	146
第十五章 集中不等式 I：独立变量与有界差分	147
15.1 Sub-Gaussian 随机变量	147
15.2 Sub-exponential 随机变量	147
15.3 Hoeffding 不等式	147
15.4 Bernstein 与 Bennett 不等式	147
15.5 Chernoff 方法	147
15.6 McDiarmid 有界差分不等式	147
15.7 Self-bounding functions	147
15.8 矩方法与 Rosenthal 型不等式	147
15.9 鞅集中回顾与统一	147
15.10 模块总结：非渐近概率估计的基础工具箱	147
第十六章 Gaussian Process 与比较不等式	148
16.1 Gaussian 向量与协方差结构	148
16.2 Isonormal Gaussian process	148
16.3 Cameron-Martin 空间	148
16.4 Slepian 引理	148
16.5 Sudakov-Fernique 不等式	148
16.6 Borell-TIS 不等式	148
16.7 Gaussian isoperimetry	148
16.8 Dudley entropy integral	148

16.9 Gaussian width	148
16.10 模块总结: Gaussian 极限与神经网络初始化	148
第十七章 Generic Chaining 与 Majorizing Measure	149
17.1 Chaining 思想的历史动机	149
17.2 Admissible sequence 与 γ_2 泛函	149
17.3 Majorizing measure theorem 陈述	149
17.4 Generic chaining 上界	149
17.5 Sudakov minoration 与下界	149
17.6 Bernoulli process 入门	149
17.7 局部复杂度与多尺度泛化	149
17.8 随机矩阵中的 chaining	149
17.9 深度网络类复杂度预告	149
17.10 模块总结: 随机过程上确界的精细工具	149
第十八章 经验过程理论	150
18.1 经验测度与经验过程	150
18.2 Symmetrization 技术	150
18.3 Rademacher complexity	150
18.4 Contraction principle	150
18.5 VC dimension 与 Sauer 引理	150
18.6 覆盖数与 bracketing entropy	150
18.7 Glivenko-Cantelli 类	150
18.8 Donsker 类	150
18.9 Multiplier process	150
18.10 模块总结: uniform law 的概率论版本	150
第十九章 高维概率与非渐近随机矩阵	151
19.1 高维随机向量	151
19.2 epsilon-net 方法	151
19.3 随机矩阵算子范数	151
19.4 奇异值非渐近界	151
19.5 Hanson-Wright 不等式	151
19.6 Matrix Bernstein 不等式	151
19.7 Matrix Chernoff 与协方差集中	151
19.8 Johnson-Lindenstrauss 与随机投影	151
19.9 Restricted isometry property	151
19.10 模块总结: 高维随机结构的非渐近控制	151

第二十章 随机矩阵极限、谱分布与 Free Probability 入门	152
20.1 经验谱分布	152
20.2 Wigner 矩阵与半圆律	152
20.3 Marchenko-Pastur 定理	152
20.4 Resolvent method	152
20.5 Spiked covariance model	152
20.6 BBP transition	152
20.7 Local law 概念	152
20.8 Universality 思想	152
20.9 Free convolution 入门	152
20.10 模块总结：谱极限与高维学习风险	152
第二十一章 高维统计与 Minimax 理论	153
21.1 统计决策理论	153
21.2 Le Cam 方法	153
21.3 Fano 不等式	153
21.4 Assouad 引理	153
21.5 稀疏线性回归	153
21.6 压缩感知	153
21.7 低秩矩阵估计	153
21.8 协方差估计	153
21.9 非参数估计与有效维数	153
21.10 模块总结：统计极限与可估计性边界	153
第二十二章 统计学习理论的纯数学版本	154
22.1 经验风险最小化	154
22.2 PAC learning 基础	154
22.3 VC 理论再解释	154
22.4 Rademacher 泛化界	154
22.5 Localized complexity 与 fast rates	154
22.6 Algorithmic stability	154
22.7 PAC-Bayes 理论	154
22.8 Compression bound	154
22.9 Uniform convergence 的失败	154
22.10 模块总结：泛化误差的多种数学机制	154
第二十三章 RKHS、Kernel Methods 与 Random Features	155
23.1 正定核与 Mercer 定理	155
23.2 RKHS 的构造	155

23.3 Representer theorem	155
23.4 Kernel ridge regression	155
23.5 Gaussian process regression	155
23.6 Random features	155
23.7 Nyström approximation	155
23.8 Kernel ridgeless interpolation	155
23.9 Spectral bias 与 effective dimension	155
23.10 模块总结：从 kernel 到神经网络极限	155
第二十四章 随机优化、SGD 与隐式正则化	156
24.1 Robbins-Monro 随机逼近	156
24.2 ODE method	156
24.3 SGD 作为随机递推	156
24.4 Gradient flow 与连续时间极限	156
24.5 Langevin dynamics 与采样	156
24.6 凸优化中的 SGD 收敛	156
24.7 非凸优化基本概率工具	156
24.8 线性回归中的隐式偏置	156
24.9 Logistic 回归中的 max-margin 偏置	156
24.10 模块总结：优化轨迹与泛化机制耦合	156
第二十五章 统计物理、Spin Glass、AMP 与 State Evolution	157
25.1 Gibbs 测度与配分函数	157
25.2 Curie-Weiss 模型	157
25.3 Sherrington-Kirkpatrick 模型入门	157
25.4 Replica 方法的数学边界	157
25.5 Cavity method 直观	157
25.6 TAP 方程	157
25.7 Approximate message passing	157
25.8 State evolution	157
25.9 Planted models 与检测相变	157
25.10 模块总结：高维推断中的物理概率语言	157
第二十六章 Double Descent、Ridgeless Regression 与 Benign Overfitting	158
26.1 经典偏差-方差分解再审视	158
26.2 插值阈值与 double descent 现象	158
26.3 最小范数插值解	158
26.4 各向同性 Gaussian 设计下的精确风险	158
26.5 有噪声线性模型的 ridgeless regression	158

26.6 Spiked covariance 下的风险	158
26.7 Benign overfitting 的谱条件	158
26.8 Random feature double descent	158
26.9 Kernel ridgeless 与无限维插值	158
26.10 模块总结：过参数泛化的第一个可解模型	158
第二十七章 无限宽神经网络、Gaussian Process、NTK 与 Tensor Programs	159
27.1 随机初始化神经网络	159
27.2 NNGP 极限	159
27.3 Neural tangent kernel 的定义	159
27.4 NTK 极限与 lazy training	159
27.5 Kernel gradient flow	159
27.6 有限宽修正	159
27.7 深度对信号传播的影响	159
27.8 Tensor programs 入门	159
27.9 架构依赖极限	159
27.10 模块总结：神经网络训练的核极限图像	159
第二十八章 Mean-field Neural Networks 与 Wasserstein Gradient Flow	160
28.1 两层网络的 mean-field scaling	160
28.2 Propagation of chaos	160
28.3 参数分布的非线性 PDE	160
28.4 Wasserstein gradient flow	160
28.5 全局收敛问题	160
28.6 Feature learning 与 lazy training 的差别	160
28.7 有限粒子涨落	160
28.8 多层 mean-field 理论导论	160
28.9 Mean-field 与 scaling exponent	160
28.10 模块总结：从核学习到特征学习	160
第二十九章 Scaling Laws 的数学化	161
29.1 Scaling laws 的经验形式	161
29.2 模型规模、数据规模与计算预算	161
29.3 风险分解框架	161
29.4 幂律的谱来源	161
29.5 非参数回归中的学习曲线	161
29.6 Kernel 与 random feature scaling	161
29.7 NTK 模型中的 scaling laws	161
29.8 优化误差与 compute-optimal tradeoff	161

29.9	Scaling exponent 的可识别性	161
29.10	模块总结：把经验幂律变成定理问题	161
第三十章 Diffusion、Score Models 与 AI 理论研究入口		162
30.1	生成建模的概率论表述	162
30.2	Denoising diffusion probabilistic models	162
30.3	Score matching	162
30.4	Score-based SDE	162
30.5	扩散模型中的误差分解	162
30.6	Scaling laws 与生成模型	162
30.7	Transformer 理论接口导论	162
30.8	最终专题一：Double descent 研究提案	162
30.9	最终专题二：Scaling laws 研究提案	162
30.10	最终总结：从 AI 现象到概率定理	162

第 1 章

数学语言与可测结构

1.1 集合、映射与概率论的形式语言

概率论的基本对象并不是一开始就直接写成某个公式，而是先从两个最基本的数学语言开始：

集合 和 映射.

集合用来描述所有可能发生的结果，映射用来描述我们如何从这些结果中提取出关心的信息。现代概率论之所以要先建立这些语言，是因为后面所有核心概念，例如事件、随机变量、分布、条件概率、随机过程，本质上都依赖集合和映射。

■ 样本空间与事件

一次随机试验的所有可能结果组成一个集合，称为样本空间，通常记作

$$\Omega.$$

样本空间中的一个元素记作

$$\omega \in \Omega,$$

它表示一次具体的试验结果。

例如，抛一次硬币时，可以取

$$\Omega = \{H, T\},$$

其中 H 表示正面， T 表示反面。抛一次骰子时，可以取

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

在概率论中，事件就是样本空间的子集。也就是说，如果

$$A \subseteq \Omega,$$

那么 A 可以表示一个事件。

例如，在抛骰子的例子中，事件“点数是偶数”可以写成

$$A = \{2, 4, 6\}.$$

事件“点数大于 4”可以写成

$$B = \{5, 6\}.$$

所以，从集合论的角度来看，概率论中的事件并不是神秘对象，而是样本空间中的某些子集。

■ 映射与随机变量

在实际问题中，我们通常并不直接关心样本点 ω 本身，而是关心由 ω 决定出来的某个数值或对象。这时就需要映射。

设 Ω 是样本空间， S 是另一个集合。一个映射

$$X : \Omega \rightarrow S$$

表示：对于每一个试验结果 $\omega \in \Omega$ ，都指定一个取值

$$X(\omega) \in S.$$

在概率论中，随机变量本质上就是这样的映射。

要点：随机变量就是把随机结果转化成我们关心的数值或对象的函数。

例如，抛一次硬币，样本空间为

$$\Omega = \{H, T\}.$$

定义

$$X(H) = 1, \quad X(T) = 0.$$

那么 X 就是一个随机变量。它表示是否抛出正面：如果抛出正面， $X = 1$ ；如果抛出反面， $X = 0$ 。注意，真正随机的是试验结果 ω ，而 X 本身是一条确定的规则。

再看一个例子。抛两次硬币，样本空间为

$$\Omega = \{HH, HT, TH, TT\}.$$

定义

$$X(\omega) = \text{两次抛硬币中正面的次数}.$$

于是有

$$X(HH) = 2, \quad X(HT) = 1, \quad X(TH) = 1, \quad X(TT) = 0.$$

因此 X 是一个从样本空间到集合 $\{0, 1, 2\}$ 的映射：

$$X : \{HH, HT, TH, TT\} \rightarrow \{0, 1, 2\}.$$

这个随机变量把每一个具体的抛硬币结果转化成一个数字，即正面出现的次数。

■ 事件可以由随机变量描述

随机变量的意义在于，它允许我们把复杂的试验结果转化成简单的数值条件。

例如，在抛两次硬币的例子中，事件“正面次数等于 1”可以写成

$$\{X = 1\}.$$

这只是一个简写。它的完整含义是

$$\{\omega \in \Omega : X(\omega) = 1\}.$$

在这个例子中，

$$\{X = 1\} = \{HT, TH\}.$$

也就是说，“正面次数等于 1”这个事件，实际上仍然是样本空间 Ω 的一个子集。

类似地，事件“正面次数至少为 1”可以写成

$$\{X \geq 1\}.$$

其完整含义是

$$\{\omega \in \Omega : X(\omega) \geq 1\}.$$

在这个例子中，

$$\{X \geq 1\} = \{HH, HT, TH\}.$$

因此，概率论中大量事件都可以通过随机变量来描述。

■ 原像的定义

设

$$f : \Omega \rightarrow S$$

是一个映射， $B \subseteq S$ 。集合 B 在映射 f 下的原像定义为

$$f^{-1}(B) = \{\omega \in \Omega : f(\omega) \in B\}.$$

也就是说， $f^{-1}(B)$ 是所有被 f 映到 B 里面的样本点组成的集合。

在概率论中，如果 $X : \Omega \rightarrow S$ 是随机变量，那么

$$\{X \in B\}$$

其实就是

$$X^{-1}(B).$$

即

$$\{X \in B\} = \{\omega \in \Omega : X(\omega) \in B\} = X^{-1}(B).$$

这说明，原像是连接“取值空间中的集合”和“样本空间中的事件”的桥梁。

■ 为什么概率论需要原像

概率测度 $\mathbb{P}$ 是定义在样本空间 Ω 上的。更准确地说，概率作用在样本空间中的事件上。因此，如果我们想讨论

$$\mathbb{P}(X \in B),$$

就必须先把 “ $X \in B$ ” 解释成样本空间中的一个事件。而这个事件正是

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

所以我们定义

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)).$$

这就是原像在概率论中的根本作用。

取值空间 S 中的集合 B 本身不一定是样本空间中的事件，所以不能直接对 B 使用 $\mathbb{P}$ 。我们必须先通过随机变量 X 把它拉回到样本空间中。可以用下面的图式来理解：

$$\Omega \xrightarrow{X} S.$$

如果 $B \subseteq S$ ，那么

$$X^{-1}(B) \subseteq \Omega.$$

也就是说，原像把取值空间中的集合拉回到了样本空间中。

结论： 概率只能直接作用在样本空间的事件上，所以我们需要原像。

■ 像与原像的区别

设

$$f : \Omega \rightarrow S.$$

如果 $A \subseteq \Omega$ ，那么 A 的像定义为

$$f(A) = \{f(\omega) : \omega \in A\} \subseteq S.$$

像是把样本空间中的集合推到取值空间中。

如果 $B \subseteq S$ ，那么 B 的原像定义为

$$f^{-1}(B) = \{\omega \in \Omega : f(\omega) \in B\} \subseteq \Omega.$$

原像是把取值空间中的集合拉回到样本空间中。

在概率论中，我们更常用原像，而不是像。原因是概率首先定义在样本空间上，我们需要把关于随机变量取值的条件转化成样本空间中的事件。

例如，抛两次硬币时

$$\Omega = \{HH, HT, TH, TT\},$$

并定义

$$X(\omega) = \text{正面次数}.$$

令

$$B = \{1\} \subseteq \{0, 1, 2\}.$$

那么

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in \{1\}\} = \{HT, TH\}.$$

这就是事件“正面次数等于 1”。

■ 原像对集合运算的保持

原像有一个非常重要的性质：它和集合运算相容。首先，对补集有

$$(f^{-1}(B))^c = f^{-1}(B^c).$$

这里左边的补集是在 Ω 中取补，右边的补集是在 S 中取补。

证明如下。对任意 $\omega \in \Omega$ ，有

$$\omega \in (f^{-1}(B))^c$$

当且仅当

$$\omega \notin f^{-1}(B).$$

根据原像定义，这等价于

$$f(\omega) \notin B.$$

而这又等价于

$$f(\omega) \in B^c.$$

再根据原像定义，这等价于

$$\omega \in f^{-1}(B^c).$$

所以

$$(f^{-1}(B))^c = f^{-1}(B^c).$$

这个性质说明，原像可以把取值空间中的“非 B ”事件准确地转化为样本空间中的“非 $X \in B$ ”事件。

其次，设 $B_1, B_2, \dots \subseteq S$ ，则

$$f^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} f^{-1}(B_n).$$

证明如下。对任意 $\omega \in \Omega$ ，有

$$\omega \in f^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right)$$

当且仅当

$$f(\omega) \in \bigcup_{n=1}^{\infty} B_n.$$

这等价于存在某个 n , 使得

$$f(\omega) \in B_n.$$

根据原像定义, 这等价于存在某个 n , 使得

$$\omega \in f^{-1}(B_n).$$

也就是

$$\omega \in \bigcup_{n=1}^{\infty} f^{-1}(B_n).$$

因此

$$f^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} f^{-1}(B_n).$$

这个性质说明, “ X 落在若干个集合之一中” 这个事件, 等于这些事件的并。例如,

$$\{X \in B_1 \cup B_2\} = \{X \in B_1\} \cup \{X \in B_2\}.$$

同理, 设 $B_1, B_2, \dots \subseteq S$, 则

$$f^{-1}\left(\bigcap_{n=1}^{\infty} B_n\right) = \bigcap_{n=1}^{\infty} f^{-1}(B_n).$$

证明如下。对任意 $\omega \in \Omega$, 有

$$\omega \in f^{-1}\left(\bigcap_{n=1}^{\infty} B_n\right)$$

当且仅当

$$f(\omega) \in \bigcap_{n=1}^{\infty} B_n.$$

这等价于对所有 n , 都有

$$f(\omega) \in B_n.$$

根据原像定义, 这等价于对所有 n , 都有

$$\omega \in f^{-1}(B_n).$$

也就是

$$\omega \in \bigcap_{n=1}^{\infty} f^{-1}(B_n).$$

因此

$$f^{-1}\left(\bigcap_{n=1}^{\infty} B_n\right) = \bigcap_{n=1}^{\infty} f^{-1}(B_n).$$

这个性质说明, “ X 同时落在所有 B_n 中” 这个事件, 等于这些事件的交。例如,

$$\{X \in B_1 \cap B_2\} = \{X \in B_1\} \cap \{X \in B_2\}.$$

■ 为什么不用像来定义随机变量事件

一个自然的问题是：既然有像和原像，为什么概率论更重视原像？

原因是：概率测度 $\mathbb{P}$ 的定义域是样本空间中的事件，而不是取值空间中的集合。随机变量

$$X : \Omega \rightarrow S$$

把样本点送到取值空间中。如果我们关心 S 中的集合 B ，那么必须找到所有导致 $X(\omega) \in B$ 的样本点 ω 。这些样本点形成的集合就是

$$X^{-1}(B).$$

只有它才是样本空间中的事件，因此才能计算概率。

相比之下，像

$$X(A)$$

是取值空间中的集合，不一定能直接用于计算 $\mathbb{P}$ 。所以概率论中最重要的操作不是把集合推出去，而是把集合拉回来：

$$B \subseteq S \implies X^{-1}(B) \subseteq \Omega.$$

■ 从原像到可测性

后面我们会看到，概率论并不是允许样本空间的所有子集都作为事件。我们会选择一个事件系统

$$\mathcal{F} \subseteq 2^\Omega,$$

称为 σ -代数。

如果随机变量的取值空间是实数轴，那么我们通常考虑

$$X : \Omega \rightarrow \mathbb{R}.$$

要想合法地讨论

$$\mathbb{P}(X \leq t), \quad \mathbb{P}(a < X < b), \quad \mathbb{P}(X \in B),$$

就要求这些集合在样本空间中确实是事件。也就是说，需要有

$$\{X \leq t\} \in \mathcal{F},$$

或者更一般地，

$$X^{-1}(B) \in \mathcal{F}.$$

这就是可测性的思想。

粗略地说，一个随机变量 X 是可测的，意思就是：所有关于 X 的合理事件，都能被拉回成样本空间中的事件。更正式地说，如果

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}),$$

那么 X 称为可测映射，如果对任意 $B \in \mathcal{S}$ ，都有

$$X^{-1}(B) \in \mathcal{F}.$$

实值随机变量就是从样本空间到实数轴的可测映射：

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

其中 $\mathcal{B}(\mathbb{R})$ 是实数轴上的 Borel σ -代数。

■ 一个完整例子：抛两次硬币

设

$$\Omega = \{HH, HT, TH, TT\}.$$

定义随机变量

$$X(\omega) = \text{两次抛硬币中正面的次数}.$$

于是

$$X(HH) = 2, \quad X(HT) = 1, \quad X(TH) = 1, \quad X(TT) = 0.$$

现在取

$$B = \{1, 2\}.$$

那么

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in \{1, 2\}\}.$$

逐个检查样本点：

$$X(HH) = 2 \in B, \quad X(HT) = 1 \in B, \quad X(TH) = 1 \in B, \quad X(TT) = 0 \notin B.$$

因此

$$X^{-1}(B) = \{HH, HT, TH\}.$$

这个事件的含义是：两次抛硬币中至少出现一次正面。

如果硬币公平，那么

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}(\{HH, HT, TH\}) = \frac{3}{4}.$$

这个例子展示了概率计算的基本流程：

取值空间中的条件 $\implies$ 通过原像变成样本空间中的事件 $\implies$ 计算概率.

■ 分布的初步思想

随机变量不仅可以用来描述事件，还可以把样本空间上的概率转移到取值空间上。

设 $X : \Omega \rightarrow S$ 是随机变量。对 $B \subseteq S$ ，我们定义

$$\mu_X(B) = \mathbb{P}(X \in B).$$

根据原像的写法，

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)).$$

这个 μ_X 就是随机变量 X 的分布。因此，随机变量的分布不是直接凭空定义在 S 上的，而是由样本空间上的概率 $\mathbb{P}$ 通过 X 推导出来的。常记为

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

也就是说：

结论：随机变量的分布，就是样本空间上的概率通过随机变量诱导出来的概率。

■ 本节小结

本节的核心内容可以总结为以下几点。

首先，样本空间 Ω 是所有可能结果的集合，事件是 Ω 的子集。

其次，随机变量不是一个“会随机变化的变量”，而是一个映射

$$X : \Omega \rightarrow S.$$

它把样本点 ω 转换成我们真正关心的数值或对象。

再次，关于随机变量的事件都可以写成原像：

$$\{X \in B\} = X^{-1}(B).$$

原像之所以重要，是因为概率测度定义在样本空间的事件上。我们必须把取值空间中的条件 B 拉回到样本空间中，才能计算概率：

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)).$$

最后，原像与集合运算相容：

$$\begin{aligned} (f^{-1}(B))^c &= f^{-1}(B^c), \\ f^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) &= \bigcup_{n=1}^{\infty} f^{-1}(B_n), \\ f^{-1}\left(\bigcap_{n=1}^{\infty} B_n\right) &= \bigcap_{n=1}^{\infty} f^{-1}(B_n). \end{aligned}$$

这些性质是后面定义可测映射、随机变量、分布以及概率空间的基础。

■ 练习

1. 设

$$\Omega = \{1, 2, 3, 4, 5, 6\},$$

并定义

$$X(\omega) = \omega.$$

求

$$X^{-1}(\{2, 4, 6\}).$$

这个事件表示什么？

2. 设抛两次硬币，

$$\Omega = \{HH, HT, TH, TT\},$$

并定义

$$X(\omega) = \text{正面出现的次数}.$$

求

$$X^{-1}(\{0\}), \quad X^{-1}(\{1\}), \quad X^{-1}(\{2\}).$$

3. 设

$$f : \Omega \rightarrow S,$$

并且 $B, C \subseteq S$ 。证明

$$f^{-1}(B \setminus C) = f^{-1}(B) \setminus f^{-1}(C).$$

4. 设

$$X : \Omega \rightarrow \mathbb{R}.$$

解释为什么

$$\{a < X < b\}$$

可以写成

$$X^{-1}((a, b)).$$

5. 设 X 是实值随机变量。解释下面三个事件分别是什么意思：

$$\{X \leq 0\}, \quad \{1 < X < 3\}, \quad \{X \in \mathbb{Z}\}.$$

1.2 拓扑空间与度量空间回顾

在上一节中，我们已经看到，概率论的基本语言来自集合和映射。样本空间

$$\Omega$$

描述所有可能结果，随机变量则是一个从样本空间出发的映射

$$X : \Omega \rightarrow S.$$

如果我们想讨论

$$\mathbb{P}(X \in B),$$

就必须把取值空间 S 中的集合 B 通过原像拉回到样本空间中：

$$\{X \in B\} = X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

因此，概率论中一个自然的问题是：取值空间 S 中哪些集合 B 是合理的？

当 $S = \mathbb{R}$ 时，我们熟悉区间、开集、闭集等概念。当 $S = \mathbb{R}^d$ 时，我们也可以用欧氏距离讨论开球和开集。但在现代概率论中，随机变量的取值空间不一定只是 $\mathbb{R}$ 或 $\mathbb{R}^d$ ，它也可能是函数空间、路径空间，甚至更抽象的空间。因此，我们需要回顾拓扑空间和度量空间的基本语言。

这一节的核心思想可以概括为：

$$\text{距离} \implies \text{开球} \implies \text{开集} \implies \text{拓扑} \implies \text{Borel } \sigma\text{-代数}.$$

后面我们会看到，Borel σ -代数正是由拓扑空间中的开集生成出来的事件系统。

■ 度量空间

我们先从最熟悉的距离开始。设 M 是一个集合。一个函数

$$d : M \times M \rightarrow [0, \infty)$$

称为 M 上的一个度量，如果对任意 $x, y, z \in M$ ，满足以下三条性质。

第一，非负性与分离性：

$$d(x, y) \geq 0,$$

并且

$$d(x, y) = 0 \iff x = y.$$

第二，对称性：

$$d(x, y) = d(y, x).$$

第三，三角不等式：

$$d(x, z) \leq d(x, y) + d(y, z).$$

如果 d 是 M 上的一个度量, 那么二元组

$$(M, d)$$

称为一个度量空间。直观地说, 度量空间就是一个带有距离概念的集合。集合 M 给出空间中的点, 度量 d 告诉我们任意两个点之间有多远。

最基本的例子是实数轴。令

$$M = \mathbb{R},$$

并定义

$$d(x, y) = |x - y|.$$

则 $(\mathbb{R}, d)$ 是一个度量空间。

更一般地, 在 $\mathbb{R}^n$ 中, 可以定义欧氏距离

$$d(x, y) = \|x - y\|_2 = \left(\sum_{i=1}^n (x_i - y_i)^2 \right)^{1/2}.$$

于是 $(\mathbb{R}^n, d)$ 是一个度量空间。

除了欧氏距离以外, $\mathbb{R}^n$ 上还可以定义其他常用距离。例如

$$d_1(x, y) = \sum_{i=1}^n |x_i - y_i|,$$

称为 ℓ^1 距离; 又如

$$d_\infty(x, y) = \max_{1 \leq i \leq n} |x_i - y_i|,$$

称为 ℓ^∞ 距离。这些距离虽然形式不同, 但都满足度量的三条基本性质。

■ 开球与开集

在度量空间 (M, d) 中, 给定一点 $x \in M$ 和一个半径 $r > 0$, 定义以 x 为中心、半径为 r 的开球为

$$B_r(x) = \{y \in M : d(x, y) < r\}.$$

开球表示所有距离 x 小于 r 的点组成的集合。

例如, 在实数轴 $\mathbb{R}$ 中, 若 $d(x, y) = |x - y|$, 则

$$B_r(x) = (x - r, x + r).$$

也就是说, 实数轴上的开球就是普通的开区间。

在 $\mathbb{R}^2$ 中, 如果使用欧氏距离, 那么 $B_r(x)$ 是一个不包含边界的圆盘。在 $\mathbb{R}^3$ 中, 开球则是不包含球面的实心球。

有了开球之后, 我们可以定义开集。设 $U \subset M$ 。如果对任意 $x \in U$, 都存在 $r > 0$, 使得

$$B_r(x) \subset U,$$

那么称 U 是 M 中的开集。

这个定义的直观意思是：集合 U 中的每一个点，周围都有一点活动空间完全留在 U 里面。也就是说， U 中没有点是被迫贴着边界站着的。

例如，在 $\mathbb{R}$ 中，

$$(0, 1)$$

是开集。因为对任意 $x \in (0, 1)$ ，总可以找到足够小的 $r > 0$ ，使得

$$(x - r, x + r) \subset (0, 1).$$

但是

$$[0, 1]$$

不是开集。因为点 0 属于 $[0, 1]$ ，但无论 $r > 0$ 多小，开球

$$B_r(0) = (-r, r)$$

都会包含负数，因此不可能完全包含在 $[0, 1]$ 中。

类似地，

$$(0, 1]$$

也不是开集，因为点 1 附近的任意小区间都会伸到 1 的右侧。

■ 闭集

在度量空间或拓扑空间中，闭集通过补集定义。设 $F \subset M$ 。如果 F 的补集

$$F^c = M \setminus F$$

是开集，那么称 F 是闭集。

例如，在 $\mathbb{R}$ 中，

$$[0, 1]$$

是闭集。因为它的补集是

$$[0, 1]^c = (-\infty, 0) \cup (1, \infty),$$

这是一个开集。

需要注意，闭集并不是“不是开集”的意思。一个集合可能既不是开集，也不是闭集。例如，在 $\mathbb{R}$ 中，

$$(0, 1]$$

既不是开集，也不是闭集。

另一方面，一个集合也可能既是开集又是闭集。比如在任意空间中，空集和全集总是既开又闭：

$$\emptyset, \quad M.$$

因为

$$\emptyset^c = M, \quad M^c = \emptyset.$$

■ 拓扑空间

度量空间通过距离来定义开集。但有时候，我们并不需要具体的距离，只需要知道哪些集合是开集。于是得到拓扑空间的概念。

设 X 是一个集合， τ 是 X 的某些子集组成的集合族。如果 τ 满足以下三条性质，那么称 τ 是 X 上的一个拓扑，称

$$(X, \tau)$$

为一个拓扑空间。 τ 中的元素称为开集。

第一，

$$\emptyset \in \tau, \quad X \in \tau.$$

第二，任意多个开集的并仍然是开集。也就是说，如果 $\{U_i\}_{i \in I}$ 是 τ 中的一族集合，则

$$\bigcup_{i \in I} U_i \in \tau.$$

第三，有限多个开集的交仍然是开集。也就是说，如果

$$U_1, \dots, U_n \in \tau,$$

则

$$\bigcap_{k=1}^n U_k \in \tau.$$

所以，拓扑本质上就是指定哪些集合被认为是开集的一套规则。

注意，拓扑中要求任意并仍然开，但只要求有限交仍然开。无限多个开集的交不一定是开集。例如，在 $\mathbb{R}$ 中，

$$\bigcap_{n=1}^{\infty} \left(-\frac{1}{n}, \frac{1}{n}\right) = \{0\}.$$

每个

$$\left(-\frac{1}{n}, \frac{1}{n}\right)$$

都是开集，但它们的交 $\{0\}$ 不是开集。

■ 由度量诱导的拓扑

每一个度量空间都会自然给出一个拓扑。设 (M, d) 是度量空间。我们把所有满足如下条件的集合 $U \subset M$ 称为开集：

$$\forall x \in U, \exists r > 0, B_r(x) \subset U.$$

所有这样的开集组成的集合族记作 τ_d 。可以验证， τ_d 满足拓扑的三条公理，因此 τ_d 是 M 上的一个拓扑。

这个拓扑称为由度量 d 诱导的拓扑。因此，度量空间和拓扑空间之间有如下关系：

度量空间 $\implies$ 拓扑空间.

也就是说，每个度量空间都是拓扑空间，但不是每个拓扑空间都一定来自某个度量。

在概率论中，我们常常从一个具体的度量空间出发，例如 $\mathbb{R}^d$ 或函数空间，然后使用这个度量诱导出的拓扑，再由拓扑生成 Borel σ -代数。

■ 离散度量

一个简单但很重要的例子是离散度量。设 M 是任意集合，定义

$$d(x, y) = \begin{cases} 0, & x = y, \\ 1, & x \neq y. \end{cases}$$

则 d 是 M 上的一个度量，称为离散度量。

在离散度量下，每个单点集都是开集。因为

$$B_{1/2}(x) = \{x\}.$$

于是任意集合 $A \subset M$ 都可以写成单点集的并：

$$A = \bigcup_{x \in A} \{x\}.$$

由于任意开集的并仍然是开集，所以 A 是开集。因此，在离散度量下， M 的每一个子集都是开集。也就是说，对离散度量诱导的拓扑，有

$$\tau = 2^M.$$

这个例子说明，不同的度量可以带来不同的开集结构。

■ 邻域、内点、闭包与边界

设 (X, τ) 是一个拓扑空间， $A \subset X$ 。

如果存在开集 U ，使得

$$x \in U \subset A,$$

则称 x 是 A 的内点。所有内点组成的集合称为 A 的内部，记作

$$A^\circ.$$

例如，在 $\mathbb{R}$ 中，

$$[0, 1]^\circ = (0, 1).$$

因为 0 和 1 没有足够小的开区间完全包含在 $[0, 1]$ 中。

集合 A 的闭包记作

$$\overline{A}.$$

直观地说, $\overline{A}$ 是 A 加上所有可以被 A 中点逼近的点。

例如,

$$\overline{(0,1)} = [0,1].$$

虽然 0 和 1 不属于 $(0,1)$, 但是它们都可以被 $(0,1)$ 中的点无限逼近。

在度量空间中, $x \in \overline{A}$ 等价于存在一个序列 (x_n) , 满足

$$x_n \in A, \quad x_n \rightarrow x.$$

集合 A 的边界记作

$$\partial A.$$

它可以定义为

$$\partial A = \overline{A} \setminus A^\circ.$$

直观地说, 边界点是那些任意小邻域都会同时碰到 A 和 A^c 的点。

例如, 在 $\mathbb{R}$ 中,

$$\partial(0,1) = \{0,1\},$$

并且

$$\partial[0,1] = \{0,1\}.$$

■ 收敛

度量空间使我们能够定义序列收敛。设 (M,d) 是度量空间, (x_n) 是 M 中的一个序列, $x \in M$ 。如果

$$d(x_n, x) \rightarrow 0,$$

则称 x_n 收敛到 x , 记作

$$x_n \rightarrow x.$$

在 $\mathbb{R}$ 中, 这就是普通的极限:

$$x_n \rightarrow x \iff |x_n - x| \rightarrow 0.$$

例如,

$$x_n = \frac{1}{n}$$

在 $\mathbb{R}$ 中收敛到 0, 因为

$$\left| \frac{1}{n} - 0 \right| = \frac{1}{n} \rightarrow 0.$$

在 $\mathbb{R}^d$ 中, 若使用欧氏距离, 则

$$x_n \rightarrow x$$

表示

$$\|x_n - x\|_2 \rightarrow 0.$$

在函数空间 $C[0, 1]$ 中, 如果定义

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|,$$

那么

$$f_n \rightarrow f$$

表示

$$\sup_{t \in [0, 1]} |f_n(t) - f(t)| \rightarrow 0.$$

这正是一致收敛。因此, 不同的度量会给出不同的收敛概念。

■ 连续映射

拓扑空间中的连续性可以用原像来定义。设 (X, τ_X) 和 (Y, τ_Y) 是两个拓扑空间, $f: X \rightarrow Y$ 是一个映射。如果对任意开集 $V \in \tau_Y$, 都有

$$f^{-1}(V) \in \tau_X,$$

则称 f 是连续映射。

也就是说, 连续映射把目标空间中的开集通过原像拉回后, 仍然得到定义域中的开集。

这个定义和上一节的原像概念完全一致。上一节我们已经看到, 原像能够保持补集、并集和交集等集合运算。这里进一步说明, 原像也可以用来刻画拓扑结构。

在度量空间中, 这个定义等价于熟悉的 ε - δ 定义。若 (M, d_M) 和 (N, d_N) 是度量空间, 映射 $f: M \rightarrow N$ 连续, 等价于对任意 $x \in M$ 和任意 $\varepsilon > 0$, 存在 $\delta > 0$, 使得只要

$$d_M(x, y) < \delta,$$

就有

$$d_N(f(x), f(y)) < \varepsilon.$$

例如, 函数

$$f: \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = x^2$$

是连续的。取开集

$$(1, 4) \subset \mathbb{R}.$$

则它的原像是

$$f^{-1}((1, 4)) = \{x \in \mathbb{R} : 1 < x^2 < 4\} = (-2, -1) \cup (1, 2),$$

这是 $\mathbb{R}$ 中的开集。

■ 稠密性与可分性

设 (X, τ) 是一个拓扑空间, $A \subset X$ 。如果

$$\overline{A} = X,$$

则称 A 在 X 中稠密。

直观地说, A 在 X 中稠密, 表示 X 中的每一个点都可以被 A 中的点任意逼近。

例如, 有理数集 $\mathbb{Q}$ 在 $\mathbb{R}$ 中稠密:

$$\overline{\mathbb{Q}} = \mathbb{R}.$$

因为任意实数都可以被有理数任意逼近。

如果一个拓扑空间 X 中存在一个可数稠密子集, 则称 X 是可分的。例如, $\mathbb{R}$ 是可分的, 因为 $\mathbb{Q}$ 是 $\mathbb{R}$ 的可数稠密子集。

更一般地, $\mathbb{R}^d$ 也是可分的, 因为 $\mathbb{Q}^d$ 是 $\mathbb{R}^d$ 的可数稠密子集。

可分性在概率论中非常重要。很多时候, 我们希望把不可数的问题化约为可数的问题。例如, 在函数空间上研究随机过程时, 可分性常常帮助我们复杂的路径性质转化为可数个点或可数个集合上的条件。

■ Cauchy 序列与完备性

设 (M, d) 是度量空间, (x_n) 是 M 中的一个序列。如果对任意 $\varepsilon > 0$, 存在 N , 使得当 $m, n \geq N$ 时,

$$d(x_m, x_n) < \varepsilon,$$

则称 (x_n) 是一个 Cauchy 序列。

Cauchy 序列的意思是: 当指标足够大以后, 序列中的项彼此之间越来越接近。如果度量空间 M 中的每一个 Cauchy 序列都收敛到 M 中的某个点, 则称 M 是完备的。

例如, $\mathbb{R}$ 在通常距离下是完备的。也就是说, 实数中的 Cauchy 序列一定收敛到某个实数。

但是有理数集 $\mathbb{Q}$ 在通常距离下不是完备的。例如, 可以取一系列有理数 (q_n) 逐渐逼近 $\sqrt{2}$ 。这列数在 $\mathbb{Q}$ 中是 Cauchy 序列, 但它的极限 $\sqrt{2}$ 不属于 $\mathbb{Q}$ 。因此 $\mathbb{Q}$ 不是完备的。

完备性在概率论中也很重要。后面研究随机过程、函数空间和弱收敛时, 我们经常希望取值空间具有良好的极限性质。完备性保证 Cauchy 序列不会“逃出空间”。

■ 紧性

设 (X, τ) 是拓扑空间, $K \subset X$ 。如果对 K 的任意开覆盖, 都存在有限子覆盖, 则称 K 是紧的。

这里, 开覆盖的意思是: 存在一族开集 $\{U_i\}_{i \in I}$, 使得

$$K \subset \bigcup_{i \in I} U_i.$$

如果总能找到有限多个指标 $i_1, \dots, i_n$, 使得

$$K \subset U_{i_1} \cup \dots \cup U_{i_n},$$

那么 K 是紧集。

在 $\mathbb{R}^d$ 中, 有一个非常重要的结论: 一个集合紧, 当且仅当它是闭且有界的。这就是 Heine–Borel 定理。

例如, 在 $\mathbb{R}$ 中,

$$[0, 1]$$

是紧集, 而

$$(0, 1)$$

不是紧集,

$$[0, \infty)$$

也不是紧集。

在度量空间中, 紧性还有一个等价刻画: 一个集合紧, 当且仅当其中任意序列都有一个收敛子列, 并且这个子列的极限仍然属于该集合。

紧性是概率论中非常重要的概念。后面讨论弱收敛时, 紧性会用来刻画概率测度族是否有收敛子列。直观地说, 紧性是一种“不会逃到无穷远”的性质。

■ 函数空间的例子

现代概率论经常研究随机函数或随机路径。因此函数空间是非常重要的例子。

令

$$C[0, 1]$$

表示所有定义在 $[0, 1]$ 上的连续实值函数。对 $f, g \in C[0, 1]$, 定义

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

则 d 是 $C[0, 1]$ 上的一个度量。

在这个度量下, $f_n \rightarrow f$ 等价于 f_n 一致收敛到 f :

$$\sup_{t \in [0, 1]} |f_n(t) - f(t)| \rightarrow 0.$$

这个度量空间在概率论中非常重要。例如, Brownian motion 可以看成取值于函数空间 $C[0, \infty)$ 或 $C[0, 1]$ 的随机元素。也就是说, 对每个样本点 ω , 我们得到一条连续路径

$$t \mapsto B_t(\omega).$$

因此, 随机过程不仅可以看作一族随机变量

$$\{X_t : t \in T\},$$

也可以看作一个取值于函数空间的随机变量

$$X : \Omega \rightarrow C[0, 1].$$

这也是为什么现代概率论需要拓扑空间和度量空间的语言。

■ 拓扑与 Borel σ -代数

现在回到概率论的主线。设 (S, τ) 是一个拓扑空间。我们已经知道 τ 是 S 中所有开集组成的集合族。

由这些开集可以生成一个 σ -代数，称为 S 上的 Borel σ -代数，记作

$$\mathcal{B}(S).$$

也就是说，

$$\mathcal{B}(S) = \sigma(\tau).$$

它是包含所有开集的最小 σ -代数。

当 $S = \mathbb{R}$ 时， $\mathcal{B}(\mathbb{R})$ 称为实数轴上的 Borel σ -代数。它包含所有开区间、闭区间、半开区间、可数集以及许多更复杂的集合。

在概率论中，如果随机变量取值于拓扑空间 S ，我们通常考虑

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S)).$$

这表示：样本空间上的事件系统是 $\mathcal{F}$ ，取值空间上的可测集合系统是 Borel σ -代数 $\mathcal{B}(S)$ 。

若对任意 $B \in \mathcal{B}(S)$ ，都有

$$X^{-1}(B) \in \mathcal{F},$$

则称 X 是可测的。

因此，拓扑通过开集生成 Borel σ -代数，而 Borel σ -代数又决定了哪些关于随机变量取值的事件可以被合法地讨论概率。

■ 为什么概率论需要拓扑

概率论并不只是研究有限样本空间上的概率，也不只是研究实值随机变量。现代概率论经常研究以下对象：

$$X : \Omega \rightarrow \mathbb{R},$$

这是实值随机变量；

$$X : \Omega \rightarrow \mathbb{R}^d,$$

这是随机向量；

$$X : \Omega \rightarrow C[0, 1],$$

这是随机连续函数；

$$X : \Omega \rightarrow D[0, 1],$$

这是带有跳跃的随机路径；

$$X : \Omega \rightarrow \mathcal{P}(S),$$

这是随机概率测度。

这些取值空间通常都带有自然的拓扑或度量。拓扑告诉我们什么叫开集、闭集、收敛、连续、紧性；Borel σ -代数则告诉我们哪些集合是可测的。

因此，拓扑和度量是现代概率论的底层语言之一。

■ 本节小结

本节回顾了拓扑空间和度量空间的基本概念。

首先，度量空间是带有距离的集合。度量

$$d : M \times M \rightarrow [0, \infty)$$

需要满足非负性、对称性和三角不等式。

其次，度量可以定义开球：

$$B_r(x) = \{y \in M : d(x, y) < r\}.$$

由开球可以定义开集。所有开集组成一个拓扑。

再次，拓扑空间是对开集结构的抽象。拓扑 τ 满足：

$$\emptyset, X \in \tau,$$

任意并仍在 τ 中，有限交仍在 τ 中。

然后，我们介绍了内点、闭包、边界、收敛、连续、稠密、可分、完备和紧性等概念。这些概念在后面的概率论中会反复出现。

最后，拓扑和概率论的连接点是 Borel σ -代数。给定拓扑空间 (S, τ) ，其 Borel σ -代数定义为

$$\mathcal{B}(S) = \sigma(\tau).$$

如果随机变量

$$X : \Omega \rightarrow S$$

取值于拓扑空间 S ，那么我们通常要求

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S))$$

是可测映射。也就是说，对任意 Borel 集 $B \in \mathcal{B}(S)$ ，都有

$$X^{-1}(B) \in \mathcal{F}.$$

所以，本节的核心逻辑是：

$$\text{拓扑} \implies \text{Borel } \sigma\text{-代数} \implies \text{随机变量的可测性}.$$

■ 练习

1. 在 $\mathbb{R}$ 中判断下列集合哪些是开集, 哪些是闭集:

$$(0, 1), \quad [0, 1], \quad (0, 1], \quad \mathbb{Q}, \quad \emptyset, \quad \mathbb{R}.$$

2. 设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 定义为

$$f(x) = x^2.$$

求

$$f^{-1}((1, 4)).$$

3. 设 (M, d) 是度量空间, 证明任意开球

$$B_r(x) = \{y \in M : d(x, y) < r\}$$

是开集。

4. 设 (M, d) 是度量空间, $x_n \rightarrow x$. 证明如果极限存在, 则极限唯一。

5. 设 $A = (0, 1) \subset \mathbb{R}$. 求

$$A^\circ, \quad \overline{A}, \quad \partial A.$$

6. 设 $A = \mathbb{Q} \subset \mathbb{R}$. 求

$$\overline{A}.$$

并解释为什么 $\mathbb{Q}$ 在 $\mathbb{R}$ 中稠密。

7. 设 M 是任意集合, 并在 M 上定义离散度量

$$d(x, y) = \begin{cases} 0, & x = y, \\ 1, & x \neq y. \end{cases}$$

证明在这个度量下, M 的任意子集都是开集。

8. 设 $C[0, 1]$ 上定义距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

解释为什么 $f_n \rightarrow f$ 在这个距离下等价于 f_n 一致收敛到 f 。

1.3 Borel σ -代数

在上一节中, 我们回顾了拓扑空间和度量空间的基本语言。拓扑告诉我们一个空间中哪些集合是开集, 度量则进一步告诉我们什么叫距离、收敛、连续和紧性。

但是在概率论中，仅有拓扑还不够。概率测度并不是定义在所有开集上，而是定义在一个 σ -代数上。因此，如果随机变量取值于一个拓扑空间 S ，我们需要在 S 上指定一个自然的可测集合系统。

这个可测集合系统就是由拓扑生成的 Borel σ -代数。

本节的核心逻辑是：

$$\text{拓扑} \implies \text{开集} \implies \text{Borel } \sigma\text{-代数} \implies \text{随机变量的可测性}.$$

■ 由集合族生成的 σ -代数

在定义 Borel σ -代数之前，我们先回顾一个更一般的概念。

设 S 是一个集合， $\mathcal{C} \subset 2^S$ 是 S 的某些子集组成的集合族。我们希望找到一个 σ -代数，它包含 $\mathcal{C}$ ，并且尽可能小。

这个最小的 σ -代数称为由 $\mathcal{C}$ 生成的 σ -代数，记作

$$\sigma(\mathcal{C}).$$

严格地说，

$$\sigma(\mathcal{C}) = \bigcap \{ \mathcal{A} : \mathcal{A} \text{ 是 } S \text{ 上的 } \sigma\text{-代数, 且 } \mathcal{C} \subset \mathcal{A} \}.$$

也就是说，我们把所有包含 $\mathcal{C}$ 的 σ -代数全部取出来，然后取它们的交集。这个交集仍然是一个 σ -代数，并且是包含 $\mathcal{C}$ 的最小 σ -代数。

直观地说， $\sigma(\mathcal{C})$ 是从 $\mathcal{C}$ 中的集合出发，反复进行补集、可数并、可数交之后，必须包含进去的所有集合。

■ Borel σ -代数的定义

设 (S, τ) 是一个拓扑空间，其中 τ 表示 S 中所有开集组成的集合族。

定义. 由拓扑 τ 生成的 σ -代数称为 S 上的 Borel σ -代数，记作

$$\mathcal{B}(S).$$

也就是说，

$$\mathcal{B}(S) = \sigma(\tau).$$

因此，Borel σ -代数是包含所有开集的最小 σ -代数。换句话说， $B \subset S$ 是 Borel 集，意思是

$$B \in \mathcal{B}(S).$$

Borel 集不一定是开集，也不一定是闭集。它们是由开集通过可数次集合运算构造出来的集合。

■ 为什么需要 Borel σ -代数

概率论中经常写

$$\mathbb{P}(X \in B).$$

这里 X 是一个随机变量, B 是取值空间中的集合。假设

$$X : \Omega \rightarrow S.$$

那么事件 $\{X \in B\}$ 的严格含义是

$$\{X \in B\} = X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

概率测度 $\mathbb{P}$ 是定义在样本空间 Ω 上的事件系统 $\mathcal{F}$ 上的。因此, 要使

$$\mathbb{P}(X \in B)$$

有意义, 必须要求

$$X^{-1}(B) \in \mathcal{F}.$$

所以我们不能随便取 S 的任意子集 B 。我们需要在取值空间 S 上指定一个合理的可测集合系统。对于拓扑空间 S , 最自然的选择就是 Borel σ -代数 $\mathcal{B}(S)$ 。

因此, 在现代概率论中, 如果随机变量取值于拓扑空间 S , 通常写成

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S)).$$

这表示: X 是从可测空间 $(\Omega, \mathcal{F})$ 到可测空间 $(S, \mathcal{B}(S))$ 的映射。

如果对任意 $B \in \mathcal{B}(S)$, 都有

$$X^{-1}(B) \in \mathcal{F},$$

那么称 X 是可测的。

■ 实数轴上的 Borel σ -代数

最重要的例子是实数轴 $\mathbb{R}$ 。

在 $\mathbb{R}$ 上, 我们使用通常拓扑。也就是说, 开集由开区间生成。实数轴上的 Borel σ -代数记作

$$\mathcal{B}(\mathbb{R}).$$

根据定义,

$$\mathcal{B}(\mathbb{R}) = \sigma(\text{所有开集}).$$

由于 $\mathbb{R}$ 中任意开集都可以写成可数个开区间的并, 所以也有

$$\mathcal{B}(\mathbb{R}) = \sigma\{(a, b) : a < b\}.$$

这里 (a, b) 表示所有开区间组成的集合族。

进一步地, $\mathcal{B}(\mathbb{R})$ 也可以由下列集合族生成:

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t) : t \in \mathbb{R}\},$$

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\},$$

$$\mathcal{B}(\mathbb{R}) = \sigma\{(t, \infty) : t \in \mathbb{R}\},$$

$$\mathcal{B}(\mathbb{R}) = \sigma\{[t, \infty) : t \in \mathbb{R}\}.$$

这些表示在概率论中非常重要, 因为它们允许我们用形如

$$\{X \leq t\}, \quad \{X < t\}$$

的事件来判断实值随机变量的可测性。

■ 一些基本的 Borel 集

首先, 所有开集都是 Borel 集。因为 Borel σ -代数就是包含所有开集的最小 σ -代数。

其次, 所有闭集也是 Borel 集。因为如果 $F \subset S$ 是闭集, 那么 F^c 是开集, 所以

$$F^c \in \mathcal{B}(S).$$

而 $\mathcal{B}(S)$ 对补集封闭, 因此

$$F \in \mathcal{B}(S).$$

在 $\mathbb{R}$ 中, 闭区间 $[a, b]$ 是 Borel 集。事实上,

$$[a, b]^c = (-\infty, a) \cup (b, \infty),$$

右边是开集, 因此 $[a, b]^c$ 是 Borel 集, 所以 $[a, b]$ 也是 Borel 集。

半开区间也是 Borel 集。例如,

$$(a, b] = (a, \infty) \cap (-\infty, b].$$

因为 (a, ∞) 和 $(-\infty, b]$ 都是 Borel 集, 所以 $(a, b]$ 也是 Borel 集。

单点集也是 Borel 集。对任意 $a \in \mathbb{R}$, 有

$$\{a\} = \bigcap_{n=1}^{\infty} \left(a - \frac{1}{n}, a + \frac{1}{n}\right).$$

每个

$$\left(a - \frac{1}{n}, a + \frac{1}{n}\right)$$

都是开区间, 因此是 Borel 集。由于 Borel σ -代数对可数交封闭, 所以

$$\{a\} \in \mathcal{B}(\mathbb{R}).$$

有限集也是 Borel 集，因为有限集是有限个单点集的并。

可数集也是 Borel 集。若

$$A = \{a_1, a_2, a_3, \dots\},$$

则

$$A = \bigcup_{n=1}^{\infty} \{a_n\}.$$

每个单点集 $\{a_n\}$ 是 Borel 集，而 Borel σ -代数对可数并封闭，所以

$$A \in \mathcal{B}(\mathbb{R}).$$

因此，有理数集 $\mathbb{Q}$ 是 Borel 集。它的补集 $\mathbb{R} \setminus \mathbb{Q}$ ，即无理数集，也是 Borel 集。

■ Borel 集不只是开集和闭集

需要注意的是，Borel 集并不等于开集和闭集的并。

例如，

$$(0, 1]$$

既不是开集，也不是闭集，但它是 Borel 集。

又如，

$$\mathbb{Q}$$

既不是开集，也不是闭集，但它是 Borel 集。

所以，Borel 集比开集和闭集丰富得多。它们包含所有可以通过开集进行可数次集合运算得到的集合。

可以粗略地理解为：

开集、闭集、半开区间、可数集 $\subset$ Borel 集。

■ Borel σ -代数不一定是所有子集

如果 S 是有限集合，并且使用离散拓扑，那么 S 的每个子集都是开集。因此，

$$\mathcal{B}(S) = 2^S.$$

更一般地，如果 S 是可数集合，并且使用离散拓扑，那么每个子集都是开集，所以仍然有

$$\mathcal{B}(S) = 2^S.$$

但是在实数轴 $\mathbb{R}$ 上，

$$\mathcal{B}(\mathbb{R}) \neq 2^{\mathbb{R}}.$$

也就是说，实数轴上存在不是 Borel 集的子集。这样的集合通常比较病态，构造它们需要用到更深的集合论工具。

在现代概率论中，我们通常不直接处理任意子集，而是处理 Borel 集，或者在测度完成化之后处理 Lebesgue 可测集。

■ 实值随机变量的可测性判别

设 $(\Omega, \mathcal{F})$ 是一个可测空间, $X : \Omega \rightarrow \mathbb{R}$ 是一个函数。

根据定义, X 是实值随机变量, 如果

$$X^{-1}(B) \in \mathcal{F}, \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

直接检查所有 Borel 集通常很困难。但由于 $\mathcal{B}(\mathbb{R})$ 可以由半直线生成, 我们有下面的常用判别准则:

$$X \text{ 可测} \iff \{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}.$$

同样, 也有

$$X \text{ 可测} \iff \{X < t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}.$$

这里

$$\{X \leq t\} = X^{-1}((-\infty, t]).$$

因此, 实值随机变量的可测性可以通过所有左半直线事件来判断。

■ 证明思路

我们说明为什么只需要检查 $\{X \leq t\}$ 。

定义

$$\mathcal{D} = \{B \subset \mathbb{R} : X^{-1}(B) \in \mathcal{F}\}.$$

我们先证明 $\mathcal{D}$ 是 $\mathbb{R}$ 上的一个 σ -代数。

首先,

$$X^{-1}(\mathbb{R}) = \Omega \in \mathcal{F},$$

所以

$$\mathbb{R} \in \mathcal{D}.$$

其次, 如果 $B \in \mathcal{D}$, 则

$$X^{-1}(B^c) = (X^{-1}(B))^c.$$

由于 $X^{-1}(B) \in \mathcal{F}$, 而 $\mathcal{F}$ 对补集封闭, 所以

$$X^{-1}(B^c) \in \mathcal{F}.$$

因此

$$B^c \in \mathcal{D}.$$

最后, 如果 $B_1, B_2, \dots \in \mathcal{D}$, 则

$$X^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} X^{-1}(B_n).$$

右边属于 $\mathcal{F}$, 所以

$$\bigcup_{n=1}^{\infty} B_n \in \mathcal{D}.$$

因此, $\mathcal{D}$ 是 σ -代数。

如果对每个 $t \in \mathbb{R}$ 都有

$$\{X \leq t\} \in \mathcal{F},$$

那么

$$X^{-1}((-\infty, t]) \in \mathcal{F}.$$

也就是说,

$$(-\infty, t] \in \mathcal{D}, \quad \forall t \in \mathbb{R}.$$

因此 $\mathcal{D}$ 包含集合族

$$\{(-\infty, t] : t \in \mathbb{R}\}.$$

由于 $\mathcal{D}$ 是 σ -代数, 它必然包含由这些集合生成的最小 σ -代数:

$$\sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

而

$$\sigma\{(-\infty, t] : t \in \mathbb{R}\} = \mathcal{B}(\mathbb{R}).$$

所以

$$\mathcal{B}(\mathbb{R}) \subset \mathcal{D}.$$

这说明对任意 Borel 集 $B \in \mathcal{B}(\mathbb{R})$, 都有

$$X^{-1}(B) \in \mathcal{F}.$$

因此 X 是可测的。

■ 连续函数是 Borel 可测的

设 (S, τ_S) 和 (T, τ_T) 是两个拓扑空间。若

$$f : S \rightarrow T$$

是连续映射, 则对任意开集 $U \in \tau_T$, 都有

$$f^{-1}(U) \in \tau_S.$$

由于

$$\tau_S \subset \mathcal{B}(S),$$

所以

$$f^{-1}(U) \in \mathcal{B}(S).$$

由开集生成 Borel σ -代数可知, 对任意

$$B \in \mathcal{B}(T),$$

都有

$$f^{-1}(B) \in \mathcal{B}(S).$$

因此, 连续映射一定是 Borel 可测映射:

$$f : (S, \mathcal{B}(S)) \rightarrow (T, \mathcal{B}(T)).$$

特别地, 若

$$f : \mathbb{R} \rightarrow \mathbb{R}$$

连续, 则 f 是 Borel 可测函数。

例如,

$$f(x) = x^2$$

是连续函数, 所以它是 Borel 可测的。

但是反过来不成立。Borel 可测函数不一定连续。例如, 函数

$$1_{\mathbb{Q}}(x) = \begin{cases} 1, & x \in \mathbb{Q}, \\ 0, & x \notin \mathbb{Q}, \end{cases}$$

处处不连续, 但它仍然是 Borel 可测的。因为 $\mathbb{Q}$ 和 $\mathbb{R} \setminus \mathbb{Q}$ 都是 Borel 集。

■ $\mathbb{R}^d$ 上的 Borel σ -代数

在 $\mathbb{R}^d$ 上, 我们使用通常的欧氏拓扑。其 Borel σ -代数记作

$$\mathcal{B}(\mathbb{R}^d).$$

它可以由所有开集生成:

$$\mathcal{B}(\mathbb{R}^d) = \sigma(\text{所有开集}).$$

也可以由所有开球生成:

$$\mathcal{B}(\mathbb{R}^d) = \sigma\{B_r(x) : x \in \mathbb{R}^d, r > 0\}.$$

还可以由所有开矩形生成:

$$\mathcal{B}(\mathbb{R}^d) = \sigma\{(a_1, b_1) \times \cdots \times (a_d, b_d) : a_i < b_i\}.$$

在概率论中, 随机向量

$$X = (X_1, \dots, X_d)$$

可以看作从样本空间到 $\mathbb{R}^d$ 的映射：

$$X : \Omega \rightarrow \mathbb{R}^d.$$

它的可测性通常表示为

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)).$$

如果每个分量 X_i 都是实值随机变量，则随机向量 $X = (X_1, \dots, X_d)$ 是 $\mathbb{R}^d$ 值随机变量。

■ 函数空间上的 Borel σ -代数

现代概率论中，随机变量的取值空间不一定是 $\mathbb{R}$ 或 $\mathbb{R}^d$ ，也可能是函数空间。

例如，令

$$C[0, 1]$$

表示所有定义在 $[0, 1]$ 上的连续实值函数。

在 $C[0, 1]$ 上定义距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

这个距离对应一致收敛拓扑。由这个拓扑生成的 Borel σ -代数记作

$$\mathcal{B}(C[0, 1]).$$

如果一个随机过程具有连续样本路径，那么它可以看成一个取值于 $C[0, 1]$ 的随机元素：

$$X : \Omega \rightarrow C[0, 1].$$

此时，可测性写作

$$X : (\Omega, \mathcal{F}) \rightarrow (C[0, 1], \mathcal{B}(C[0, 1])).$$

这说明，对于每个 Borel 集

$$B \in \mathcal{B}(C[0, 1]),$$

事件

$$\{X \in B\}$$

都属于 $\mathcal{F}$ ，从而可以讨论其概率。

这正是现代概率论研究随机过程时需要函数空间和 Borel σ -代数的原因。

■ 分布作为推出测度

设

$$X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{B}(S))$$

是一个随机变量。对任意 $B \in \mathcal{B}(S)$ ，定义

$$\mu_X(B) = \mathbb{P}(X \in B).$$

根据原像的写法，

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)).$$

这样得到的 μ_X 是定义在 $(S, \mathcal{B}(S))$ 上的概率测度，称为随机变量 X 的分布。

常记为

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

这个记号表示：先把 $B \subset S$ 通过 X^{-1} 拉回到样本空间 Ω ，再用 $\mathbb{P}$ 计算概率。

因此，随机变量的分布不是凭空定义的，而是样本空间上的概率测度通过随机变量诱导出来的。

■ 本节小结

本节介绍了 Borel σ -代数。

首先，如果 (S, τ) 是拓扑空间，那么 S 上的 Borel σ -代数定义为

$$\mathcal{B}(S) = \sigma(\tau).$$

它是包含所有开集的最小 σ -代数。

其次，在实数轴上，

$$\mathcal{B}(\mathbb{R}) = \sigma\{(a, b) : a < b\}.$$

它也可以由半直线生成：

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

再次，Borel 集包括开集、闭集、半开区间、单点集、有限集、可数集等，但在 $\mathbb{R}$ 上 Borel σ -代数并不等于所有子集。

然后，Borel σ -代数是定义随机变量可测性的自然取值空间结构。若

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S))$$

满足

$$X^{-1}(B) \in \mathcal{F}, \quad \forall B \in \mathcal{B}(S),$$

则称 X 是可测的。

对于实值函数 $X : \Omega \rightarrow \mathbb{R}$ ，可测性可以通过

$$\{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}$$

来判断。

最后,连续映射一定是 Borel 可测映射。因此,拓扑中的连续性天然地导向概率论中的可测性。

核心思想: Borel σ -代数把拓扑中的开集结构转化为概率论中的可测事件结构。

■ 练习

1. 证明 $\mathbb{R}$ 中的闭区间 $[a, b]$ 是 Borel 集。
2. 证明单点集 $\{a\}$ 是 $\mathbb{R}$ 中的 Borel 集。
3. 证明任意可数集 $A \subset \mathbb{R}$ 都是 Borel 集。
4. 判断下列集合是否属于 $\mathcal{B}(\mathbb{R})$:

$$(0, 1), \quad [0, 1], \quad (0, 1], \quad \mathbb{Q}, \quad \mathbb{R} \setminus \mathbb{Q}.$$

5. 设 $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ 。证明如果

$$\{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R},$$

那么 X 是实值随机变量。

6. 设 X, Y 是实值随机变量。证明事件

$$\{X < Y\}$$

属于 $\mathcal{F}$ 。

7. 设 $f : \mathbb{R} \rightarrow \mathbb{R}$ 连续。证明 f 是 Borel 可测函数。

8. 设

$$f(x) = 1_{\mathbb{Q}}(x).$$

判断 f 是否是 Borel 可测函数,并说明理由。

9. 设 S 是一个有限集合,并赋予离散拓扑。证明

$$\mathcal{B}(S) = 2^S.$$

10. 设 $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{B}(S))$ 是随机变量。定义

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{B}(S).$$

证明 μ_X 是 $(S, \mathcal{B}(S))$ 上的概率测度。

1.4 生成类、 π -系统与 λ -系统

前面我们已经看到，概率论中大量对象都是定义在某个 σ -代数上的。比如实值随机变量的取值空间通常写作

$$(\mathbb{R}, \mathcal{B}(\mathbb{R})),$$

其中

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

这句话暗示了一个非常重要的思想：很多时候，我们并不需要直接检查整个 σ -代数，只需要检查一个较小的生成类即可。

本节的目标是说明：

如何从一个小的生成类出发，把结论推广到整个 σ -代数。

这里的核心工具是 π -系统、 λ -系统以及 π - λ 定理。

■ 生成类

设 Ω 是一个集合， $\mathcal{C} \subset 2^\Omega$ 是 Ω 的某些子集组成的集合族。由 $\mathcal{C}$ 生成的 σ -代数记作

$$\sigma(\mathcal{C}).$$

它定义为包含 $\mathcal{C}$ 的最小 σ -代数，即

$$\sigma(\mathcal{C}) = \bigcap \{ \mathcal{A} : \mathcal{A} \text{ 是 } \Omega \text{ 上的 } \sigma\text{-代数, 且 } \mathcal{C} \subset \mathcal{A} \}.$$

直观地说， $\sigma(\mathcal{C})$ 是从 $\mathcal{C}$ 中的集合出发，反复进行补集、可数并、可数交之后必须得到的所有集合。

例. 在实数轴上，通常拓扑的 Borel σ -代数可以写成

$$\mathcal{B}(\mathbb{R}) = \sigma\{(a, b) : a < b\}.$$

也可以写成

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

因此，半直线族 $\{(-\infty, t] : t \in \mathbb{R}\}$ 虽然很小，却能够生成全部 Borel 集。

■ π -系统

定义. 设 $\mathcal{P} \subset 2^\Omega$ 。如果对任意 $A, B \in \mathcal{P}$ ，都有

$$A \cap B \in \mathcal{P},$$

那么称 $\mathcal{P}$ 是一个 π -系统。

也就是说， π -系统就是对有限交封闭的集合族。

例. 集合族

$$\mathcal{P} = \{(-\infty, t] : t \in \mathbb{R}\}$$

是 $\mathbb{R}$ 上的一个 π -系统。因为对任意 $s, t \in \mathbb{R}$, 有

$$(-\infty, s] \cap (-\infty, t] = (-\infty, \min\{s, t\}] \in \mathcal{P}.$$

例: 矩形类. 设 S, T 是两个集合, $\mathcal{A} \subset 2^S$, $\mathcal{B} \subset 2^T$. 若 $\mathcal{A}$ 和 $\mathcal{B}$ 都对有限交封闭, 则

$$\mathcal{P} = \{A \times B : A \in \mathcal{A}, B \in \mathcal{B}\}$$

是 $S \times T$ 上的 π -系统。因为

$$(A_1 \times B_1) \cap (A_2 \times B_2) = (A_1 \cap A_2) \times (B_1 \cap B_2).$$

这个例子在乘积 σ -代数、独立性以及乘积测度中非常重要。

■ λ -系统

定义. 设 $\mathcal{D} \subset 2^\Omega$. 如果 $\mathcal{D}$ 满足以下三条性质, 则称 $\mathcal{D}$ 是一个 λ -系统, 也称为 Dynkin 系统:

1. $\Omega \in \mathcal{D}$;
2. 若 $A \in \mathcal{D}$, 则 $A^c \in \mathcal{D}$;
3. 若 $A_1, A_2, \dots \in \mathcal{D}$ 两两不交, 则

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

λ -系统和 σ -代数非常相似, 但略弱一些。 σ -代数要求对任意可数并封闭, 而 λ -系统只要求对两两不交的可数并封闭。

注. 每个 σ -代数都是 λ -系统。因为 σ -代数包含全集、对补集封闭, 并且对任意可数并封闭, 当然也对两两不交的可数并封闭。

■ 基本关系

命题. 如果一个集合族 $\mathcal{D}$ 既是 π -系统, 又是 λ -系统, 那么 $\mathcal{D}$ 是一个 σ -代数。

证明. 因为 $\mathcal{D}$ 是 λ -系统, 所以

$$\Omega \in \mathcal{D},$$

并且 $\mathcal{D}$ 对补集封闭。因此只需要证明 $\mathcal{D}$ 对任意可数并封闭。

取任意 $A_1, A_2, \dots \in \mathcal{D}$. 这些集合不一定两两不交。我们把它们改写成两两不交的集合:

$$B_1 = A_1,$$

并且对 $n \geq 2$ 定义

$$B_n = A_n \setminus \bigcup_{k=1}^{n-1} A_k.$$

由于 $\mathcal{D}$ 是 π -系统并且对补集封闭, 所以它对有限并封闭。事实上,

$$A \cup B = (A^c \cap B^c)^c.$$

因此

$$\bigcup_{k=1}^{n-1} A_k \in \mathcal{D}.$$

又因为 $\mathcal{D}$ 对补集封闭且对交封闭, 所以

$$B_n = A_n \cap \left(\bigcup_{k=1}^{n-1} A_k \right)^c \in \mathcal{D}.$$

显然 $B_1, B_2, \dots$ 两两不交。由 λ -系统的定义,

$$\bigcup_{n=1}^{\infty} B_n \in \mathcal{D}.$$

而

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

所以 $\mathcal{D}$ 对任意可数并封闭。因此 $\mathcal{D}$ 是 σ -代数。

■ π - λ 定理

定义. 设 $\mathcal{P} \subset 2^\Omega$ 。包含 $\mathcal{P}$ 的最小 λ -系统记作

$$\lambda(\mathcal{P}).$$

也就是说,

$$\lambda(\mathcal{P}) = \bigcap \{ \mathcal{D} : \mathcal{D} \text{ 是 } \lambda\text{-系统, 且 } \mathcal{P} \subset \mathcal{D} \}.$$

定理: π - λ 定理. 若 $\mathcal{P}$ 是一个 π -系统, 则

$$\lambda(\mathcal{P}) = \sigma(\mathcal{P}).$$

等价地, 若 $\mathcal{D}$ 是一个 λ -系统, 且

$$\mathcal{P} \subset \mathcal{D},$$

则

$$\sigma(\mathcal{P}) \subset \mathcal{D}.$$

证明. 记

$$\mathcal{L} = \lambda(\mathcal{P}).$$

因为 $\sigma(\mathcal{P})$ 是一个 σ -代数, 所以它也是 λ -系统, 并且包含 $\mathcal{P}$ 。由 $\lambda(\mathcal{P})$ 的最小性,

$$\mathcal{L} \subset \sigma(\mathcal{P}).$$

因此只需要证明反向包含

$$\sigma(\mathcal{P}) \subset \mathcal{L}.$$

为此, 只要证明 $\mathcal{L}$ 本身是 σ -代数即可。

第一步: 差集引理. 若 $\mathcal{D}$ 是 λ -系统, $A, B \in \mathcal{D}$, 且 $A \subset B$, 则

$$B \setminus A \in \mathcal{D}.$$

事实上, 因为 $B \in \mathcal{D}$, 所以 $B^c \in \mathcal{D}$ 。又因为 $A \subset B$, 所以 A 与 B^c 不交。由 λ -系统对两两不交可数并封闭,

$$A \cup B^c \in \mathcal{D}.$$

再取补集, 得到

$$(A \cup B^c)^c \in \mathcal{D}.$$

而

$$(A \cup B^c)^c = A^c \cap B = B \setminus A.$$

所以 $B \setminus A \in \mathcal{D}$ 。

第二步: 先固定一个 $A \in \mathcal{P}$ 。对固定的 $A \in \mathcal{P}$, 定义

$$\mathcal{L}_A = \{B \subset \Omega : A \cap B \in \mathcal{L}\}.$$

我们证明 $\mathcal{L}_A$ 是 λ -系统。

首先,

$$A \cap \Omega = A \in \mathcal{P} \subset \mathcal{L},$$

所以

$$\Omega \in \mathcal{L}_A.$$

其次, 若 $B \in \mathcal{L}_A$, 则

$$A \cap B \in \mathcal{L}.$$

因为 $A \in \mathcal{P} \subset \mathcal{L}$, 且

$$A \cap B \subset A,$$

由差集引理可得

$$A \setminus (A \cap B) \in \mathcal{L}.$$

但

$$A \setminus (A \cap B) = A \cap B^c.$$

所以

$$A \cap B^c \in \mathcal{L},$$

即

$$B^c \in \mathcal{L}_A.$$

最后, 若 $B_1, B_2, \dots \in \mathcal{L}_A$ 两两不交, 则

$$A \cap B_n \in \mathcal{L}, \quad n = 1, 2, \dots$$

并且 $A \cap B_1, A \cap B_2, \dots$ 仍然两两不交。因此

$$\bigcup_{n=1}^{\infty} (A \cap B_n) \in \mathcal{L}.$$

又有

$$\bigcup_{n=1}^{\infty} (A \cap B_n) = A \cap \left(\bigcup_{n=1}^{\infty} B_n \right).$$

所以

$$\bigcup_{n=1}^{\infty} B_n \in \mathcal{L}_A.$$

因此 $\mathcal{L}_A$ 是 λ -系统。

另一方面, 因为 $\mathcal{P}$ 是 π -系统, 且 $A \in \mathcal{P}$, 所以对任意 $B \in \mathcal{P}$,

$$A \cap B \in \mathcal{P} \subset \mathcal{L}.$$

这说明

$$\mathcal{P} \subset \mathcal{L}_A.$$

由于 $\mathcal{L} = \lambda(\mathcal{P})$ 是包含 $\mathcal{P}$ 的最小 λ -系统, 得到

$$\mathcal{L} \subset \mathcal{L}_A.$$

于是我们已经证明:

$$A \in \mathcal{P}, \quad B \in \mathcal{L} \implies A \cap B \in \mathcal{L}.$$

第三步: 再固定一个 $B \in \mathcal{L}$. 对固定的 $B \in \mathcal{L}$, 定义

$$\mathcal{M}_B = \{A \subset \Omega : A \cap B \in \mathcal{L}\}.$$

与上一步完全类似, 可以证明 $\mathcal{M}_B$ 是 λ -系统。

根据第二步的结论, 对任意 $A \in \mathcal{P}$, 都有

$$A \cap B \in \mathcal{L}.$$

所以

$$\mathcal{P} \subset \mathcal{M}_B.$$

由最小性,

$$\mathcal{L} \subset \mathcal{M}_B.$$

因此

$$A, B \in \mathcal{L} \implies A \cap B \in \mathcal{L}.$$

这说明 $\mathcal{L}$ 是 π -系统。

第四步：收尾。 我们已经知道 $\mathcal{L}$ 是 λ -系统，同时刚刚证明了 $\mathcal{L}$ 是 π -系统。由前面的命题， $\mathcal{L}$ 是 σ -代数。

又因为 $\mathcal{L}$ 包含 $\mathcal{P}$ ，而 $\sigma(\mathcal{P})$ 是包含 $\mathcal{P}$ 的最小 σ -代数，所以

$$\sigma(\mathcal{P}) \subset \mathcal{L}.$$

结合一开始得到的

$$\mathcal{L} \subset \sigma(\mathcal{P}),$$

可得

$$\lambda(\mathcal{P}) = \sigma(\mathcal{P}).$$

证毕。

■ 应用一：测度在生成类上一致

定理：唯一性定理。 设 μ, ν 是同一个可测空间 $(\Omega, \mathcal{F})$ 上的概率测度。设 $\mathcal{P}$ 是一个 π -系统，且

$$\sigma(\mathcal{P}) = \mathcal{F}.$$

如果

$$\mu(A) = \nu(A), \quad \forall A \in \mathcal{P},$$

那么

$$\mu(A) = \nu(A), \quad \forall A \in \mathcal{F}.$$

证明。 定义

$$\mathcal{D} = \{A \in \mathcal{F} : \mu(A) = \nu(A)\}.$$

我们证明 $\mathcal{D}$ 是 λ -系统。

首先，

$$\mu(\Omega) = \nu(\Omega) = 1,$$

所以 $\Omega \in \mathcal{D}$ 。

其次，若 $A \in \mathcal{D}$ ，则

$$\mu(A) = \nu(A).$$

因此

$$\mu(A^c) = 1 - \mu(A) = 1 - \nu(A) = \nu(A^c),$$

所以 $A^c \in \mathcal{D}$ 。

最后, 若 $A_1, A_2, \dots \in \mathcal{D}$ 两两不交, 则由测度的可数可加性,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) = \sum_{n=1}^{\infty} \nu(A_n) = \nu\left(\bigcup_{n=1}^{\infty} A_n\right).$$

所以

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

因此 $\mathcal{D}$ 是 λ -系统。

由假设, $\mathcal{P} \subset \mathcal{D}$ 。又因为 $\mathcal{P}$ 是 π -系统, 由 π - λ 定理,

$$\sigma(\mathcal{P}) \subset \mathcal{D}.$$

但 $\sigma(\mathcal{P}) = \mathcal{F}$, 所以 $\mathcal{F} \subset \mathcal{D}$ 。因此两个概率测度在整个 $\mathcal{F}$ 上相等。

■ 应用二：分布函数决定分布

设 X, Y 是两个实值随机变量。如果对任意 $t \in \mathbb{R}$, 都有

$$\mathbb{P}(X \leq t) = \mathbb{P}(Y \leq t),$$

那么 X 和 Y 分布相同。

令 μ_X 与 μ_Y 分别为 X, Y 的分布, 即

$$\mu_X(B) = \mathbb{P}(X \in B), \quad \mu_Y(B) = \mathbb{P}(Y \in B), \quad B \in \mathcal{B}(\mathbb{R}).$$

条件可以改写为

$$\mu_X((-\infty, t]) = \mu_Y((-\infty, t]), \quad \forall t \in \mathbb{R}.$$

设

$$\mathcal{P} = \{(-\infty, t] : t \in \mathbb{R}\}.$$

前面已经知道 $\mathcal{P}$ 是 π -系统, 并且

$$\sigma(\mathcal{P}) = \mathcal{B}(\mathbb{R}).$$

由测度唯一性定理,

$$\mu_X(B) = \mu_Y(B), \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

因此 X 与 Y 分布相同。

这说明实值随机变量的分布函数

$$F_X(t) = \mathbb{P}(X \leq t)$$

完全决定 X 的分布。

■ 应用三：独立性的生成类判别

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $\mathcal{A}, \mathcal{B} \subset \mathcal{F}$ 是两个 π -系统。若

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B), \quad \forall A \in \mathcal{A}, \quad B \in \mathcal{B},$$

则可以推出

$$\mathbb{P}(C \cap D) = \mathbb{P}(C)\mathbb{P}(D), \quad \forall C \in \sigma(\mathcal{A}), \quad D \in \sigma(\mathcal{B}).$$

直观地说, 若两个事件族在生成的 π -系统层面独立, 那么它们生成的 σ -代数也独立。这条结论是随机变量独立性、随机过程独立增量以及乘积概率空间中的基础工具。

■ 本节小结

本节的核心可以概括为四句话:

π -系统: 对有限交封闭;

λ -系统: 包含全集, 对补集封闭, 对两两不交可数并封闭;

σ -代数: 同时具有足够强的补集和可数并封闭性;

π - λ 定理: 在生成的 π -系统上验证, 可以推广到整个 σ -代数。

在概率论中, 这个定理的典型用途是:

1. 证明两个概率测度相等;
2. 证明分布函数决定分布;
3. 从简单事件的独立性推广到 σ -代数的独立性;
4. 在乘积空间和随机过程构造中, 从矩形类推广到完整可测结构。

核心思想: π - λ 定理允许我们先在一个小而稳定的生成类上验证命题, 再把结论推广到由它生成的整个 σ -代数。

■ 练习

1. 证明 $\mathcal{P} = \{(-\infty, t] : t \in \mathbb{R}\}$ 是 $\mathbb{R}$ 上的 π -系统。
2. 设 $\mathcal{D}$ 是 λ -系统。证明如果 $A, B \in \mathcal{D}$ 且 $A \subset B$, 则 $B \setminus A \in \mathcal{D}$ 。
3. 证明: 如果 $\mathcal{D}$ 既是 π -系统又是 λ -系统, 那么 $\mathcal{D}$ 是 σ -代数。
4. 设 μ, ν 是 $\mathbb{R}$ 上的两个概率测度。若

$$\mu((-\infty, t]) = \nu((-\infty, t]), \quad \forall t \in \mathbb{R},$$

证明

$$\mu(B) = \nu(B), \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

5. 设 X, Y 是实值随机变量。若

$$\mathbb{P}(X \leq t) = \mathbb{P}(Y \leq t), \quad \forall t \in \mathbb{R},$$

证明 X 与 Y 分布相同。

1.5 可测空间与可测映射

在前面的几节中，我们已经逐步建立了现代概率论的基本语言。

首先，概率论并不是直接从公式开始，而是从样本空间、事件和映射开始。样本空间

$$\Omega$$

表示所有可能的随机结果，而事件是样本空间中的某些子集。其次，我们看到，概率论中真正重要的并不是普通意义下的集合族，而是满足封闭性的事件系统，也就是 σ -代数。最后，在 Borel σ -代数和生成类的讨论中，我们看到，很多复杂的可测结构可以由较小的集合族生成。

本节要讨论的核心问题是：

什么样的映射可以被看作概率论中的随机变量？

普通集合论中，一个函数只是一个映射

$$X : \Omega \rightarrow S.$$

但是在概率论中，仅有函数结构是不够的。因为我们想讨论

$$\mathbb{P}(X \in B),$$

其中 $B \subset S$ 是取值空间中的集合。严格地说，

$$\{X \in B\} = X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

概率 $\mathbb{P}$ 是定义在样本空间的事件系统上的，所以要使 $\mathbb{P}(X \in B)$ 有意义，就必须要求

$$X^{-1}(B) \in \mathcal{F}.$$

这正是可测映射的思想。

■ 可测空间

定义：可测空间。设 Ω 是一个集合， $\mathcal{F} \subset 2^\Omega$ 是 Ω 上的一个 σ -代数。二元组

$$(\Omega, \mathcal{F})$$

称为一个可测空间。 $\mathcal{F}$ 中的集合称为可测集合。在概率论语境下， $\mathcal{F}$ 中的集合也称为事件。

这里 Ω 只是一个底层集合，而 $\mathcal{F}$ 指定了哪些子集是允许被讨论的集合。也就是说，并不是 Ω 的所有子集都一定被视为事件。我们只把 $\mathcal{F}$ 中的集合看作合法事件。

例如，如果

$$\Omega = \{1, 2, 3, 4, 5, 6\},$$

并且

$$\mathcal{F} = 2^\Omega,$$

那么所有子集都是事件。这适合有限样本空间中的初等概率论。

但是如果

$$\Omega = \mathbb{R},$$

通常不会直接取 $\mathcal{F} = 2^\mathbb{R}$ ，而是取

$$\mathcal{F} = \mathcal{B}(\mathbb{R}),$$

也就是实数轴上的 Borel σ -代数。

因此，一个可测空间的意义是：它不仅告诉我们底层点集是什么，还告诉我们哪些集合是可测的、哪些事件是合法的。

■ 可测映射的定义

设有两个可测空间

$$(\Omega, \mathcal{F}), \quad (S, \mathcal{S}).$$

一个映射

$$X : \Omega \rightarrow S$$

把每个 $\omega \in \Omega$ 送到一个取值 $X(\omega) \in S$ 。但是要让 X 成为概率论中合法的随机对象，还需要它和两个 σ -代数相容。

定义：可测映射。 设 $(\Omega, \mathcal{F})$ 和 $(S, \mathcal{S})$ 是可测空间。映射

$$X : \Omega \rightarrow S$$

称为从 $(\Omega, \mathcal{F})$ 到 $(S, \mathcal{S})$ 的可测映射，如果对任意 $B \in \mathcal{S}$ ，都有

$$X^{-1}(B) \in \mathcal{F}.$$

此时记作

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}).$$

也就是说，可测映射的定义可以概括为：

$$B \in \mathcal{S} \implies X^{-1}(B) \in \mathcal{F}.$$

这句话的含义是：目标空间中任何一个可测集合，经过 X 拉回之后，都必须成为源空间中的可测集合。

在概率论中，如果 X 是一个随机变量，而 B 是取值空间中的可测集合，那么事件

$$\{X \in B\}$$

就是

$$X^{-1}(B).$$

因此，可测性保证了

$$\{X \in B\} \in \mathcal{F}.$$

于是概率

$$\mathbb{P}(X \in B)$$

才是有意义的。

注. 可测映射的核心作用是保证：关于随机变量取值的条件，可以转化为样本空间中的合法事件。

■ 从原像角度理解可测性

在集合论中，映射 $X : \Omega \rightarrow S$ 有两个基本操作：像和原像。

如果 $A \subset \Omega$ ，则 A 在 X 下的像是

$$X(A) = \{X(\omega) : \omega \in A\} \subset S.$$

如果 $B \subset S$ ，则 B 在 X 下的原像是

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} \subset \Omega.$$

在概率论中，更重要的是原像而不是像。原因是概率测度首先定义在样本空间上的事件系统 $\mathcal{F}$ 上，而不是定义在取值空间 S 的所有子集上。

如果我们想讨论

$$\mathbb{P}(X \in B),$$

那么必须先把 B 通过 X 拉回到样本空间中：

$$X^{-1}(B) \subset \Omega.$$

然后才能用 $\mathbb{P}$ 去计算概率：

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)).$$

因此，可测映射就是要求这种拉回操作不会把可测集合变成不可测集合。

■ 实值随机变量

概率论中最常见的随机变量是实值随机变量。此时取值空间为实数轴 $\mathbb{R}$ ，并且实数轴上通常配备 Borel σ -代数 $\mathcal{B}(\mathbb{R})$ 。

定义：实值随机变量。 设 $(\Omega, \mathcal{F})$ 是可测空间。映射

$$X : \Omega \rightarrow \mathbb{R}$$

称为一个实值随机变量，如果

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

是可测映射。也就是说，对任意 $B \in \mathcal{B}(\mathbb{R})$ ，都有

$$X^{-1}(B) \in \mathcal{F}.$$

这说明，随机变量不是普通函数，而是可测函数。普通函数只要求每个样本点有一个取值；随机变量还要求关于其取值的 Borel 条件都能拉回成样本空间中的事件。

例如，对于任意 $t \in \mathbb{R}$ ，集合

$$(-\infty, t] \in \mathcal{B}(\mathbb{R}).$$

如果 X 是随机变量，那么

$$X^{-1}((-\infty, t]) = \{\omega \in \Omega : X(\omega) \leq t\} = \{X \leq t\}$$

必须属于 $\mathcal{F}$ 。

因此，对实值随机变量而言，事件

$$\{X \leq t\}, \quad \{X < t\}, \quad \{a < X < b\}, \quad \{X \in B\}$$

都应该属于 $\mathcal{F}$ 。

■ 实值可测函数的判别准则

根据定义，要证明 $X : \Omega \rightarrow \mathbb{R}$ 可测，需要验证对所有 Borel 集

$$B \in \mathcal{B}(\mathbb{R})$$

都有

$$X^{-1}(B) \in \mathcal{F}.$$

但是 Borel 集非常多，直接检查所有 Borel 集通常不可行。

幸运的是，Borel σ -代数可以由半直线生成：

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

因此，只需要检查这些生成集合的原像即可。

命题：实值可测函数的常用判别。 设 $(\Omega, \mathcal{F})$ 是可测空间， $X : \Omega \rightarrow \mathbb{R}$ 是函数。则以下条件等价：

X 是 $\mathcal{F}/\mathcal{B}(\mathbb{R})$ 可测的；

$$\{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}.$$

证明。 若 X 是可测的，则因为

$$(-\infty, t] \in \mathcal{B}(\mathbb{R}),$$

所以

$$\{X \leq t\} = X^{-1}((-\infty, t]) \in \mathcal{F}.$$

因此必要性成立。

下面证明充分性。假设对任意 $t \in \mathbb{R}$ ，都有

$$\{X \leq t\} \in \mathcal{F}.$$

定义

$$\mathcal{D} = \{B \subset \mathbb{R} : X^{-1}(B) \in \mathcal{F}\}.$$

我们证明 $\mathcal{D}$ 是 $\mathbb{R}$ 上的一个 σ -代数。

首先，

$$X^{-1}(\mathbb{R}) = \Omega \in \mathcal{F},$$

所以

$$\mathbb{R} \in \mathcal{D}.$$

其次，若 $B \in \mathcal{D}$ ，则

$$X^{-1}(B) \in \mathcal{F}.$$

由于原像保持补集，

$$X^{-1}(B^c) = (X^{-1}(B))^c.$$

又因为 $\mathcal{F}$ 对补集封闭，所以

$$X^{-1}(B^c) \in \mathcal{F}.$$

因此

$$B^c \in \mathcal{D}.$$

最后，若 $B_1, B_2, \dots \in \mathcal{D}$ ，则

$$X^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} X^{-1}(B_n).$$

右边属于 $\mathcal{F}$ ，因为每个 $X^{-1}(B_n) \in \mathcal{F}$ 且 $\mathcal{F}$ 对可数并封闭。因此

$$\bigcup_{n=1}^{\infty} B_n \in \mathcal{D}.$$

所以 $\mathcal{D}$ 是 σ -代数。

由假设，

$$X^{-1}((-\infty, t]) = \{X \leq t\} \in \mathcal{F},$$

因此

$$(-\infty, t] \in \mathcal{D}, \quad \forall t \in \mathbb{R}.$$

于是 $\mathcal{D}$ 包含生成类

$$\{(-\infty, t] : t \in \mathbb{R}\}.$$

因为 $\mathcal{D}$ 是 σ -代数，所以它包含由这个生成类生成的最小 σ -代数：

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\} \subset \mathcal{D}.$$

于是对任意 $B \in \mathcal{B}(\mathbb{R})$ ，都有

$$B \in \mathcal{D},$$

即

$$X^{-1}(B) \in \mathcal{F}.$$

所以 X 可测。

同理，也可以得到以下等价判别：

$$X \text{ 可测} \iff \{X < t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R},$$

$$X \text{ 可测} \iff \{X > t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R},$$

$$X \text{ 可测} \iff \{X \geq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}.$$

这些判别准则在概率论中非常重要，因为它们把复杂的 Borel 可测性问题化约为半直线事件的可测性。

■ 例子：有限样本空间

设

$$\Omega = \{1, 2, 3, 4, 5, 6\},$$

并取

$$\mathcal{F} = 2^{\Omega}.$$

令

$$X : \Omega \rightarrow \mathbb{R}$$

为任意函数。

由于 $\mathcal{F} = 2^\Omega$ 包含 Ω 的所有子集，所以对于任意 Borel 集

$$B \in \mathcal{B}(\mathbb{R}),$$

都有

$$X^{-1}(B) \subset \Omega.$$

于是

$$X^{-1}(B) \in 2^\Omega = \mathcal{F}.$$

因此 X 一定可测。

这说明，在有限样本空间并且取全体子集作为事件系统时，每个实值函数都是随机变量。

■ 例子：较粗的 σ -代数会限制可测函数

设

$$\Omega = \{1, 2, 3, 4\},$$

并取

$$\mathcal{F} = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\}.$$

这是一个 σ -代数。

定义函数 $X : \Omega \rightarrow \mathbb{R}$ 为

$$X(1) = X(2) = 0, \quad X(3) = X(4) = 1.$$

则

$$\{X = 0\} = \{1, 2\} \in \mathcal{F},$$

并且

$$\{X = 1\} = \{3, 4\} \in \mathcal{F}.$$

对于任意 Borel 集 $B \in \mathcal{B}(\mathbb{R})$ ， $X^{-1}(B)$ 只可能是下面四个集合之一：

$$\emptyset, \quad \Omega, \quad \{1, 2\}, \quad \{3, 4\}.$$

它们都属于 $\mathcal{F}$ 。因此 X 是可测的。

但是，如果定义 $Y : \Omega \rightarrow \mathbb{R}$ 为

$$Y(1) = 0, \quad Y(2) = 1, \quad Y(3) = 0, \quad Y(4) = 1,$$

则

$$\{Y = 0\} = \{1, 3\}.$$

而

$$\{1, 3\} \notin \mathcal{F}.$$

所以 Y 不是可测的。

这个例子说明，可测性并不是函数本身单独决定的，而是由源空间的 σ -代数和目标空间的 σ -代数共同决定的。

■ 可测映射的复合

可测映射最基本的稳定性性质是：可测映射的复合仍然可测。

命题：复合可测性。 设

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B})$$

是可测映射，并且

$$g : (Y, \mathcal{B}) \rightarrow (Z, \mathcal{C})$$

是可测映射。那么复合映射

$$g \circ f : X \rightarrow Z$$

也是可测映射，即

$$g \circ f : (X, \mathcal{A}) \rightarrow (Z, \mathcal{C})$$

可测。

证明。 取任意 $C \in \mathcal{C}$ 。因为 g 可测，所以

$$g^{-1}(C) \in \mathcal{B}.$$

又因为 f 可测，所以

$$f^{-1}(g^{-1}(C)) \in \mathcal{A}.$$

另一方面，由原像的复合性质，

$$(g \circ f)^{-1}(C) = f^{-1}(g^{-1}(C)).$$

因此

$$(g \circ f)^{-1}(C) \in \mathcal{A}.$$

由 $C \in \mathcal{C}$ 的任意性可知， $g \circ f$ 可测。

这条性质在概率论中非常常用。若 X 是随机变量， $g : \mathbb{R} \rightarrow \mathbb{R}$ 是 Borel 可测函数，则

$$g(X) = g \circ X$$

仍然是随机变量。

例如，如果 X 是实值随机变量，则

$$X^2, \quad |X|, \quad e^X, \quad \sin X$$

都是随机变量，因为函数

$$x \mapsto x^2, \quad x \mapsto |x|, \quad x \mapsto e^x, \quad x \mapsto \sin x$$

都是连续函数，从而是 Borel 可测函数。

■ 连续映射与 Borel 可测映射

可测性和拓扑中的连续性有密切关系。

设 S, T 是拓扑空间，分别配备 Borel σ -代数

$$\mathcal{B}(S), \quad \mathcal{B}(T).$$

若

$$f : S \rightarrow T$$

是连续映射，则对任意开集 $U \subset T$ ，都有

$$f^{-1}(U)$$

是 S 中的开集。因此

$$f^{-1}(U) \in \mathcal{B}(S).$$

由于 $\mathcal{B}(T)$ 是由 T 的开集生成的，利用生成类思想可以推出，对任意

$$B \in \mathcal{B}(T),$$

都有

$$f^{-1}(B) \in \mathcal{B}(S).$$

因此 f 是 Borel 可测映射。

命题：连续映射是 Borel 可测的。设 S, T 是拓扑空间。若

$$f : S \rightarrow T$$

连续，则

$$f : (S, \mathcal{B}(S)) \rightarrow (T, \mathcal{B}(T))$$

是可测映射。

证明。 定义

$$\mathcal{D} = \{B \subset T : f^{-1}(B) \in \mathcal{B}(S)\}.$$

与前面的证明类似， $\mathcal{D}$ 是 T 上的一个 σ -代数。

由于 f 连续，对于任意开集 $U \subset T$ ，都有

$$f^{-1}(U)$$

是 S 中的开集, 因此

$$f^{-1}(U) \in \mathcal{B}(S).$$

所以所有开集 U 都属于 $\mathcal{D}$ 。于是

$$\mathcal{B}(T) = \sigma(\text{所有开集}) \subset \mathcal{D}.$$

因此对任意 $B \in \mathcal{B}(T)$, 都有

$$f^{-1}(B) \in \mathcal{B}(S).$$

所以 f 是 Borel 可测映射。

需要注意的是, Borel 可测函数不一定连续。例如

$$f(x) = 1_{\mathbb{Q}}(x) = \begin{cases} 1, & x \in \mathbb{Q}, \\ 0, & x \notin \mathbb{Q}. \end{cases}$$

这个函数处处不连续, 但是它是 Borel 可测函数。因为

$$\mathbb{Q} \in \mathcal{B}(\mathbb{R}), \quad \mathbb{R} \setminus \mathbb{Q} \in \mathcal{B}(\mathbb{R}).$$

■ 随机向量

实值随机变量是取值于 $\mathbb{R}$ 的可测映射。更一般地, 随机向量是取值于 $\mathbb{R}^d$ 的可测映射。

定义: 随机向量. 设 $(\Omega, \mathcal{F})$ 是可测空间。映射

$$X : \Omega \rightarrow \mathbb{R}^d$$

称为一个 d 维随机向量, 如果

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$$

是可测映射。

如果写

$$X = (X_1, \dots, X_d),$$

其中每个

$$X_i : \Omega \rightarrow \mathbb{R},$$

那么有如下重要事实:

命题. 映射

$$X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d$$

是随机向量, 当且仅当每个分量 X_i 都是实值随机变量。

证明. 如果 X 是 $\mathbb{R}^d$ 值随机变量, 则坐标投影

$$\pi_i : \mathbb{R}^d \rightarrow \mathbb{R}, \quad \pi_i(x_1, \dots, x_d) = x_i$$

是连续函数，因此是 Borel 可测函数。于是

$$X_i = \pi_i \circ X$$

是可测函数。

反过来，假设每个 X_i 都是实值随机变量。要证明 X 可测，只需证明对 $\mathbb{R}^d$ 的一个生成类的原像可测。 $\mathcal{B}(\mathbb{R}^d)$ 可由开矩形生成，即

$$(a_1, b_1) \times \cdots \times (a_d, b_d).$$

对这样的开矩形，有

$$X^{-1}((a_1, b_1) \times \cdots \times (a_d, b_d)) = \bigcap_{i=1}^d \{a_i < X_i < b_i\}.$$

因为每个 X_i 可测，所以

$$\{a_i < X_i < b_i\} \in \mathcal{F}.$$

又因为 $\mathcal{F}$ 对有限交封闭，所以

$$\bigcap_{i=1}^d \{a_i < X_i < b_i\} \in \mathcal{F}.$$

因此 X 可测。

■ 由随机变量诱导的分布

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间， X 是从样本空间到可测空间 $(S, \mathcal{S})$ 的可测映射：

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}).$$

那么可以在 S 上定义一个集合函数

$$\mu_X : \mathcal{S} \rightarrow [0, 1]$$

如下：

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{S}.$$

也常写作

$$\mu_X(B) = \mathbb{P}(X \in B).$$

命题. μ_X 是 $(S, \mathcal{S})$ 上的概率测度。

证明. 首先，

$$\mu_X(S) = \mathbb{P}(X^{-1}(S)) = \mathbb{P}(\Omega) = 1.$$

其次，若 $B_1, B_2, \dots \in \mathcal{S}$ 两两不交，则

$$X^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} X^{-1}(B_n).$$

并且这些原像 $X^{-1}(B_n)$ 也两两不交。因此由 $\mathbb{P}$ 的可数可加性,

$$\begin{aligned}\mu_X \left(\bigcup_{n=1}^{\infty} B_n \right) &= \mathbb{P} \left(X^{-1} \left(\bigcup_{n=1}^{\infty} B_n \right) \right) \\ &= \mathbb{P} \left(\bigcup_{n=1}^{\infty} X^{-1}(B_n) \right) \\ &= \sum_{n=1}^{\infty} \mathbb{P}(X^{-1}(B_n)) = \sum_{n=1}^{\infty} \mu_X(B_n).\end{aligned}$$

所以 μ_X 是概率测度。

这个概率测度 μ_X 称为随机变量 X 的分布, 也称为 $\mathbb{P}$ 在 X 下的推出测度, 记作

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

这个记号的含义是: 先把 S 中的集合 B 通过 X^{-1} 拉回到 Ω , 再用 $\mathbb{P}$ 计算概率。

因此, 随机变量的分布不是凭空定义的, 而是样本空间上的概率测度通过随机变量诱导出来的。

■ 可测空间与可测映射构成范畴

从范畴论角度看, 可测空间和可测映射自然构成一个范畴, 通常记作

Meas.

在这个范畴中:

- 对象是可测空间 $(X, \mathcal{A})$;
- 态射是可测映射

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B}).$$

下面验证范畴公理。

首先, 恒等映射是可测的。对任意可测空间 $(X, \mathcal{A})$, 恒等映射

$$\text{id}_X : X \rightarrow X$$

满足

$$\text{id}_X^{-1}(A) = A, \quad A \in \mathcal{A}.$$

因此

$$\text{id}_X : (X, \mathcal{A}) \rightarrow (X, \mathcal{A})$$

是可测映射。

其次, 可测映射的复合仍然可测。若

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B})$$

和

$$g : (Y, \mathcal{B}) \rightarrow (Z, \mathcal{C})$$

都是可测映射，则前面已经证明

$$g \circ f : (X, \mathcal{A}) \rightarrow (Z, \mathcal{C})$$

可测。

最后，映射复合的结合律来自普通函数复合的结合律：

$$h \circ (g \circ f) = (h \circ g) \circ f.$$

因此，可测空间与可测映射确实构成一个范畴。

Meas = 可测空间与可测映射的范畴.

■ 与其他范畴的关系

可测空间范畴 **Meas** 可以和集合范畴 **Set**、拓扑空间范畴 **Top** 对比。

集合范畴为

Set,

其对象是集合，态射是普通映射。

拓扑空间范畴为

Top,

其对象是拓扑空间，态射是连续映射。

可测空间范畴为

Meas,

其对象是可测空间，态射是可测映射。

它们之间有一个自然的忘却函子

$$U : \mathbf{Meas} \rightarrow \mathbf{Set},$$

它把可测空间

$$(X, \mathcal{A})$$

送到其底层集合 X ，并把可测映射看成普通函数。

同时，也有一个从拓扑空间到可测空间的自然构造：

$$(X, \tau) \mapsto (X, \mathcal{B}(X)).$$

也就是说，把拓扑空间送到它的 Borel 可测空间。若

$$f : X \rightarrow Y$$

是连续映射，则

$$f : (X, \mathcal{B}(X)) \rightarrow (Y, \mathcal{B}(Y))$$

是可测映射。因此得到一个自然函子

$$\mathbf{Top} \rightarrow \mathbf{Meas}.$$

这个函子体现了前面几节的主线：

$$\text{拓扑} \implies \text{Borel } \sigma\text{-代数} \implies \text{可测空间}.$$

■ 范畴论性质简介

可测空间范畴 $\mathbf{Meas}$ 有一些重要的范畴论性质。

首先， $\mathbf{Meas}$ 是完备的，也就是说它有所有小极限。直观地说，乘积、等化子等结构都存在。

例如，一族可测空间

$$(X_i, \mathcal{A}_i)_{i \in I}$$

的乘积对象，其底层集合是集合论乘积

$$\prod_{i \in I} X_i.$$

其 σ -代数是使所有坐标投影

$$\pi_i : \prod_{j \in I} X_j \rightarrow X_i$$

都可测的最小 σ -代数，即

$$\sigma\{\pi_i^{-1}(A_i) : i \in I, A_i \in \mathcal{A}_i\}.$$

这正是概率论中的乘积 σ -代数。

其次， $\mathbf{Meas}$ 也是余完备的，也就是说它有所有小余极限。余积由无交并给出。若有一族可测空间

$$(X_i, \mathcal{A}_i)_{i \in I},$$

其余积的底层集合为

$$\bigsqcup_{i \in I} X_i.$$

一个集合 $B \subset \bigsqcup_{i \in I} X_i$ 可测，当且仅当它在每个分量上的截面都可测：

$$B \cap X_i \in \mathcal{A}_i, \quad \forall i \in I.$$

不过， $\mathbf{Meas}$ 并不像 $\mathbf{Set}$ 那样具有很好的函数空间对象。一般来说， $\mathbf{Meas}$ 不是笛卡尔闭范畴。也就是说，对一般的可测空间 X, Y ，未必存在一个合适的可测空间 Y^X ，使得自然同构

$$\mathbf{Meas}(Z \times X, Y) \cong \mathbf{Meas}(Z, Y^X)$$

对所有 Z 成立。

这说明，在普通可测空间范畴中处理“随机函数”或“高阶函数”时会遇到技术困难。这也是现代概率论和概率程序语义中常常需要引入更精细结构的原因之一。

■ 本节小结

本节的核心内容可以总结如下。

首先，一个可测空间是

$$(\Omega, \mathcal{F}),$$

其中 $\mathcal{F}$ 是 Ω 上的 σ -代数。它指定了哪些子集是可测集合，也就是概率论中的合法事件。

其次，一个映射

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$$

是可测映射，当且仅当对任意

$$B \in \mathcal{S},$$

都有

$$X^{-1}(B) \in \mathcal{F}.$$

这说明可测映射的本质是：目标空间的可测集合可以被拉回成源空间中的可测集合。

再次，实值随机变量就是可测映射

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

判断实值随机变量可测时，常用准则是

$$\{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}.$$

然后，可测映射的复合仍然可测，连续映射一定是 Borel 可测映射。因此，如果 X 是随机变量， f 是 Borel 可测函数，那么 $f(X)$ 仍然是随机变量。

最后，随机变量会诱导取值空间上的概率测度：

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)).$$

这个测度称为 X 的分布，记作

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

从范畴论角度看，可测空间与可测映射构成范畴

Meas.

随机变量正是这个范畴中的一个态射。

核心思想：可测性保证：关于随机变量的取值条件，确实对应样本空间中的事件。

■ 练习

1. 设 $(\Omega, \mathcal{F})$ 是可测空间，证明恒等映射

$$\text{id}_\Omega : (\Omega, \mathcal{F}) \rightarrow (\Omega, \mathcal{F})$$

是可测映射。

2. 设

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B}), \quad g : (Y, \mathcal{B}) \rightarrow (Z, \mathcal{C})$$

都是可测映射。证明 $g \circ f$ 可测。

3. 设 $\Omega = \{1, 2, 3, 4\}$,

$$\mathcal{F} = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\}.$$

判断函数

$$X(1) = 0, \quad X(2) = 0, \quad X(3) = 1, \quad X(4) = 1$$

是否可测。

4. 在上一题的可测空间上，判断函数

$$Y(1) = 0, \quad Y(2) = 1, \quad Y(3) = 0, \quad Y(4) = 1$$

是否可测。

5. 设 $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ 。证明若

$$\{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R},$$

则 X 是实值随机变量。

6. 设 X, Y 是实值随机变量。证明

$$\{X < Y\} \in \mathcal{F}.$$

提示：使用有理数的稠密性，将事件写成可数并。

7. 设 X 是实值随机变量，证明

$$|X|, \quad X^2, \quad e^X$$

都是实值随机变量。

8. 设 $X = (X_1, \dots, X_d)$ 。证明 X 是 $\mathbb{R}^d$ 值随机变量，当且仅当每个分量 X_i 都是实值随机变量。

9. 设 $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{S})$ 是随机元素。定义

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{S}.$$

证明 μ_X 是 $(S, \mathcal{S})$ 上的概率测度。

10. 证明可测空间与可测映射构成一个范畴 **Meas**。

1.6 Polish 空间与标准 Borel 空间

前面几节中，我们已经从集合、映射、拓扑、Borel σ -代数一路走到了可测空间与可测映射。现在我们已经知道，如果一个随机变量取值于拓扑空间 S ，那么通常会把 S 配备上它的 Borel σ -代数：

$$\mathcal{B}(S) = \sigma(\text{所有开集}).$$

于是随机变量可以写成

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S)).$$

但是，现代概率论中取值空间 S 不一定只是 $\mathbb{R}$ 或 $\mathbb{R}^d$ 。它也可能是函数空间、路径空间、概率测度空间，甚至更加抽象的空间。例如：

$$X : \Omega \rightarrow C[0, 1],$$

表示一个随机连续函数；

$$X : \Omega \rightarrow D[0, 1],$$

表示一个带跳跃路径的随机过程；

$$X : \Omega \rightarrow \mathcal{P}(S),$$

表示一个随机概率测度。

因此，我们需要知道：哪些拓扑空间足够好，能够作为概率论中的取值空间？哪些可测空间足够规整，能够支持分布、条件概率、概率核和随机过程构造？

这一节要介绍的两个核心概念就是：

Polish 空间

和

标准 Borel 空间。

它们之间的关系可以概括为：

$$\text{Polish 空间} \implies \text{Borel 化} \implies \text{标准 Borel 空间}.$$

■ Polish 空间

定义. 设 S 是一个拓扑空间。如果存在一个度量 d , 使得:

d 诱导出的拓扑正好是 S 原来的拓扑,

并且度量空间 (S, d) 是可分且完备的, 那么称 S 是一个 Polish 空间。

也就是说, Polish 空间是可以被某个完备可分度量描述的拓扑空间。

这里有三个关键词。

第一, S 是可度量化。这表示 S 的拓扑可以由某个距离函数 d 描述。换句话说, 开集、收敛、连续等概念都可以通过距离来刻画。

第二, S 是完备的。这表示在合适的度量下, S 中的每一个 Cauchy 序列都收敛到 S 中的某个点。直观地说, 极限不会逃出空间。

第三, S 是可分的。这表示 S 中存在一个可数稠密子集。也就是说, 虽然 S 本身可能非常大, 但它可以由可数个点逼近。

因此, Polish 空间可以直观理解为:

既有良好的极限结构, 又可以被可数对象控制的拓扑空间。

这种性质在概率论中非常重要。完备性保证极限过程比较稳定, 可分性则允许我们把很多不可数问题化约为可数问题。

■ 基本例子

最重要的例子是实数轴。令

$$S = \mathbb{R},$$

并取通常距离

$$d(x, y) = |x - y|.$$

则 $(\mathbb{R}, d)$ 是完备的, 而且 $\mathbb{Q}$ 是 $\mathbb{R}$ 中的可数稠密子集。因此 $\mathbb{R}$ 是 Polish 空间。

更一般地,

$$\mathbb{R}^d$$

在欧氏距离

$$d(x, y) = |x - y|_2$$

下也是 Polish 空间。它是完备的, 并且 $\mathbb{Q}^d$ 是可数稠密子集。

另一个重要例子是连续函数空间

$$C[0, 1].$$

在 $C[0, 1]$ 上定义距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

这个距离对应一致收敛拓扑。可以证明, $(C[0, 1], d)$ 是完备可分的。因此 $C[0, 1]$ 是 Polish 空间。

这个例子在概率论中非常重要。Brownian motion 可以看作取值于 $C[0, 1]$ 的随机元素:

$$B : \Omega \rightarrow C[0, 1].$$

也就是说, 对每一个样本点 ω , 我们得到一条连续路径

$$t \mapsto B_t(\omega).$$

可数离散空间也是 Polish 空间。例如 $\mathbb{N}$ 上定义离散距离:

$$d(m, n) = \begin{cases} 0, & m = n, \\ 1, & m \neq n. \end{cases}$$

在这个距离下, $\mathbb{N}$ 是完备的, 并且它本身就是可数稠密子集。因此 $\mathbb{N}$ 是 Polish 空间。

■ 一个需要注意的例子

开区间 $(0, 1)$ 在通常距离下不是完备的。因为序列

$$x_n = \frac{1}{n}$$

是 $(0, 1)$ 中的 Cauchy 序列, 但它在 $\mathbb{R}$ 中的极限是 0, 而

$$0 \notin (0, 1).$$

所以 $(0, 1)$ 在通常距离下不是完备度量空间。

但是, $(0, 1)$ 仍然是 Polish 空间。

原因是 Polish 空间并不要求当前给出的度量一定完备, 而是要求存在某个诱导相同拓扑的完备度量。

事实上, $(0, 1)$ 与 $\mathbb{R}$ 同胚。例如映射

$$\varphi : (0, 1) \rightarrow \mathbb{R}, \quad \varphi(x) = \log \frac{x}{1-x}$$

是一个同胚。因此 $(0, 1)$ 可以从 $\mathbb{R}$ 上搬运一个完备可分的拓扑结构, 所以它是 Polish 空间。

这个例子说明:

Polish 性质是拓扑性质, 而不是某一个具体度量的性质。

■ 非例子

有理数集 $\mathbb{Q}$ 带通常拓扑不是 Polish 空间。

虽然 $\mathbb{Q}$ 是可分的，但它不能被赋予一个诱导通常拓扑的完备度量。直观地说， $\mathbb{Q}$ 中有很多序列会逼近无理数。例如可以取一系列有理数 (q_n) ，使得

$$q_n \rightarrow \sqrt{2}.$$

这列数在 $\mathbb{Q}$ 中表现得像一个 Cauchy 序列，但极限 $\sqrt{2}$ 不属于 $\mathbb{Q}$ 。

更深层地说， $\mathbb{Q}$ 的通常拓扑太稀疏，不能成为一个完备可分度量空间的拓扑。

因此，

$$\mathbb{Q}$$

带通常拓扑不是 Polish 空间。

■ 从拓扑空间到可测空间：Borel 化

只要 S 是拓扑空间，它就有开集族。记 S 的拓扑为 τ 。由这些开集可以生成 Borel σ -代数：

$$\mathcal{B}(S) = \sigma(\tau).$$

于是我们可以把拓扑空间

$$(S, \tau)$$

变成可测空间

$$(S, \mathcal{B}(S)).$$

这个过程可以称为 Borel 化。也就是说：

$$\text{拓扑空间} \implies \text{Borel 可测空间}.$$

特别地，如果 S 是 Polish 空间，那么它天然就是拓扑空间，所以可以自然得到

$$(S, \mathcal{B}(S)).$$

这就是概率论中常见的取值空间结构。

例如：

$$\mathbb{R} \rightsquigarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})),$$

$$\mathbb{R}^d \rightsquigarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)),$$

$$C[0, 1] \rightsquigarrow (C[0, 1], \mathcal{B}(C[0, 1])).$$

Borel 化以后，我们暂时忘掉一部分拓扑信息，只保留由拓扑生成出来的可测结构。

■ 标准 Borel 空间

现在我们定义标准 Borel 空间。

定义. 一个可测空间 $(S, \mathcal{S})$ 称为标准 Borel 空间, 如果它与某个 Polish 空间的 Borel 可测空间可测同构。

也就是说, 存在一个 Polish 空间 E , 使得

$$(S, \mathcal{S})$$

与

$$(E, \mathcal{B}(E))$$

之间存在一个双射

$$f : S \rightarrow E,$$

并且 f 和 f^{-1} 都是可测映射。

这样的 f 称为 Borel 同构。

更一般地, 也可以说 $(S, \mathcal{S})$ 是标准 Borel 空间, 如果它可测同构于某个 Polish 空间的 Borel 子集。即存在 Polish 空间 E 和 Borel 集 $A \in \mathcal{B}(E)$, 使得

$$(S, \mathcal{S})$$

与

$$(A, \mathcal{B}(E)|_A)$$

可测同构。其中

$$\mathcal{B}(E)|_A = \{A \cap B : B \in \mathcal{B}(E)\}.$$

直观地说, 标准 Borel 空间就是来自 Polish 空间的可测空间。它只关心可测结构, 而不直接关心距离、开集和收敛。

因此可以把标准 Borel 空间理解为:

Polish 空间经过 Borel 化以后得到的可测空间,

或者与这样的可测空间可测同构的空间。

■ Polish 空间与标准 Borel 空间的关系

如果 S 是 Polish 空间, 那么

$$(S, \mathcal{B}(S))$$

一定是标准 Borel 空间。

这是因为标准 Borel 空间的定义正是要求它与某个 Polish 空间的 Borel 可测空间可测同构。取这个 Polish 空间就是 S 本身, 恒等映射

$$\text{id}_S : S \rightarrow S$$

就是一个 Borel 同构。

因此有：

核心关系：

S 是 Polish 空间 $\implies (S, \mathcal{B}(S))$ 是标准 Borel 空间.

但反过来需要小心。标准 Borel 空间是可测空间概念，而 Polish 空间是拓扑空间概念。标准 Borel 空间只保留了可测结构，不保留完整的拓扑结构。

例如， $\mathbb{Q}$ 带通常拓扑不是 Polish 空间，但是

$$(\mathbb{Q}, \mathcal{B}(\mathbb{Q}))$$

是标准 Borel 空间。因为 $\mathbb{Q}$ 是 $\mathbb{R}$ 的可数子集，所以 $\mathbb{Q} \in \mathcal{B}(\mathbb{R})$ 。于是 $\mathbb{Q}$ 作为 $\mathbb{R}$ 的 Borel 子集，带上子空间 Borel 结构，就是标准 Borel 空间。

这说明：

不是 Polish 空间的拓扑空间，仍然可能给出标准 Borel 空间。

■ 拓扑结构与可测结构的区别

Polish 空间关心的是拓扑结构。它研究：

开集、闭集、收敛、连续、紧性、完备性、可分性。

标准 Borel 空间关心的是可测结构。它研究：

哪些集合可测，哪些映射可测。

所以从 Polish 空间到标准 Borel 空间的过程可以理解为：

$$(S, \tau) \longmapsto (S, \mathcal{B}(S)).$$

左边是拓扑空间，右边是可测空间。

在这个过程中，我们保留了由开集生成的 Borel 集，但不再直接记录哪些集合是开集。

因此，两个不同的 Polish 拓扑可能生成同一个 Borel σ -代数。对于标准 Borel 空间来说，它们可能是同一个可测空间；但对于 Polish 空间来说，它们可能是不同的拓扑空间。

■ 为什么概率论需要标准 Borel 空间

在初等概率论中，我们通常只关心实值随机变量：

$$X : \Omega \rightarrow \mathbb{R}.$$

这时取值空间是

$$(\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

在多维情形中，我们考虑随机向量：

$$X : \Omega \rightarrow \mathbb{R}^d,$$

取值空间是

$$(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)).$$

在随机过程理论中，我们会考虑随机路径：

$$X : \Omega \rightarrow C[0, 1],$$

取值空间是

$$(C[0, 1], \mathcal{B}(C[0, 1])).$$

这些空间都是标准 Borel 空间。

标准 Borel 空间的重要性在于，它们足够一般，可以包含绝大多数概率论中自然出现的取值空间；同时它们又足够规整，使许多关键定理能够成立。

例如，在标准 Borel 空间上，我们可以比较安全地讨论：

随机元素的分布，

概率核，

正则条件分布，

Markov 过程，

可测选择。

如果只在任意可测空间上工作，很多结论可能失败。普通可测空间可能过于病态，而标准 Borel 空间避免了许多这类问题。

因此，在现代概率论中，常常默认随机对象的取值空间是标准 Borel 空间，或者至少是由 Polish 空间 Borel 化得到的可测空间。

■ 随机元素的语言

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间， $(S, \mathcal{S})$ 是可测空间。如果

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$$

是可测映射，则称 X 是取值于 S 的随机元素。

当

$$(S, \mathcal{S}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

时, X 就是实值随机变量。

当

$$(S, \mathcal{S}) = (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$$

时, X 是随机向量。

当

$$(S, \mathcal{S}) = (C[0, 1], \mathcal{B}(C[0, 1]))$$

时, X 是随机连续函数。

统一地说, 如果 S 是 Polish 空间, 我们通常把随机元素写成

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S)).$$

这说明 Polish 空间通过 Borel 化提供了现代概率论中随机对象的标准取值空间。

■ 分布

若

$$X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{S})$$

是随机元素, 则它诱导出 S 上的概率测度

$$\mu_X(B) = \mathbb{P}(X \in B), \quad B \in \mathcal{S}.$$

更严格地写为

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)).$$

这个测度 μ_X 称为 X 的分布, 也记作

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

当 $(S, \mathcal{S})$ 是标准 Borel 空间时, μ_X 是定义在一个非常规整的可测空间上的概率测度。因此许多后续理论可以顺利展开。

■ 本节小结

本节介绍了 Polish 空间与标准 Borel 空间。

首先, Polish 空间是可以由完备可分度量描述的拓扑空间。它同时具有良好的极限结构和可数逼近结构。

其次, 只要 S 是拓扑空间, 就可以由开集生成 Borel σ -代数:

$$\mathcal{B}(S) = \sigma(\text{开集}).$$

因此拓扑空间可以 Borel 化为可测空间:

$$(S, \tau) \mapsto (S, \mathcal{B}(S)).$$

再次，标准 Borel 空间是与某个 Polish 空间的 Borel 可测空间可测同构的可测空间。特别地，如果 S 是 Polish 空间，那么

$$(S, \mathcal{B}(S))$$

一定是标准 Borel 空间。

最后，标准 Borel 空间是现代概率论中最重要的一类取值空间。它们既足够一般，可以包含 $\mathbb{R}^d$ 、函数空间和路径空间；又足够规整，可以支持分布、条件概率、概率核和随机过程等理论。

本节的核心逻辑是：

Polish 空间 $\implies$ Borel 化 $\implies$ 标准 Borel 空间 $\implies$ 现代概率论中的良好取值空间。

■ 练习

1. 证明 $\mathbb{R}$ 在通常距离下是 Polish 空间。
2. 证明 $\mathbb{R}^d$ 在欧氏距离下是 Polish 空间。
3. 设 S 是可数集合，并赋予离散拓扑。证明 S 是 Polish 空间。
4. 解释为什么 $(0, 1)$ 在通常距离下不是完备的，但作为拓扑空间仍然是 Polish 空间。
5. 说明为什么 $\mathbb{Q}$ 带通常拓扑不是 Polish 空间。
6. 证明如果 S 是 Polish 空间，则 $(S, \mathcal{B}(S))$ 是标准 Borel 空间。
7. 说明为什么 $(\mathbb{Q}, \mathcal{B}(\mathbb{Q}))$ 是标准 Borel 空间。
8. 设 $X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B}(S))$ 是随机元素，其中 S 是 Polish 空间。解释为什么对每个 $B \in \mathcal{B}(S)$ ，事件 $\{X \in B\}$ 都属于 $\mathcal{F}$ 。
9. 设 $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{S})$ 是随机元素。定义

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{S}.$$

证明 μ_X 是 $(S, \mathcal{S})$ 上的概率测度。

10. 用一句话解释 Polish 空间和标准 Borel 空间的差别。

1.7 乘积空间与乘积 σ -代数

前面几节中，我们已经建立了可测空间与可测映射的语言。一个随机变量不只是普通函数，而是一个可测映射

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}).$$

如果有两个随机对象

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T}),$$

那么我们自然希望把它们合并成一个联合随机对象

$$(X, Y) : \Omega \rightarrow S \times T.$$

于是本节的核心问题是：

要点：如果两个空间各自有可测结构，那么它们的乘积空间上应该配备什么样的 σ -代数？

答案就是乘积 σ -代数。它既是概率论中联合随机变量的自然可测结构，也正是可测空间范畴 **Meas** 中的积对象结构。

■ 乘积空间

设 S 和 T 是两个集合。它们的乘积空间定义为

$$S \times T = \{(s, t) : s \in S, t \in T\}.$$

乘积空间中的元素是有序对。比如

$$\mathbb{R}^2 = \mathbb{R} \times \mathbb{R}.$$

如果

$$S = \{H, T\}, \quad T = \{1, 2, 3, 4, 5, 6\},$$

那么 $S \times T$ 可以表示“先抛硬币，再掷骰子”的所有可能结果。

在乘积空间 $S \times T$ 中，最基本的集合是矩形集合。若

$$A \subset S, \quad B \subset T,$$

则

$$A \times B = \{(s, t) : s \in A, t \in B\}$$

称为一个矩形。

在概率论中，矩形集合对应联合事件。若

$$X : \Omega \rightarrow S, \quad Y : \Omega \rightarrow T,$$

则

$$\{(X, Y) \in A \times B\} = \{X \in A\} \cap \{Y \in B\}.$$

这说明矩形集合是理解联合随机对象的第一块积木。

■ 乘积 σ -代数的定义

设

$$(S, \mathcal{S}), \quad (T, \mathcal{T})$$

是两个可测空间。我们希望在 $S \times T$ 上定义一个自然的 σ -代数，使所有可测矩形

$$A \times B, \quad A \in \mathcal{S}, B \in \mathcal{T}$$

都是可测的。

定义. 由所有可测矩形生成的 σ -代数称为 $\mathcal{S}$ 与 $\mathcal{T}$ 的乘积 σ -代数，记作

$$\mathcal{S} \otimes \mathcal{T}.$$

也就是说，

$$\mathcal{S} \otimes \mathcal{T} = \sigma(\{A \times B : A \in \mathcal{S}, B \in \mathcal{T}\}).$$

于是

$$(S \times T, \mathcal{S} \otimes \mathcal{T})$$

称为两个可测空间的乘积可测空间。

需要注意，矩形类本身一般不是 σ -代数。例如在 $\mathbb{R}^2$ 中，

$$(0, 1) \times (0, 1)$$

和

$$(2, 3) \times (2, 3)$$

都是矩形，但它们的并

$$(0, 1) \times (0, 1) \cup (2, 3) \times (2, 3)$$

通常不是一个矩形。因此我们不能只取矩形类，而必须取由矩形类生成的最小 σ -代数。

■ 投影映射与柱形集合

在乘积空间 $S \times T$ 上有两个自然的投影映射：

$$\pi_S : S \times T \rightarrow S, \quad \pi_S(s, t) = s,$$

以及

$$\pi_T : S \times T \rightarrow T, \quad \pi_T(s, t) = t.$$

对于 $A \in \mathcal{S}$ ，有

$$\pi_S^{-1}(A) = A \times T.$$

对于 $B \in \mathcal{T}$ ，有

$$\pi_T^{-1}(B) = S \times B.$$

这些集合称为柱形集合。柱形集合只限制某一个坐标，而不限制另一个坐标。

乘积 σ -代数也可以由投影映射来刻画：

$$\mathcal{S} \otimes \mathcal{T} = \sigma(\{\pi_S^{-1}(A) : A \in \mathcal{S}\} \cup \{\pi_T^{-1}(B) : B \in \mathcal{T}\}).$$

这是因为

$$A \times B = (A \times T) \cap (S \times B) = \pi_S^{-1}(A) \cap \pi_T^{-1}(B).$$

所以由柱形集合生成的 σ -代数包含所有矩形。反过来，

$$A \times T, \quad S \times B$$

本身也是矩形，因此它们也属于由矩形生成的 σ -代数。

因此，乘积 σ -代数可以理解为：

要点：使两个坐标投影映射都可测的最小 σ -代数。

■ 可测空间范畴中的积对象

可测空间与可测映射构成一个范畴，记作 **Meas**。其中对象是可测空间，态射是可测映射。

在这个范畴中，两个可测空间

$$(S, \mathcal{S}), \quad (T, \mathcal{T})$$

的积对象正是

$$(S \times T, \mathcal{S} \otimes \mathcal{T}),$$

连同两个投影态射

$$\pi_S : (S \times T, \mathcal{S} \otimes \mathcal{T}) \rightarrow (S, \mathcal{S}),$$

$$\pi_T : (S \times T, \mathcal{S} \otimes \mathcal{T}) \rightarrow (T, \mathcal{T}).$$

它满足如下泛性质。对任意可测空间 $(\Omega, \mathcal{F})$ ，如果有两个可测映射

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T}),$$

则存在唯一的可测映射

$$\langle X, Y \rangle : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

使得

$$\pi_S \circ \langle X, Y \rangle = X, \quad \pi_T \circ \langle X, Y \rangle = Y.$$

这个唯一映射就是

$$\langle X, Y \rangle(\omega) = (X(\omega), Y(\omega)).$$

换句话说，有自然双射

$$\mathbf{Meas}((\Omega, \mathcal{F}), (S \times T, \mathcal{S} \otimes \mathcal{T})) \cong \mathbf{Meas}((\Omega, \mathcal{F}), (S, \mathcal{S})) \times \mathbf{Meas}((\Omega, \mathcal{F}), (T, \mathcal{T})).$$

左边的一个态射 $Z : \Omega \rightarrow S \times T$ 被送到

$$(\pi_S \circ Z, \pi_T \circ Z),$$

右边的一对态射 (X, Y) 被送到

$$\langle X, Y \rangle.$$

这说明：

要点：联合随机元素本质上就是 **Meas** 中积对象的泛性质给出的唯一态射。

■ 联合随机元素的可测性

设

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T})$$

都是可测映射。定义

$$Z = (X, Y) : \Omega \rightarrow S \times T, \quad Z(\omega) = (X(\omega), Y(\omega)).$$

则

$$Z : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

是可测映射。

证明如下。对任意可测矩形 $A \times B$ ，其中 $A \in \mathcal{S}$ ， $B \in \mathcal{T}$ ，有

$$Z^{-1}(A \times B) = \{\omega : (X(\omega), Y(\omega)) \in A \times B\}.$$

这等价于

$$X(\omega) \in A, \quad Y(\omega) \in B.$$

因此

$$Z^{-1}(A \times B) = X^{-1}(A) \cap Y^{-1}(B).$$

由于 X 与 Y 可测，

$$X^{-1}(A) \in \mathcal{F}, \quad Y^{-1}(B) \in \mathcal{F}.$$

又因为 $\mathcal{F}$ 对有限交封闭，所以

$$X^{-1}(A) \cap Y^{-1}(B) \in \mathcal{F}.$$

因此所有可测矩形的原像都是可测的。由生成类思想可知，整个 $\mathcal{S} \otimes \mathcal{T}$ 中所有集合的原像也都是可测的。于是 $Z = (X, Y)$ 可测。

反过来，如果

$$Z = (X, Y) : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

可测, 那么

$$X = \pi_S \circ Z, \quad Y = \pi_T \circ Z.$$

由于投影映射 π_S 和 π_T 可测, 而可测映射的复合仍然可测, 所以 X 和 Y 都可测。

因此得到重要结论:

核心结论:

$$(X, Y) \text{ 可测} \iff X, Y \text{ 分别可测}.$$

■ $\mathbb{R}^d$ 上的 Borel σ -代数

最重要的例子是欧氏空间。我们知道

$$\mathbb{R}^d = \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{d \text{ 次}}.$$

在每个坐标上都有 Borel σ -代数 $\mathcal{B}(\mathbb{R})$ 。于是可以构造乘积 σ -代数

$$\mathcal{B}(\mathbb{R})^{\otimes d} = \underbrace{\mathcal{B}(\mathbb{R}) \otimes \cdots \otimes \mathcal{B}(\mathbb{R})}_{d \text{ 次}}.$$

一个基本事实是

基本事实:

$$\mathcal{B}(\mathbb{R}^d) = \mathcal{B}(\mathbb{R})^{\otimes d}.$$

证明思路如下。首先, 任意开矩形

$$(a_1, b_1) \times \cdots \times (a_d, b_d)$$

都是 $\mathbb{R}^d$ 中的开集, 因此属于 $\mathcal{B}(\mathbb{R}^d)$ 。这些开矩形也属于 $\mathcal{B}(\mathbb{R})^{\otimes d}$ 。另一方面, $\mathbb{R}^d$ 中的任意开集都可以写成可数个有理端点开矩形的并, 而这些有理端点开矩形属于乘积 σ -代数。因此所有开集都属于 $\mathcal{B}(\mathbb{R})^{\otimes d}$ 。所以

$$\mathcal{B}(\mathbb{R}^d) \subset \mathcal{B}(\mathbb{R})^{\otimes d}.$$

反过来, 坐标投影

$$\pi_i : \mathbb{R}^d \rightarrow \mathbb{R}, \quad \pi_i(x_1, \dots, x_d) = x_i$$

是连续映射, 因此是 Borel 可测映射。于是每个柱形集合

$$\pi_i^{-1}(A), \quad A \in \mathcal{B}(\mathbb{R}),$$

都属于 $\mathcal{B}(\mathbb{R}^d)$ 。由这些柱形集合生成的乘积 σ -代数也包含在 $\mathcal{B}(\mathbb{R}^d)$ 中。因此

$$\mathcal{B}(\mathbb{R})^{\otimes d} \subset \mathcal{B}(\mathbb{R}^d).$$

两边合起来得到结论。

于是, 若

$$X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d,$$

则 X 是 $\mathbb{R}^d$ 值随机向量, 当且仅当每个坐标函数 X_i 都是实值随机变量。

■ 由生成类生成乘积 σ -代数

在实际证明中, 我们常常不想直接处理整个 $\mathcal{S}$ 与 $\mathcal{T}$, 而是希望从较小的生成类出发。

设

$$\mathcal{S} = \sigma(\mathcal{C}), \quad \mathcal{T} = \sigma(\mathcal{D}),$$

其中 $\mathcal{C} \subset 2^S$, $\mathcal{D} \subset 2^T$ 。在适当条件下, 可以用

$$C \times D, \quad C \in \mathcal{C}, D \in \mathcal{D}$$

来生成乘积 σ -代数。

例如, 在实数轴上,

$$\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, t] : t \in \mathbb{R}\}.$$

因此

$$\mathcal{B}(\mathbb{R}^2) = \sigma\{(-\infty, s] \times (-\infty, t] : s, t \in \mathbb{R}\}.$$

这个事实在分布函数和联合分布中非常重要。若 (X, Y) 是二维随机向量, 那么它的联合分布由二维分布函数

$$F_{X,Y}(s, t) = \mathbb{P}(X \leq s, Y \leq t)$$

决定。因为集合

$$(-\infty, s] \times (-\infty, t]$$

构成了 $\mathbb{R}^2$ 上 Borel σ -代数的一个生成类。

■ 有限乘积与一般乘积

对于有限多个可测空间

$$(S_1, \mathcal{S}_1), \dots, (S_n, \mathcal{S}_n),$$

它们的乘积可测空间定义为

$$\left(\prod_{i=1}^n S_i, \bigotimes_{i=1}^n \mathcal{S}_i \right),$$

其中

$$\bigotimes_{i=1}^n \mathcal{S}_i = \sigma\{A_1 \times \dots \times A_n : A_i \in \mathcal{S}_i, i = 1, \dots, n\}.$$

如果有一族可测空间

$$(S_i, \mathcal{S}_i)_{i \in I},$$

则它们的乘积空间是

$$\prod_{i \in I} S_i.$$

对每个 $i \in I$, 有坐标投影

$$\pi_i : \prod_{j \in I} S_j \rightarrow S_i.$$

定义乘积 σ -代数为

$$\bigotimes_{i \in I} \mathcal{S}_i = \sigma\{\pi_i^{-1}(A) : i \in I, A \in \mathcal{S}_i\}.$$

也就是说, 它是使所有坐标投影 π_i 都可测的最小 σ -代数。

当 I 是无穷指标集时, 这个定义尤其重要。随机过程可以看作取值于无穷乘积空间的随机元素。例如, 若

$$X_t : \Omega \rightarrow S, \quad t \in T,$$

是一族随机变量, 则可以把整个过程写成

$$X : \Omega \rightarrow S^T, \quad X(\omega) = (X_t(\omega))_{t \in T}.$$

此时 S^T 上的自然可测结构就是由所有坐标投影生成的乘积 σ -代数。

■ 联合分布、边缘分布与独立性

设 $(\Omega, \mathcal{F}, P)$ 是概率空间, 并且

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T})$$

是随机元素。联合随机元素

$$(X, Y) : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

诱导出 $S \times T$ 上的概率测度

$$\mu_{(X,Y)}(C) = \mathbb{P}((X, Y) \in C), \quad C \in \mathcal{S} \otimes \mathcal{T}.$$

这个测度称为 X 与 Y 的联合分布。

特别地, 对可测矩形 $A \times B$, 有

$$\mu_{(X,Y)}(A \times B) = \mathbb{P}(X \in A, Y \in B).$$

同时, X 和 Y 各自诱导边缘分布

$$\mu_X(A) = \mathbb{P}(X \in A), \quad A \in \mathcal{S},$$

$$\mu_Y(B) = \mathbb{P}(Y \in B), \quad B \in \mathcal{T}.$$

需要区分两个层次：乘积 σ -代数是可测空间层面的结构，而乘积测度是额外的测度结构。一般情况下，联合分布不一定等于边缘分布的乘积测度：

$$\mu_{(X,Y)} \neq \mu_X \otimes \mu_Y.$$

只有当 X 与 Y 独立时，才有

$$\mu_{(X,Y)} = \mu_X \otimes \mu_Y.$$

在矩形集合上，这等价于

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B), \quad A \in \mathcal{S}, B \in \mathcal{T}.$$

因此，独立性可以理解为：

要点：联合分布等于边缘分布的乘积。

■ 本节小结

本节介绍了乘积空间与乘积 σ -代数。

首先，若 $(S, \mathcal{S})$ 和 $(T, \mathcal{T})$ 是可测空间，则它们的乘积可测空间为

$$(S \times T, \mathcal{S} \otimes \mathcal{T}),$$

其中

$$\mathcal{S} \otimes \mathcal{T} = \sigma\{A \times B : A \in \mathcal{S}, B \in \mathcal{T}\}.$$

其次，乘积 σ -代数也可以看成使投影映射

$$\pi_S : S \times T \rightarrow S, \quad \pi_T : S \times T \rightarrow T$$

都可测的最小 σ -代数。

再次，从范畴论角度看，

$$(S \times T, \mathcal{S} \otimes \mathcal{T})$$

正是 **Meas** 中的积对象。它满足泛性质：任意两个可测映射

$$X : \Omega \rightarrow S, \quad Y : \Omega \rightarrow T$$

可以唯一地合并成一个可测映射

$$\langle X, Y \rangle : \Omega \rightarrow S \times T.$$

然后，对随机变量而言，

$$(X, Y) \text{ 可测} \iff X, Y \text{ 分别可测}.$$

最后, 乘积 σ -代数 为联合分布提供了可测空间结构。若 X 与 Y 独立, 则联合分布等于边缘分布的乘积测度:

$$\mu_{(X,Y)} = \mu_X \otimes \mu_Y.$$

本节的核心逻辑是:

$$\begin{aligned} \text{多个可测对象} &\implies \text{乘积空间} \\ &\implies \text{乘积}\sigma\text{-代数} \\ &\implies \text{联合随机元素与联合分布.} \end{aligned}$$

■ 练习

1. 设 $(S, \mathcal{S})$ 和 $(T, \mathcal{T})$ 是可测空间。证明

$$\mathcal{S} \otimes \mathcal{T} = \sigma\left(\left\{\pi_S^{-1}(A) : A \in \mathcal{S}\right\} \cup \left\{\pi_T^{-1}(B) : B \in \mathcal{T}\right\}\right).$$

2. 证明投影映射

$$\pi_S : (S \times T, \mathcal{S} \otimes \mathcal{T}) \rightarrow (S, \mathcal{S}), \quad \pi_T : (S \times T, \mathcal{S} \otimes \mathcal{T}) \rightarrow (T, \mathcal{T})$$

都是可测映射。

3. 设

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T})$$

都是可测映射。证明

$$(X, Y) : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

是可测映射。

4. 反过来, 设

$$Z = (X, Y) : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T})$$

是可测映射。证明 X 与 Y 都是可测映射。

5. 证明

$$\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}).$$

6. 设 X, Y 是实值随机变量。证明 (X, Y) 是 $\mathbb{R}^2$ 值随机变量。

7. 设 (X, Y) 是二维随机向量。证明事件

$$\{X < Y\}$$

属于 $\mathcal{F}$ 。

8. 设 X, Y 是随机元素，联合分布为 $\mu_{(X,Y)}$ 。证明它的边缘分布满足

$$\mu_X(A) = \mu_{(X,Y)}(A \times T), \quad A \in \mathcal{S},$$

$$\mu_Y(B) = \mu_{(X,Y)}(S \times B), \quad B \in \mathcal{T}.$$

9. 设 X, Y 独立。证明对所有 $A \in \mathcal{S}$, $B \in \mathcal{T}$, 有

$$\mu_{(X,Y)}(A \times B) = \mu_X(A)\mu_Y(B).$$

10. 用一句话解释：乘积 σ -代数和乘积测度的区别是什么？

1.8 函数空间的可测结构

前面我们已经看到，随机变量不一定只取实数值。一个随机对象可以取值于

$$\mathbb{R}^d, \quad C[0, 1], \quad D[0, 1],$$

甚至更一般的函数空间。

本节的目标是解释：当随机对象的取值本身是一条函数或一条路径时，我们应该在函数空间上放什么样的可测结构。

这一问题在随机过程理论中非常重要。一个随机过程通常写成

$$\{X_t : t \in T\}.$$

这里每个 X_t 是一个随机变量。但是我们可以把整个过程看成一个单一的映射

$$X : \Omega \rightarrow \mathbb{R}^T,$$

其中

$$X(\omega) = (X_t(\omega))_{t \in T}.$$

也就是说，对每一个样本点 ω ，我们不再只得到一个数，而是得到一个函数

$$t \mapsto X_t(\omega).$$

因此，随机过程可以理解为函数空间中的随机元素。

■ 函数空间与坐标映射

设 T 是一个指标集， S 是一个集合。记

$$S^T = \{f : T \rightarrow S\}$$

为所有从 T 到 S 的函数组成的空间。

对每个 $t \in T$ ，定义坐标映射，也称为评价映射，

$$\pi_t : S^T \rightarrow S, \quad \pi_t(f) = f(t).$$

它的作用是：给定一条函数 f ，取出它在时刻 t 的值。

如果 S 上有一个 σ -代数 $\mathcal{S}$ ，那么我们希望在 S^T 上定义一个自然的 σ -代数，使得所有坐标映射

$$\pi_t : S^T \rightarrow S$$

都是可测的。

于是定义

$$\mathcal{S}^T = \sigma(\pi_t^{-1}(A) : t \in T, A \in \mathcal{S}).$$

这称为函数空间 S^T 上的柱形 σ -代数，也就是由所有坐标映射生成的 σ -代数。

换句话说， $\mathcal{S}^T$ 是使所有坐标映射 π_t 都可测的最小 σ -代数。

■ 柱形集合

函数空间中最基本的可测集合是柱形集合。给定有限多个时刻

$$t_1, \dots, t_n \in T$$

以及一个集合

$$B \in \mathcal{S}^{\otimes n},$$

定义

$$C(t_1, \dots, t_n; B) = \{f \in S^T : (f(t_1), \dots, f(t_n)) \in B\}.$$

这类集合称为柱形集合。

如果 $B = A_1 \times \dots \times A_n$ ，其中 $A_i \in \mathcal{S}$ ，那么

$$C(t_1, \dots, t_n; A_1 \times \dots \times A_n) = \bigcap_{i=1}^n \pi_{t_i}^{-1}(A_i).$$

因此，柱形集合只关心函数在有限多个时间点上的取值。

对随机过程 $X = (X_t)_{t \in T}$ 来说，柱形事件就是

$$\{(X_{t_1}, \dots, X_{t_n}) \in B\}.$$

这说明函数空间上的柱形 σ -代数正是由随机过程的有限维观测生成的。

■ 连续函数空间 $C[0, 1]$

现代概率论中最重要的函数空间之一是

$$C[0, 1],$$

它表示所有定义在 $[0, 1]$ 上的连续实值函数。

在 $C[0, 1]$ 上定义一致距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

在这个距离下,

$$f_n \rightarrow f$$

等价于

$$\sup_{t \in [0, 1]} |f_n(t) - f(t)| \rightarrow 0,$$

也就是 f_n 一致收敛到 f 。

由这个度量可以得到一个拓扑, 再由这个拓扑生成 Borel σ -代数:

$$\mathcal{B}(C[0, 1]).$$

这就是连续函数空间上最自然的可测结构。

如果一个随机过程具有连续样本路径, 那么它可以看成

$$X : (\Omega, \mathcal{F}) \rightarrow (C[0, 1], \mathcal{B}(C[0, 1]))$$

的随机元素。这里

$$X(\omega)(t) = X_t(\omega).$$

也就是说, 对每个样本点 ω , 随机元素 $X(\omega)$ 是一条连续函数路径。

■ 评价映射

对每个 $t \in [0, 1]$, 定义评价映射

$$e_t : C \rightarrow \mathbb{R}, \quad e_t(f) = f(t).$$

这个映射把一条连续函数 f 送到它在 t 点的取值。

我们先说明 e_t 是连续的。对任意 $f, g \in C[0, 1]$, 有

$$|e_t(f) - e_t(g)| = |f(t) - g(t)| \leq \sup_{s \in [0, 1]} |f(s) - g(s)| = d(f, g).$$

因此 e_t 是 Lipschitz 连续映射, 从而也是 Borel 可测映射:

$$e_t : (C[0, 1], \mathcal{B}(C[0, 1])) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

于是, 对任意 $B \in \mathcal{B}(\mathbb{R})$, 集合

$$e_t^{-1}(B) = \{f \in C[0, 1] : f(t) \in B\}$$

都是 $C[0, 1]$ 中的 Borel 集。

■ 由评价映射生成的 σ -代数

由所有评价映射生成的 σ -代数定义为

$$\sigma(e_t : t \in [0, 1]) = \sigma(e_t^{-1}(B) : t \in [0, 1], B \in \mathcal{B}(\mathbb{R})).$$

这是 $C[0, 1]$ 上的一个 σ -代数。

由于每个 e_t 都是 Borel 可测的, 所以

$$\sigma(e_t : t \in [0, 1]) \subset \mathcal{B}(C[0, 1]).$$

事实上, 在连续函数空间中, 反向包含也成立。

命题.

在 $C[0, 1]$ 上, 有

$$\mathcal{B}(C[0, 1]) = \sigma(e_t : t \in [0, 1]).$$

更进一步, 若

$$D = \mathbb{Q} \cap [0, 1],$$

则

$$\mathcal{B}(C[0, 1]) = \sigma(e_q : q \in D).$$

证明.

记

$$\mathcal{G} = \sigma(e_q : q \in D).$$

由于每个 e_q 都是连续映射, 因此都是 Borel 可测映射, 所以

$$\mathcal{G} \subset \mathcal{B}(C[0, 1]).$$

下面证明反向包含。只要证明 $C[0, 1]$ 中的每个开集都属于 $\mathcal{G}$, 即可得到

$$\mathcal{B}(C[0, 1]) \subset \mathcal{G}.$$

首先固定一个函数 $f \in C[0, 1]$ 。考虑映射

$$\Phi_f : C \rightarrow \mathbb{R}, \quad \Phi_f(g) = d(f, g).$$

因为 f, g 都是连续函数, 而 $D = \mathbb{Q} \cap [0, 1]$ 在 $[0, 1]$ 中稠密, 所以

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)| = \sup_{q \in D} |f(q) - g(q)|.$$

也就是说,

$$\Phi_f(g) = \sup_{q \in D} |f(q) - e_q(g)|.$$

对每个 $q \in D$, 映射

$$g \mapsto |f(q) - e_q(g)|$$

是 $\mathcal{G}/\mathcal{B}(\mathbb{R})$ -可测函数。由于 D 是可数集合, 可数个可测函数的上确界仍然可测, 所以

$$\Phi_f$$

是 $\mathcal{G}/\mathcal{B}(\mathbb{R})$ -可测函数。

因此, 对于任意 $r > 0$, 开球

$$B(f, r) = \{g \in C[0, 1] : d(f, g) < r\}$$

可以写成

$$B(f, r) = \Phi_f^{-1}((-\infty, r)),$$

从而

$$B(f, r) \in \mathcal{G}.$$

接下来利用 $C[0, 1]$ 在一致距离下是可分的。取一个可数稠密子集

$$\{f_1, f_2, \dots\} \subset C[0, 1].$$

于是 $C[0, 1]$ 的拓扑有一个可数基:

$$\{B(f_n, r) : n \in \mathbb{N}, r \in \mathbb{Q}_{>0}\}.$$

任意开集 $U \subset C[0, 1]$ 都可以写成这些基元素的可数并:

$$U = \bigcup_{\substack{n \in \mathbb{N}, r \in \mathbb{Q}_{>0} \\ B(f_n, r) \subset U}} B(f_n, r).$$

由于每个开球 $B(f_n, r) \in \mathcal{G}$, 而 $\mathcal{G}$ 对可数并封闭, 所以

$$U \in \mathcal{G}.$$

因此所有开集都属于 $\mathcal{G}$, 于是

$$\mathcal{B}(C[0, 1]) \subset \mathcal{G}.$$

结合前面得到的

$$\mathcal{G} \subset \mathcal{B}(C[0, 1]),$$

可得

$$\mathcal{B}(C[0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]).$$

又因为

$$\sigma(e_q : q \in \mathbb{Q} \cap [0, 1]) \subset \sigma(e_t : t \in [0, 1]) \subset \mathcal{B}(C[0, 1]),$$

所以

$$\mathcal{B}(C[0, 1]) = \sigma(e_t : t \in [0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]).$$

证毕。

■ 随机连续函数的可测性判别

设

$$X : \Omega \rightarrow C[0, 1]$$

是一个映射。令

$$X_t(\omega) = X(\omega)(t).$$

则

$$X_t = e_t \circ X.$$

由上面的结论可知，若 $X(\omega) \in C[0, 1]$ 对所有 ω 成立，则

$$X : (\Omega, \mathcal{F}) \rightarrow (C[0, 1], \mathcal{B}(C[0, 1]))$$

可测，当且仅当对所有

$$q \in \mathbb{Q} \cap [0, 1],$$

都有

$$X_q : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

可测。

也就是说，对连续路径随机过程来说，只需要检查有理数时刻的坐标随机变量，就可以得到整个路径作为 $C[0, 1]$ -值随机元素的可测性。

这就是可分性在函数空间中的重要作用：它把不可数个时间点上的问题，化约为可数个时间点上的问题。

■ 例子：最大值事件

设 $X : \Omega \rightarrow C[0, 1]$ 是随机连续函数。定义

$$M(\omega) = \sup_{t \in [0, 1]} X_t(\omega).$$

由于 $X(\omega)$ 是连续函数，并且 $\mathbb{Q} \cap [0, 1]$ 在 $[0, 1]$ 中稠密，所以

$$\sup_{t \in [0, 1]} X_t(\omega) = \sup_{q \in \mathbb{Q} \cap [0, 1]} X_q(\omega).$$

因此

$$M = \sup_{q \in \mathbb{Q} \cap [0, 1]} X_q.$$

右边是可数个随机变量的上确界，所以 M 是随机变量。

特别地，对任意 $a \in \mathbb{R}$ ，事件

$$\left\{ \sup_{t \in [0, 1]} X_t > a \right\}$$

可以写成

$$\bigcup_{q \in \mathbb{Q} \cap [0,1]} \{X_q > a\}.$$

因此它属于 $\mathcal{F}$ 。

这个例子说明，函数空间的可测结构可以把看似涉及不可数多个时间点的事件，转化为可数个事件的并或交。

■ 布朗运动作为函数空间值随机元素

如果 $(B_t)_{0 \leq t \leq 1}$ 是具有连续样本路径的布朗运动，那么对每个样本点 ω ，映射

$$t \mapsto B_t(\omega)$$

是一条连续函数。因此可以定义

$$B : \Omega \rightarrow C[0, 1], \quad B(\omega)(t) = B_t(\omega).$$

此时 B 是一个 $C[0, 1]$ -值随机元素。

在这个观点下，布朗运动不只是一个随机变量族

$$\{B_t : 0 \leq t \leq 1\},$$

而是一个取值于连续函数空间的随机对象

$$B : (\Omega, \mathcal{F}) \rightarrow (C[0, 1], \mathcal{B}(C[0, 1])).$$

它在 $C[0, 1]$ 上诱导出的分布称为 Wiener 测度。

■ 有限维分布与路径分布

设

$$X : \Omega \rightarrow C[0, 1]$$

是随机连续函数。它的分布是 $C[0, 1]$ 上的概率测度

$$\mu_X(A) = \mathbb{P}(X \in A), \quad A \in \mathcal{B}(C[0, 1]).$$

由于

$$\mathcal{B}(C[0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]),$$

这个分布由有限维柱形事件决定。

也就是说，若两个随机连续函数 X, Y 满足：对任意

$$q_1, \dots, q_n \in \mathbb{Q} \cap [0, 1],$$

都有

$$(X_{q_1}, \dots, X_{q_n})$$

与

$$(Y_{q_1}, \dots, Y_{q_n})$$

分布相同, 那么 X 与 Y 作为 $C[0, 1]$ -值随机元素具有相同的分布。

直观地说, 在连续路径空间中, 路径的概率分布可以由有理数时刻上的所有有限维分布决定。

■ 本节小结

本节讨论了函数空间上的可测结构。

首先, 对一般函数空间

$$S^T$$

可以通过坐标映射

$$\pi_t(f) = f(t)$$

生成柱形 σ -代数:

$$\sigma(\pi_t^{-1}(A) : t \in T, A \in \mathcal{S}).$$

其次, 对连续函数空间 $C[0, 1]$, 我们可以使用一致距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|$$

得到 Borel σ -代数

$$\mathcal{B}(C[0, 1]).$$

再次, 评价映射

$$e_t(f) = f(t)$$

是连续的, 因此是 Borel 可测的。

最重要的是, 在连续函数空间中有

$$\mathcal{B}(C[0, 1]) = \sigma(e_t : t \in [0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]).$$

这说明连续路径的 Borel 可测结构可以由可数个有理时刻的取值生成。

最后, 如果随机过程具有连续样本路径, 那么它可以看成一个 $C[0, 1]$ -值随机元素:

$$X : \Omega \rightarrow C[0, 1].$$

此时许多涉及整条路径的事件, 例如

$$\left\{ \sup_{t \in [0, 1]} X_t > a \right\},$$

都可以通过可数个坐标随机变量来表达。

本节的核心思想是:

随机过程 = 函数空间中的随机元素.

函数空间的可测结构使我们能够严格地讨论路径事件、路径分布以及随机过程的整体分布。

■ 练习

1. 设 $e_t : C \rightarrow \mathbb{R}$ 定义为 $e_t(f) = f(t)$ 。证明 e_t 是连续映射。

2. 证明对任意 $t \in [0, 1]$ 和 $a \in \mathbb{R}$, 集合

$$\{f \in C[0, 1] : f(t) \leq a\}$$

属于 $\mathcal{B}(C[0, 1])$ 。

3. 设 $D = \mathbb{Q} \cap [0, 1]$ 。证明对任意 $f, g \in C[0, 1]$, 有

$$\sup_{t \in [0, 1]} |f(t) - g(t)| = \sup_{q \in D} |f(q) - g(q)|.$$

4. 证明

$$\mathcal{B}(C[0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]).$$

5. 设 $X : \Omega \rightarrow C[0, 1]$ 是映射, 并定义

$$X_t(\omega) = X(\omega)(t).$$

证明若 X 可测, 则每个 X_t 都是实值随机变量。

6. 设 $X : \Omega \rightarrow C[0, 1]$, 并假设对所有 $q \in \mathbb{Q} \cap [0, 1]$, X_q 都是随机变量。证明 X 是 $C[0, 1]$ -值随机元素。

7. 设 $X : \Omega \rightarrow C[0, 1]$ 是随机连续函数。证明

$$\sup_{t \in [0, 1]} X_t$$

是实值随机变量。

8. 设 $X : \Omega \rightarrow C[0, 1]$ 是随机连续函数。证明事件

$$\{X(t) > 0, \forall t \in [0, 1]\}$$

属于 $\mathcal{F}$ 。

9. 设 X, Y 是两个 $C[0, 1]$ -值随机元素。若对任意

$$q_1, \dots, q_n \in \mathbb{Q} \cap [0, 1],$$

随机向量

$$(X_{q_1}, \dots, X_{q_n})$$

与

$$(Y_{q_1}, \dots, Y_{q_n})$$

分布相同, 证明 X 与 Y 作为 $C[0, 1]$ -值随机元素分布相同。

10. 用一句话解释: 为什么连续路径空间的可测结构可以由有理数时刻的取值生成?

1.9 可测选择与正则化思想入门

前面几节建立了可测空间、可测映射、Polish 空间、标准 Borel 空间以及函数空间上的可测结构。这些概念不是为了形式上的精致，而是为了让我们能够严格处理随机对象的取值、分布、联合结构和路径结构。本节讨论一个在现代概率论、随机优化、控制论和条件分布理论中反复出现的问题：

如果对每个参数 x 都给出一组候选点 $\Gamma(x)$ ，我们能否从每个候选集合中选出一个点，并且使选出来的函数 $x \mapsto f(x)$ 是可测的？

这就是可测选择问题。它表面上只是一个“选点”的问题，实质上却是在问：一个抽象存在的对象，能否被替换成一个概率论可以继续操作的可测版本。

■ 从普通选择到可测选择

设 $(X, \mathcal{A})$ 是可测空间， Y 是一个拓扑空间。假设对每个 $x \in X$ ，我们给出一个非空集合

$$\Gamma(x) \subset Y.$$

这样的对象称为集值映射，也记作

$$\Gamma : X \rightrightarrows Y.$$

这里的符号 $\rightrightarrows$ 提醒我们： Γ 不是把 x 送到一个点，而是把 x 送到一个集合。

一个普通的选择函数是指映射

$$f : X \rightarrow Y$$

满足

$$f(x) \in \Gamma(x), \quad x \in X.$$

如果进一步要求

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B}(Y))$$

是可测映射，那么称 f 是 Γ 的一个可测选择。

普通选择只关心“能不能选”，可测选择关心的是“能不能以可测的方式选”。这个额外要求在概率论中非常关键。如果 $Z : \Omega \rightarrow X$ 是随机元素，而 $f : X \rightarrow Y$ 不可测，那么复合 $f(Z)$ 可能根本不是随机元素。因此，在随机优化、随机控制和条件概率中，我们不仅需要最优解或条件对象存在，还需要它们能被选成可测对象。

■ 集值映射的图像

描述集值映射的一个基本方法是看它的图像。给定 $\Gamma : X \rightrightarrows Y$ ，定义

$$\text{Gr}(\Gamma) = \{(x, y) \in X \times Y : y \in \Gamma(x)\}.$$

选择函数 $f : X \rightarrow Y$ 满足 $f(x) \in \Gamma(x)$ ，等价于

$$(x, f(x)) \in \text{Gr}(\Gamma), \quad x \in X.$$

也就是说， f 自己的图像

$$\text{Gr}(f) = \{(x, f(x)) : x \in X\}$$

被包含在 Γ 的图像中：

$$\text{Gr}(f) \subset \text{Gr}(\Gamma).$$

所以，可测选择问题也可以表述为：

给定一个集合 $A \subset X \times Y$ ，如果每个竖直截面

$$A_x = \{y \in Y : (x, y) \in A\}$$

都非空，能否可测地从每个截面 A_x 中选出一个点？

这个视角非常重要。很多概率论中的“存在性”问题最后都会变成截面选择问题。例如，在条件分布中，我们想对每个 x 选一个概率测度；在优化中，我们想对每个参数 x 选一个最优解；在随机过程理论中，我们想对每个等价类选一个更规则的路径版本。

■ Effros 可测性

若目标空间 Y 带有拓扑结构，而 $\Gamma(x)$ 通常取闭集值，那么最常用的可测性条件不是直接要求 $\text{Gr}(\Gamma)$ 可测，而是要求它与开集相交这件事可测。

称非空闭值集值映射 $\Gamma : X \rightrightarrows Y$ 是 Effros 可测的，如果对任意开集 $U \subset Y$ ，都有

$$\{x \in X : \Gamma(x) \cap U \neq \emptyset\} \in \mathcal{A}.$$

这句话的直观意思是：对于任意一个可观察的开区域 U ，我们可以可测地判断候选集合 $\Gamma(x)$ 是否碰到了 U 。

在度量空间中，也可以用距离来理解这个条件。对闭集 $F \subset Y$ ，定义

$$\text{dist}(y, F) = \inf_{z \in F} d(y, z).$$

当 Y 是可分度量空间时，闭值映射的 Effros 可测性与许多距离函数的可测性密切相关。例如，固定 $y \in Y$ ，集合

$$\{x : \Gamma(x) \cap B(y, r) \neq \emptyset\}$$

可以看作是在判断 $\text{dist}(y, \Gamma(x)) < r$ 。这也是后面可数逼近构造能够工作的原因。

■ Kuratowski–Ryll–Nardzewski 可测选择定理

可测选择理论中最经典的结果是 Kuratowski–Ryll–Nardzewski 定理。在本书这里我们只记录它的核心形式。

Kuratowski–Ryll–Nardzewski 可测选择定理. 设 $(X, \mathcal{A})$ 是可测空间, Y 是 Polish 空间。设 $\Gamma : X \rightrightarrows Y$ 是非空闭值集值映射, 即对每个 $x \in X$,

$$\emptyset \neq \Gamma(x) \subset Y,$$

且 $\Gamma(x)$ 是闭集。如果 Γ 是 Effros 可测的, 那么存在一个可测函数

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B}(Y))$$

使得

$$f(x) \in \Gamma(x), \quad x \in X.$$

这个定理说明, 在 Polish 目标空间中, 只要候选集合是非空闭集, 并且候选集合随 x 的变化是可测的, 我们就可以可测地从每个候选集合中选出一个点。Polish 条件在这里不是装饰。可分性提供可数稠密集, 完备性保证极限不会逃出空间; 这两点正是可测选择构造的骨架。

■ 证明思想: 可数逼近与极限

我们不在这里完整证明定理, 但说明它的核心机制。因为 Y 是 Polish 空间, 所以存在可数稠密点列

$$\{y_1, y_2, y_3, \dots\} \subset Y.$$

构造可测选择时, 可以按照如下思路进行。

1. 固定这列可数稠密点。
2. 对每个 x , 按照固定编号寻找第一个足够接近 $\Gamma(x)$ 的稠密点。
3. 让逼近精度逐步提高, 并通过完备性取极限。

粗略地说, 我们构造一系列可测函数

$$f_1, f_2, f_3, \dots : X \rightarrow Y$$

使得

$$\text{dist}(f_k(x), \Gamma(x)) < 2^{-k}.$$

每个 f_k 只从可数集合 $\{y_n : n \geq 1\}$ 中取值。它在某个 y_n 上取值的事件, 可以由形如

$$\{x : \Gamma(x) \cap B(y_n, r) \neq \emptyset\}$$

的集合组合出来。Effros 可测性正好保证这些事件可测, 因此 f_k 可测。

为了让 $f_k(x)$ 收敛, 还需要在构造时安排 Cauchy 性质。当 Y 完备时, 极限

$$f(x) = \lim_{k \rightarrow \infty} f_k(x)$$

存在; 由于 $\Gamma(x)$ 闭, 且 $f_k(x)$ 越来越接近 $\Gamma(x)$, 极限点仍属于 $\Gamma(x)$ 。最后, 可测函数的点态极限仍然可测, 因此 f 是可测选择。

■ 几个基本例子

区间中的选择. 令 $X = \mathbb{R}$, $Y = \mathbb{R}$, 并定义

$$\Gamma(x) = [x, x+1].$$

可以选择左端点

$$f(x) = x,$$

也可以选择中点

$$g(x) = x + \frac{1}{2}.$$

它们都满足 $f(x), g(x) \in [x, x+1]$, 并且都是连续函数, 因此都是可测选择。

平方方程的选择. 令

$$\Gamma(x) = \{y \in \mathbb{R} : y^2 = x^2\}.$$

则

$$\Gamma(x) = \{-|x|, |x|\}.$$

函数

$$f(x) = |x|, \quad g(x) = x$$

都是可测选择。这个例子说明, 选择通常不唯一; 可测选择定理保证的是至少存在一个可测选法, 而不是指定唯一的选法。

不可测性的警示. 设 $A \subset \mathbb{R}$ 是一个非 Borel 集, 并定义

$$\Gamma(x) = \begin{cases} \{0\}, & x \in A, \\ \{1\}, & x \notin A. \end{cases}$$

此时每个 $\Gamma(x)$ 都是非空闭集, 但唯一的选择函数是

$$f(x) = \begin{cases} 0, & x \in A, \\ 1, & x \notin A. \end{cases}$$

它不是 Borel 可测函数。这说明“每个截面非空”远远不够; 集值映射随参数变化的可测性是不可省略的。

■ 可测 argmin 定理

可测选择定理在优化问题中尤其常用。设有目标函数

$$c : X \times Y \rightarrow \mathbb{R},$$

并希望对每个 $x \in X$ 求解

$$\min_{y \in \Gamma(x)} c(x, y).$$

如果最优解不唯一，那么最优解集合为

$$M(x) = \arg \min_{y \in \Gamma(x)} c(x, y).$$

此时我们希望选出一个最优解 $f(x) \in M(x)$ ，并且希望 f 是可测的。

一个常用版本如下。设 $(X, \mathcal{A})$ 是可测空间， Y 是 Polish 空间。设 $\Gamma : X \rightrightarrows Y$ 是非空紧值的 Effros 可测集值映射。设 $c : X \times Y \rightarrow \mathbb{R}$ 满足：

1. 对每个 $y \in Y$ ，函数 $x \mapsto c(x, y)$ 是 $\mathcal{A}/\mathcal{B}(\mathbb{R})$ 可测的；
2. 对每个 $x \in X$ ，函数 $y \mapsto c(x, y)$ 是连续的。

定义值函数

$$v(x) = \min_{y \in \Gamma(x)} c(x, y),$$

以及最优解集合

$$M(x) = \{y \in \Gamma(x) : c(x, y) = v(x)\}.$$

在这些条件下， $M(x)$ 是非空紧集，并且可以选出可测函数

$$f : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B}(Y))$$

使得

$$f(x) \in M(x), \quad x \in X.$$

等价地，

$$c(x, f(x)) = \min_{y \in \Gamma(x)} c(x, y).$$

这类结论在统计学习、随机控制和贝叶斯决策中非常有用。例如，当 x 是观测数据， y 是决策， $c(x, y)$ 是损失函数时，定理保证我们可以把“每个数据点的最优决策”选成一个可测决策规则。如果缺少可测性，这个最优规则就无法作为随机变量或统计量使用。

投影到区间的例子。 令 $Y = [0, 1]$ ，并令

$$c(x, y) = (y - x)^2.$$

对每个 $x \in \mathbb{R}$ ，考虑

$$\min_{y \in [0, 1]} (y - x)^2.$$

最优解为

$$y^*(x) = \begin{cases} 0, & x < 0, \\ x, & 0 \leq x \leq 1, \\ 1, & x > 1. \end{cases}$$

也就是

$$y^*(x) = \min\{\max\{x, 0\}, 1\}.$$

这是连续函数，因此是可测最优选择。

■ Jankov–von Neumann 选择定理

Kuratowski–Ryll–Nardzewski 定理给出 Borel 可测选择，但它要求闭值和 Effros 可测性。还有一个更一般但结论稍弱的版本，称为 Jankov–von Neumann 选择定理。

非正式地说，设 X, Y 是标准 Borel 空间， $A \subset X \times Y$ 是解析集。若对每个

$$x \in \text{proj}_X(A)$$

都存在 $y \in Y$ 使得

$$(x, y) \in A,$$

则存在选择函数

$$f : \text{proj}_X(A) \rightarrow Y$$

满足

$$(x, f(x)) \in A.$$

不过，在这个一般性下，通常只能保证 f 是 universally measurable，而不一定是 Borel 可测。

这个定理解释了为什么标准 Borel 空间在现代概率论中如此常见。在标准 Borel 框架下，即使投影、截面和条件对象把问题推到了 Borel 集之外，仍然可以在解析集和普遍可测性的层面继续工作。

■ 正则化思想

本节标题中的“正则化”不是机器学习中常见的 L^2 penalty，而是概率论中的一种基础思想：

将原本不唯一、只在几乎处处意义下定义、或不够规则的对象，替换成一个可测、稳定、可继续操作的版本。

典型例子包括：

1. **可测选择**：每个集合 $\Gamma(x)$ 中可能有很多候选点，我们选出一个可测版本 $f(x) \in \Gamma(x)$ 。

2. **条件期望**：条件期望通常只在几乎处处意义下唯一。实际使用时，需要选取一个方便的可测版本。
3. **正则条件分布**：条件概率 $\mathbb{P}(Y \in B \mid X = x)$ 需要被表示为一个概率核 $K(x, B)$ ，使它对 x 可测，对 B 是概率测度。
4. **随机过程的路径正则化**：一个随机过程可能最初只按每个时刻 t 定义，但我们希望找到一个具有连续、右连续或 cadlag 路径的版本。

因此，正则化思想可以概括为

$$\text{抽象存在} \implies \text{可测版本} \implies \text{可操作对象}.$$

■ 与正则条件分布的关系

设

$$X : \Omega \rightarrow S, \quad Y : \Omega \rightarrow T$$

是随机元素。我们希望讨论

$$\mathbb{P}(Y \in B \mid X = x).$$

当事件 $\{X = x\}$ 的概率为零时，普通条件概率无法直接定义。现代概率论通过正则条件分布来处理这个问题。

设 $(S, \mathcal{S})$ 和 $(T, \mathcal{T})$ 是可测空间。一个映射

$$K : S \times \mathcal{T} \rightarrow [0, 1]$$

称为从 S 到 T 的概率核，如果：

1. 对每个 $x \in S$ ， $B \mapsto K(x, B)$ 是 $(T, \mathcal{T})$ 上的概率测度；
2. 对每个 $B \in \mathcal{T}$ ， $x \mapsto K(x, B)$ 是 $\mathcal{S}/\mathcal{B}([0, 1])$ 可测函数。

正则条件分布就是把条件分布写成这样的概率核。在标准 Borel 空间中，正则条件分布通常能够存在；这也是前面坚持使用标准 Borel 语言的重要原因之一。

从思想上看，正则条件分布与可测选择是同一类问题。我们不仅要知道“条件分布存在”，还要能把它选成一个对条件变量 x 可测的对象。只有这样，表达式

$$K(X(\omega), B)$$

才真正是一个随机变量，后续的积分、迭代条件期望和 disintegration 公式才有意义。

■ 本节小结

本节可以压缩成六个要点。

1. 集值映射 $\Gamma : X \rightrightarrows Y$ 给每个 x 分配一个集合 $\Gamma(x)$ 。

2. 选择函数 f 满足 $f(x) \in \Gamma(x)$ 。
3. 可测选择要求 f 进一步是可测映射。
4. Kuratowski–Ryll–Nardzewski 定理说明：若 Y 是 Polish 空间， Γ 是非空闭值 Effros 可测集值映射，则存在可测选择。
5. 在优化问题中，可测选择定理保证可以选出可测最优解。
6. 正则化思想是把原本不唯一或不够规则的对象，替换为可测、稳定、可操作的版本。

一句话总结：在足够好的空间中，我们不仅可以从每个候选集合中选点，而且可以以可测的方式选点。

■ 练习

1. 设 $\Gamma(x) = [0, x]$ ，其中 $x \geq 0$ 。写出两个不同的可测选择。

2. 设

$$\Gamma(x) = \{y \in \mathbb{R} : y^2 = x^2\}.$$

写出两个不同的可测选择，并说明它们为什么可测。

3. 设

$$c(x, y) = (y - x)^2, \quad y \in [-1, 1].$$

求

$$y^*(x) = \arg \min_{y \in [-1, 1]} c(x, y),$$

并证明 y^* 是可测函数。

4. 设 $\Gamma : X \rightrightarrows Y$ 是非空闭值集值映射。解释为什么条件

$$\{x : \Gamma(x) \cap U \neq \emptyset\} \in \mathcal{A}$$

可以看成是集值映射的可测性条件。

5. 用一句话解释：为什么最优解 $y^*(X)$ 要成为随机变量，必须要求 y^* 是可测函数？
6. 用一句话解释：正则条件分布为什么可以看作一种正则化？

1.10 模块总结：概率论为何从可测结构开始

本章的核心问题是：为什么现代概率论不是直接从概率公式开始，而是要先讨论集合、映射、拓扑、 σ -代数、Borel 结构、可测映射、Polish 空间和标准 Borel 空间？

这一点一开始看起来比较抽象。初等概率论中，我们常常直接写

$$\mathbb{P}(A), \quad \mathbb{P}(X \leq t), \quad \mathbb{P}(a < X < b).$$

但是在现代概率论中，这些表达式并不是无条件合法的。要使它们有意义，我们必须先回答两个问题：

A 是不是一个合法事件？

以及

$\{X \leq t\}, \{a < X < b\}$ 是不是样本空间中的合法事件？

也就是说，概率论不是先问某个事件的概率是多少，而是先问哪些集合可以被称为事件。只有事件系统先被确定下来，概率测度才能被定义在这些事件上。

因此，现代概率论的基本起点不是一个单独的集合 Ω ，而是一个可测空间

$$(\Omega, \mathcal{F}),$$

其中 Ω 是样本空间， $\mathcal{F}$ 是 Ω 上的一个 σ -代数。 $\mathcal{F}$ 中的集合才是我们允许讨论概率的事件。

■ 从样本空间到事件系统

样本空间

$$\Omega$$

表示随机试验的所有可能结果。样本点

$$\omega \in \Omega$$

表示一次具体的结果。

但是，在一般情形下，并不是 Ω 的所有子集都一定可以被赋予概率。我们需要选择一个事件系统

$$\mathcal{F} \subset 2^\Omega.$$

这里 2^Ω 表示 Ω 的所有子集组成的幂集。

为了让概率论中的基本逻辑运算成立， $\mathcal{F}$ 必须满足一些封闭性。若 A 是事件，那么“ A 不发生”也应该是事件，因此需要

$$A \in \mathcal{F} \implies A^c \in \mathcal{F}.$$

若 $A_1, A_2, \dots$ 都是事件，那么“至少发生一个”也应该是事件，因此需要

$$A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

由补集和可数并的封闭性，又可以推出可数交的封闭性：

$$\bigcap_{n=1}^{\infty} A_n = \left(\bigcup_{n=1}^{\infty} A_n^c \right)^c.$$

因此，概率论中的事件系统自然要求是一个 σ -代数。

事件系统 = σ -代数

这就是可测结构的第一层含义：它规定了哪些集合是合法事件。

■ 随机变量不是普通函数，而是可测映射

在集合论中，一个随机变量看起来只是一个映射

$$X : \Omega \rightarrow S.$$

它把每个样本点 $\omega \in \Omega$ 送到某个取值

$$X(\omega) \in S.$$

但是在概率论中，随机变量不能只是普通函数。因为我们真正想讨论的是

$$\mathbb{P}(X \in B),$$

其中 $B \subset S$ 是取值空间中的集合。

严格地说，

$$\{X \in B\} = \{\omega \in \Omega : X(\omega) \in B\} = X^{-1}(B).$$

这里 $X^{-1}(B)$ 是集合 B 在映射 X 下的原像。

概率测度 $\mathbb{P}$ 是定义在样本空间的事件系统 $\mathcal{F}$ 上的，而不是直接定义在 S 的所有子集上的。因此，想要 $\mathbb{P}(X \in B)$ 有意义，就必须要求

$$X^{-1}(B) \in \mathcal{F}.$$

如果取值空间 S 上也有一个 σ -代数 $\mathcal{S}$ ，那么我们要求

$$B \in \mathcal{S} \implies X^{-1}(B) \in \mathcal{F}.$$

这正是可测映射的定义。

也就是说，

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$$

是可测映射，如果对任意 $B \in \mathcal{S}$ ，都有

$$X^{-1}(B) \in \mathcal{F}.$$

因此：

$$\boxed{\text{随机变量} = \text{可测映射}}$$

可测性的真正作用是保证：关于随机变量取值的条件，能够被拉回成样本空间中的合法事件。

■ 原像是概率论的核心操作

在概率论中，映射最重要的操作不是像，而是原像。原因是概率测度首先定义在样本空间上。

如果

$$X : \Omega \rightarrow S$$

是随机变量， $B \subset S$ 是取值空间中的集合，那么 B 本身通常不是 Ω 中的事件，因此不能直接写 $\mathbb{P}(B)$ 。正确的做法是先把 B 拉回到样本空间：

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

然后再计算

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)).$$

这个过程可以概括为：

$$B \subset S \xrightarrow{X^{-1}} X^{-1}(B) \subset \Omega \xrightarrow{\mathbb{P}} \mathbb{P}(X^{-1}(B)).$$

所以，原像是连接取值空间和样本空间的桥梁。

原像之所以重要，还因为它和集合运算相容。对任意映射 $f : \Omega \rightarrow S$ ，有

$$f^{-1}(B^c) = (f^{-1}(B))^c,$$

$$f^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} f^{-1}(B_n),$$

$$f^{-1}\left(\bigcap_{n=1}^{\infty} B_n\right) = \bigcap_{n=1}^{\infty} f^{-1}(B_n).$$

这些性质说明，原像能够把取值空间中的逻辑结构稳定地转移到样本空间中。这正是可测映射能够良好定义的根本原因。

■ 拓扑为什么会出现

当随机变量取值于实数轴时，我们自然会关心区间事件，例如

$$\{X \leq t\}, \quad \{a < X < b\}.$$

这些事件对应于实数轴上的集合

$$(-\infty, t], \quad (a, b).$$

实数轴上有自然的拓扑结构。开区间、开集、闭集、连续性、收敛、紧性等概念都来自拓扑。更一般地，现代概率论中的随机对象不一定只取值于 $\mathbb{R}$ ，也可能取值于

$$\mathbb{R}^d, \quad C[0, 1], \quad D[0, 1], \quad \mathcal{P}(S).$$

这些空间往往都有自然的拓扑或度量。

拓扑本身还不是概率测度的定义域。概率测度需要定义在 σ -代数上。因此，对于一个拓扑空间 S ，我们用它的开集生成一个 σ -代数：

$$\mathcal{B}(S) = \sigma(\text{open sets of } S).$$

这个 σ -代数称为 S 上的 Borel σ -代数。

于是，拓扑空间自然给出可测空间：

$$S \longmapsto (S, \mathcal{B}(S)).$$

所以，本章的一条主线是：

$$\boxed{\text{拓扑} \implies \text{Borel } \sigma\text{-代数} \implies \text{可测空间}}$$

拓扑告诉我们哪些集合是开集，Borel σ -代数告诉我们哪些集合是可测集合。概率论正是通过 Borel σ -代数把拓扑语言转化为可测语言。

■ 实值随机变量的可测性判别

如果

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

是实值随机变量，那么按定义需要对任意 Borel 集 $B \in \mathcal{B}(\mathbb{R})$ 都有

$$X^{-1}(B) \in \mathcal{F}.$$

但是 $\mathcal{B}(\mathbb{R})$ 中的集合非常多，直接检查所有 Borel 集通常不可行。

幸运的是，

$$\mathcal{B}(\mathbb{R}) = \sigma((-\infty, t] : t \in \mathbb{R}).$$

因此，只需要检查半直线的原像即可。也就是说，函数 $X : \Omega \rightarrow \mathbb{R}$ 是实值随机变量，当且仅当

$$\{X \leq t\} \in \mathcal{F}, \quad t \in \mathbb{R}.$$

这体现了生成类思想：要验证一个关于整个 σ -代数的性质，往往只需要在一个较小的生成类上验证。

$$X \text{ 可测} \iff \{X \leq t\} \in \mathcal{F}, \quad \forall t \in \mathbb{R}$$

■ 分布是推出测度

设

$$X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{S})$$

是随机元素。对任意 $B \in \mathcal{S}$ ，定义

$$\mu_X(B) = \mathbb{P}(X \in B).$$

严格地写，就是

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)).$$

这样得到的 μ_X 是 $(S, \mathcal{S})$ 上的概率测度，称为 X 的分布。

这个测度通常记作

$$\mu_X = \mathbb{P} \circ X^{-1}.$$

其中 X^{-1} 表示先把 S 中的集合拉回到 Ω 中，再由 $\mathbb{P}$ 计算概率。因此，随机变量的分布不是直接凭空定义在取值空间上的，而是由样本空间上的概率测度通过随机变量诱导出来的。

$$\text{分布} = \text{样本空间上的概率通过随机变量推出的测度}$$

这个观点非常重要。它说明随机变量不仅仅是一个函数，更是把一个概率空间上的概率结构转移到另一个可测空间上的通道。

■ 生成类、 π -系统与 λ -系统的意义

很多时候，我们需要证明两个概率测度相等，或者证明两个随机变量分布相同。直接在整个 σ -代数上验证通常很困难。

例如，设 μ, ν 是 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上的两个概率测度。如果对所有 $t \in \mathbb{R}$ 都有

$$\mu((-\infty, t]) = \nu((-\infty, t]),$$

那么可以推出

$$\mu(B) = \nu(B), \quad B \in \mathcal{B}(\mathbb{R}).$$

原因是半直线族

$$\{(-\infty, t] : t \in \mathbb{R}\}$$

生成了 $\mathcal{B}(\mathbb{R})$ ，并且它是一个 π -系统。

π - λ 定理的作用就是把结论从一个小的生成类推广到整个 σ -代数。它的基本精神是：

$$\boxed{\text{在生成类上验证} \implies \text{推广到整个}\sigma\text{-代数}}$$

这也是为什么分布函数

$$F_X(t) = \mathbb{P}(X \leq t)$$

能够决定实值随机变量的分布。因为它已经给出了分布在所有半直线 $(-\infty, t]$ 上的取值，而这些半直线生成整个 Borel σ -代数。

■ 乘积结构与联合随机对象

概率论经常同时研究多个随机对象。若

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}), \quad Y : (\Omega, \mathcal{F}) \rightarrow (T, \mathcal{T})$$

是两个随机元素，那么我们希望把它们合并成一个联合随机元素

$$(X, Y) : \Omega \rightarrow S \times T.$$

为此，需要在 $S \times T$ 上定义合适的 σ -代数。自然的选择是乘积 σ -代数：

$$\mathcal{S} \otimes \mathcal{T} = \sigma(A \times B : A \in \mathcal{S}, B \in \mathcal{T}).$$

它是由所有可测矩形生成的最小 σ -代数。

这样，联合随机元素写作

$$(X, Y) : (\Omega, \mathcal{F}) \rightarrow (S \times T, \mathcal{S} \otimes \mathcal{T}).$$

并且有重要结论：

$$(X, Y) \text{ 可测} \iff X, Y \text{ 分别可测}.$$

联合分布定义为

$$\mu_{(X,Y)}(C) = \mathbb{P}((X, Y) \in C), \quad C \in \mathcal{S} \otimes \mathcal{T}.$$

特别地，在矩形集合上有

$$\mu_{(X,Y)}(A \times B) = \mathbb{P}(X \in A, Y \in B).$$

如果 X 与 Y 独立，那么联合分布等于边缘分布的乘积测度：

$$\mu_{(X,Y)} = \mu_X \otimes \mu_Y.$$

也就是说，独立性可以理解为：

$$\boxed{\text{独立性} = \text{联合分布等于边缘分布的乘积}}$$

■ 随机过程是函数空间中的随机元素

随机过程通常写成

$$\{X_t : t \in T\}.$$

这表示对每个时间点 t ，都有一个随机变量 X_t 。但是从现代概率论的观点看，我们可以把整个随机过程看成一个取值于函数空间的随机元素。

对每个样本点 $\omega \in \Omega$ ，映射

$$t \mapsto X_t(\omega)$$

是一条函数或者路径。因此可以定义

$$X(\omega)(t) = X_t(\omega).$$

于是整个随机过程可以写成

$$X : \Omega \rightarrow S^T.$$

如果路径连续，则可以进一步写成

$$X : \Omega \rightarrow C[0, 1].$$

此时 $C[0, 1]$ 上通常使用一致距离

$$d(f, g) = \sup_{t \in [0, 1]} |f(t) - g(t)|.$$

这个度量生成 Borel σ -代数

$$\mathcal{B}(C[0, 1]).$$

于是连续路径随机过程可以严格地表示为

$$X : (\Omega, \mathcal{F}) \rightarrow (C[0, 1], \mathcal{B}(C[0, 1])).$$

在 $C[0, 1]$ 中，评价映射

$$e_t : C[0, 1] \rightarrow \mathbb{R}, \quad e_t(f) = f(t)$$

是连续的，因此是 Borel 可测的。更重要的是，由于连续函数由其在稠密子集上的取值决定，有

$$\mathcal{B}(C[0, 1]) = \sigma(e_q : q \in \mathbb{Q} \cap [0, 1]).$$

这说明连续路径空间的 Borel 结构可以由有理数时刻的取值生成。

因此，许多看似涉及不可数多个时间点的事件，可以转化为可数个事件。例如，

$$\left\{ \sup_{t \in [0, 1]} X_t > a \right\} = \bigcup_{q \in \mathbb{Q} \cap [0, 1]} \{X_q > a\}.$$

右边是可数并，因此是可测事件。

这体现了函数空间可测结构的核心作用：

随机过程 = 函数空间中的随机元素

■ Polish 空间与标准 Borel 空间的作用

为了避免过于病态的可测空间，现代概率论经常在 Polish 空间和标准 Borel 空间中工作。一个 Polish 空间是可以由完备可分度量描述的拓扑空间。典型例子包括

$$\mathbb{R}, \quad \mathbb{R}^d, \quad C[0, 1].$$

Polish 空间经过 Borel 化之后，得到标准 Borel 空间：

$$S \text{ Polish} \implies (S, \mathcal{B}(S)) \text{ 是标准 Borel 空间.}$$

标准 Borel 空间的重要性在于：它既足够一般，可以容纳现代概率论中常见的取值空间；又足够规整，使许多关键结构能够良好存在，例如分布、概率核、正则条件分布、Markov 过程和可测选择。

如果只在任意可测空间中工作，很多结论可能失败。标准 Borel 空间排除了许多病态情形，因此成为现代概率论最常用的取值空间框架。可以把这条逻辑概括为：

$$\boxed{\text{Polish 空间} \implies \text{Borel 化} \implies \text{标准 Borel 空间} \implies \text{良好的随机对象取值空间}}$$

■ 可测选择与正则化思想

本章最后讨论了可测选择和正则化思想。它们说明现代概率论不仅关心对象是否存在，还关心对象是否能以可测的方式存在。

设

$$\Gamma : X \rightrightarrows Y$$

是一个集值映射，也就是说，每个 $x \in X$ 对应一个集合

$$\Gamma(x) \subset Y.$$

一个选择函数是指

$$f : X \rightarrow Y$$

满足

$$f(x) \in \Gamma(x), \quad x \in X.$$

如果进一步要求 f 是可测映射，那么 f 称为可测选择。

可测选择的重要性在于：在概率论中，如果 $Z : \Omega \rightarrow X$ 是随机元素，而 $f : X \rightarrow Y$ 不是可测函数，那么复合

$$f(Z)$$

可能根本不是随机元素。因此，在随机优化、随机控制、条件分布和正则化理论中，我们不仅需要选出对象，还需要以可测方式选出对象。

Kuratowski–Ryll–Nardzewski 可测选择定理说明，在 Polish 目标空间中，对于适当可测的非空闭值集值映射，可以选出可测选择。这背后的思想可以概括为：

$$\boxed{\text{抽象存在} \implies \text{可测版本} \implies \text{可操作对象}}$$

条件期望、正则条件分布、随机过程的连续版本或右连续版本，本质上都体现了这种正则化思想。它们的共同目标是把原本只在某种弱意义下存在的对象，替换成一个可以继续概率运算的可测版本。

■ 本章主线总结

第一章的全部内容可以压缩成如下逻辑链：

$$\Omega \implies (\Omega, \mathcal{F}) \implies X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S}) \implies \mathbb{P}(X \in B).$$

其中每一步都有明确含义：

$$\Omega$$

给出所有可能结果；

$$\mathcal{F}$$

规定哪些子集是合法事件；

$$X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$$

要求随机变量是可测映射；

$$X^{-1}(B) \in \mathcal{F}$$

保证关于随机变量的事件是合法事件；

$$\mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B))$$

把取值空间中的条件转化为样本空间中的概率计算；

$$\mu_X = \mathbb{P} \circ X^{-1}$$

把样本空间上的概率推出为取值空间上的分布。

因此，本章的中心思想可以写成：

概率论从可测结构开始，是因为概率只能定义在可测事件上。

更进一步：

随机变量必须是可测映射，是因为它必须把取值空间中的可测集合拉回为样本空间中的事件。

最终：

现代概率论研究的不是孤立的随机数，而是可测空间之间的结构保持映射。

■ 一句话总结

本章的三句核心结论是：

随机变量 = 可测映射

分布 = 概率测度在随机变量下的推出测度

随机过程 = 函数空间中的随机元素

所以，概率论之所以从可测结构开始，并不是为了形式化而形式化，而是因为只有先规定哪些集合可以被测量，哪些映射可以保持可测性，哪些路径事件可以被讨论，后面的概率、分布、期望、条件概率、随机过程和极限定理才有严格的数学意义。

■ 练习

1. 解释为什么在一般样本空间中，不能总是直接令所有子集都是事件。

2. 设 $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 是实值随机变量。说明为什么

$$\mathbb{P}(X \leq t)$$

实际上是

$$\mathbb{P}(X^{-1}((-\infty, t])).$$

3. 证明若 X 是实值随机变量，则

$$\{a < X < b\} \in \mathcal{F}.$$

4. 用一句话解释为什么原像比像在概率论中更重要。

5. 设 $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (S, \mathcal{S})$ 是随机元素。定义

$$\mu_X(B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{S}.$$

证明 μ_X 是 $(S, \mathcal{S})$ 上的概率测度。

6. 解释为什么

$$\mathcal{B}(\mathbb{R}) = \sigma((-\infty, t] : t \in \mathbb{R})$$

使得我们可以用事件 $\{X \leq t\}$ 判别实值随机变量的可测性。

7. 设 X, Y 是实值随机变量。说明为什么 (X, Y) 是 $\mathbb{R}^2$ 值随机向量。

8. 设 $X : \Omega \rightarrow C[0, 1]$ 是连续路径随机过程。解释为什么事件

$$\left\{ \sup_{t \in [0, 1]} X_t > a \right\}$$

是可测事件。

9. 用一句话说明 Polish 空间和标准 Borel 空间的区别。
10. 用一句话解释为什么可测选择可以看作一种正则化思想。

第 2 章

测度与积分

2.1 外测度与 Carathéodory 构造

第一章中我们已经看到，现代概率论并不是直接把概率赋给任意集合，而是先指定一个事件系统，也就是一个 σ -代数。概率测度只定义在这个 σ -代数上。因此，进入测度论以后，一个自然的问题是：

如何从直观的长度、面积或大小概念出发，严格构造一个测度？

Carathéodory 构造给出了一个非常基本而强大的答案。它的思想可以概括为：

先在所有子集上定义外测度，再筛选出可测集合，最后在这些集合上得到真正的测度。

■ 外测度

设 Ω 是一个集合。一个函数

$$\mu^* : 2^\Omega \rightarrow [0, \infty]$$

称为 Ω 上的一个外测度，如果它满足以下三条性质：

1. 空集测度为零：

$$\mu^*(\emptyset) = 0.$$

2. 单调性：若 $A \subset B \subset \Omega$ ，则

$$\mu^*(A) \leq \mu^*(B).$$

3. 可数次可加性：对任意集合列 $A_1, A_2, \dots \subset \Omega$ ，有

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu^*(A_n).$$

这里“可数次可加性”指的是 countable subadditivity。它只给出一个不等式，而不要求互不相交集的测度严格相加。

注意，外测度定义在所有子集 2^Ω 上，但它一般不是测度。它只是给每个集合一个从外部观察到的大小。这也是“外”这个字的含义：我们先不判断集合本身是否足够规则，而是先用覆盖或其他方式从外部估计它的大小。

■ Lebesgue 外测度

最重要的例子来自实数轴上的长度。对任意集合 $A \subset \mathbb{R}$ ，定义

$$m^*(A) = \inf \left\{ \sum_{n=1}^{\infty} (b_n - a_n) : A \subset \bigcup_{n=1}^{\infty} (a_n, b_n) \right\}.$$

也就是说，我们用可数多个开区间 (a_n, b_n) 覆盖 A ，然后取这些开区间总长度的下确界。

直观地说，

$$m^*(A) = \text{从外面覆盖 } A \text{ 所需要的最小总长度.}$$

这个 m^* 称为 Lebesgue 外测度。

例如，

$$m^*((a, b)) = b - a,$$

$$m^*({x}) = 0,$$

并且

$$m^*(\mathbb{Q} \cap [0, 1]) = 0.$$

虽然 $\mathbb{Q} \cap [0, 1]$ 在 $[0, 1]$ 中稠密，但它是可数集。可数集可以被总长度任意小的开区间列覆盖，因此其 Lebesgue 外测度为零。

■ 为什么外测度还不够

如果 μ 是一个真正的测度，那么对于两两不交的集合列 $E_1, E_2, \dots$ ，应该有

$$\mu \left(\bigcup_{n=1}^{\infty} E_n \right) = \sum_{n=1}^{\infty} \mu(E_n).$$

但是外测度只保证

$$\mu^* \left(\bigcup_{n=1}^{\infty} E_n \right) \leq \sum_{n=1}^{\infty} \mu^*(E_n).$$

也就是说，外测度只有次可加性，而没有真正的可数可加性。

因此，外测度定义在所有子集上虽然很方便，但它太粗糙。我们不能期待所有子集都表现得像良好的可测集合。Carathéodory 的思想是：不强行让所有集合都可测，而是从所有集合中筛选出那些与外测度相容的好集合。

■ Carathéodory 可测性

设 μ^* 是 Ω 上的一个外测度。集合 $E \subset \Omega$ 称为 μ^* -可测的, 如果对任意集合 $A \subset \Omega$, 都有

$$\mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c).$$

这个条件称为 Carathéodory 条件。

直观地说, E 是可测的, 意味着它可以无损地切割任意集合 A 。由于

$$A = (A \cap E) \cup (A \cap E^c),$$

并且两部分互不相交, 我们希望一个良好的集合 E 能够使外测度在这种切割下表现得像真正的加法。

外测度的次可加性总是给出

$$\mu^*(A) \leq \mu^*(A \cap E) + \mu^*(A \cap E^c).$$

因此, Carathéodory 条件的实质在于要求反方向不等式也成立。也就是说, E 可测当且仅当这种切割没有产生任何额外的测度缺陷。

可以定义缺陷量

$$\delta_E(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c) - \mu^*(A).$$

由次可加性可知

$$\delta_E(A) \geq 0.$$

于是

$$E \text{ 是 } \mu^* \text{-可测的} \iff \delta_E(A) = 0, \quad A \subset \Omega.$$

■ Carathéodory 构造定理

令

$$\mathcal{M} = \{E \subset \Omega : E \text{ 满足 Carathéodory 条件}\}.$$

也就是说, $\mathcal{M}$ 是所有 μ^* -可测集合组成的集合族。

Carathéodory 构造定理. 设 μ^* 是 Ω 上的一个外测度。则所有 μ^* -可测集合组成的集合族 $\mathcal{M}$ 是一个 σ -代数, 并且 μ^* 限制在 $\mathcal{M}$ 上以后成为一个测度。也就是说, 若定义

$$\mu = \mu^*|_{\mathcal{M}},$$

则

$$(\Omega, \mathcal{M}, \mu)$$

是一个测度空间。

这个定理说明, 外测度虽然在所有子集上未必可加, 但它自动诱导出一个良好的可测世界。在这个世界中, 外测度变成真正的测度。

$$\text{外测度} \implies \text{Carathéodory 可测集} \implies \text{测度}.$$

■ 证明思路

完整证明较长，但核心结构可以分成两步。

第一步，证明 $\mathcal{M}$ 是一个 σ -代数。这需要证明：

$$\Omega \in \mathcal{M},$$

若 $E \in \mathcal{M}$ ，则

$$E^c \in \mathcal{M},$$

若 $E_1, E_2, \dots \in \mathcal{M}$ ，则

$$\bigcup_{n=1}^{\infty} E_n \in \mathcal{M}.$$

补集封闭性来自 Carathéodory 条件本身的对称性，因为 E 和 E^c 对 A 的切割只是交换了两部分：

$$A \cap E, \quad A \cap E^c.$$

有限并和可数并的封闭性则来自对集合进行逐层切割。若 E 和 F 都是可测的，那么先用 E 切割 A ，再用 F 切割每一部分，可以证明 $E \cup F$ 仍然满足 Carathéodory 条件。通过归纳和极限过程，可进一步得到可数并封闭性。

第二步，证明 μ^* 在 $\mathcal{M}$ 上满足可数可加性。设 $E_1, E_2, \dots \in \mathcal{M}$ 两两不交。外测度的次可加性给出

$$\mu^* \left(\bigcup_{n=1}^{\infty} E_n \right) \leq \sum_{n=1}^{\infty} \mu^*(E_n).$$

另一方面，由每个 E_n 的可测性，可以反复切割集合 $\bigcup_{n=1}^{\infty} E_n$ ，得到对任意 N ，

$$\mu^* \left(\bigcup_{n=1}^{\infty} E_n \right) \geq \sum_{n=1}^N \mu^*(E_n).$$

令 $N \rightarrow \infty$ ，得到

$$\mu^* \left(\bigcup_{n=1}^{\infty} E_n \right) \geq \sum_{n=1}^{\infty} \mu^*(E_n).$$

两边合起来，得到

$$\mu^* \left(\bigcup_{n=1}^{\infty} E_n \right) = \sum_{n=1}^{\infty} \mu^*(E_n).$$

因此， μ^* 限制在 $\mathcal{M}$ 上以后是一个测度。

■ 零外测度集一定可测

一个非常重要的结论是：若集合 $N \subset \Omega$ 满足

$$\mu^*(N) = 0,$$

则 N 一定是 μ^* -可测的。

事实上, 对任意 $A \subset \Omega$, 因为

$$A \cap N \subset N,$$

由单调性得到

$$\mu^*(A \cap N) \leq \mu^*(N) = 0.$$

因此

$$\mu^*(A \cap N) = 0.$$

另一方面, 由外测度的次可加性,

$$\mu^*(A) \leq \mu^*(A \cap N) + \mu^*(A \cap N^c) = \mu^*(A \cap N^c).$$

又因为

$$A \cap N^c \subset A,$$

由单调性得到

$$\mu^*(A \cap N^c) \leq \mu^*(A).$$

于是

$$\mu^*(A) = \mu^*(A \cap N^c).$$

因此

$$\mu^*(A) = \mu^*(A \cap N) + \mu^*(A \cap N^c).$$

这正是 Carathéodory 条件, 所以 N 是 μ^* -可测的。

特别地, Lebesgue 外测度为零的集合都是 Lebesgue 可测的, 并且它们的任意子集也都是 Lebesgue 可测的。这一点与测度完成化密切相关。

■ Lebesgue 测度的构造

在 $\mathbb{R}$ 上, 从 Lebesgue 外测度

$$m^*(A) = \inf \left\{ \sum_{n=1}^{\infty} (b_n - a_n) : A \subset \bigcup_{n=1}^{\infty} (a_n, b_n) \right\}$$

出发, 考虑所有满足 Carathéodory 条件的集合。它们组成一个 σ -代数, 记作

$$\mathcal{L}.$$

$\mathcal{L}$ 中的集合称为 Lebesgue 可测集。

把 m^* 限制到 $\mathcal{L}$ 上, 得到

$$m = m^*|_{\mathcal{L}}.$$

这就是实数轴上的 Lebesgue 测度。它满足

$$m((a, b)) = b - a,$$

并且比 Borel 测度更大, 因为它不仅包含所有 Borel 集, 还包含所有零测集的任意子集。

■ 与局部对象的类比

Carathéodory 条件也可以从一种局部化或正交性的角度理解。对一个集合 $E \subset \Omega$ ，定义

$$\delta_E(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c) - \mu^*(A).$$

这个量描述了用 E 切割 A 时，外测度的加法缺陷。外测度的次可加性说明

$$\delta_E(A) \geq 0.$$

而 E 是 Carathéodory 可测的，当且仅当

$$\delta_E(A) = 0, \quad A \subset \Omega.$$

也就是说， E 对所有测试集合 A 都看不见这个加法缺陷。在这个意义下，Carathéodory 可测集可以理解为那些使外测度的切割缺陷消失的对象。

这同伦论或同调代数中的局部对象有一种形式上的相似性。若 W 是一类弱等价， Z 是 W -local object，则对每个 $w : X \rightarrow Y$ ，映射空间诱导的映射

$$\text{Map}(Y, Z) \rightarrow \text{Map}(X, Z)$$

成为等价。也就是说， Z 看不见 w 的缺陷，在 Z 的眼里， w 已经表现为等价。

类似地，Carathéodory 可测集合 E 可以看作对外测度 μ^* 而言的良好切割对象。它使得任意集合 A 的分解

$$A = (A \cap E) \cup (A \cap E^c)$$

在 μ^* 的眼里表现为严格加法：

$$\mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c).$$

因此，Carathéodory 构造的思想可以概括为：

从所有集合中筛出对外测度加法缺陷不可见的集合。

这些集合组成一个 σ -代数，并且在这个 σ -代数上，外测度变成真正的测度。

■ 本节小结

本节的核心逻辑是：

$$\text{外测度} \implies \text{Carathéodory 可测集} \implies \text{测度}.$$

外测度 μ^* 定义在所有子集上，满足空集为零、单调性和可数次可加性，但一般不满足真正的可数可加性。

Carathéodory 条件要求集合 E 能够无损切割任意集合 A ：

$$\mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c).$$

所有满足这个条件的集合组成一个 σ -代数。在这个 σ -代数上，外测度限制后成为真正的测度。

Carathéodory 构造把粗糙的外测度世界，筛成一个可加的可测世界。

■ 练习

1. 设 μ^* 是外测度。证明若 $A \subset B$ ，则 $\mu^*(A) \leq \mu^*(B)$ 不能由空集为零和可数次可加性自动推出，因此单调性必须作为定义的一部分保留。
2. 证明 Lebesgue 外测度满足平移不变性：
$$m^*(A+x) = m^*(A), \quad x \in \mathbb{R}.$$
3. 证明任意可数集 $N \subset \mathbb{R}$ 的 Lebesgue 外测度为零。
4. 设 $E \subset \Omega$ 满足 Carathéodory 条件。证明 E^c 也满足 Carathéodory 条件。
5. 设 $\mu^*(N) = 0$ 。证明 N 的任意子集也都是 μ^* -可测的。
6. 用一句话解释：为什么外测度可以定义在所有子集上，但测度通常只能定义在筛选出的 σ -代数上？

2.2 测度空间与测度的基本性质

上一节中，我们从外测度出发，介绍了 Carathéodory 构造。它的核心思想是：先在所有子集上定义外测度，再筛选出可测集合，最后在这些可测集合上得到真正的测度。也就是说，上一节的逻辑是

$$\text{外测度} \implies \text{Carathéodory 可测集} \implies \text{测度}.$$

本节正式定义测度空间，并讨论测度最基本、也最常用的一组性质。这些性质看起来像集合代数中的普通运算规则，但它们实际上都来自一个核心公理：可数可加性。

■ 测度的定义

设 $(\Omega, \mathcal{F})$ 是一个可测空间。一个函数

$$\mu : \mathcal{F} \rightarrow [0, \infty]$$

称为 $\mathcal{F}$ 上的一个测度，如果满足以下两个条件：

1. 空集测度为零：

$$\mu(\emptyset) = 0.$$

2. 可数可加性：若 $A_1, A_2, \dots \in \mathcal{F}$ 两两不交，即

$$A_i \cap A_j = \emptyset, \quad i \neq j,$$

则

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

这里的可数可加性是测度最核心的性质。它说明：如果一组集合互不重叠，那么它们并集的大小等于各部分大小之和。第一章中概率的可加性，在测度论中正是这一条公理的特殊情形。

■ 测度空间

若 Ω 是一个集合， $\mathcal{F}$ 是 Ω 上的一个 σ -代数， μ 是定义在 $\mathcal{F}$ 上的测度，则三元组

$$(\Omega, \mathcal{F}, \mu)$$

称为一个测度空间。其中：

$$\Omega$$

表示底层空间，

$$\mathcal{F}$$

表示哪些集合允许被测量，

$$\mu$$

表示这些可测集合的大小。

因此，测度空间可以理解为

$$\text{测度空间} = \text{可测空间} + \text{测度}.$$

也就是说， $(\Omega, \mathcal{F})$ 只告诉我们哪些集合是可测的，而 $(\Omega, \mathcal{F}, \mu)$ 进一步告诉我们这些集合的大小是多少。

■ 有限测度与概率测度

若测度空间 $(\Omega, \mathcal{F}, \mu)$ 满足

$$\mu(\Omega) < \infty,$$

则称 μ 是有限测度，也称 $(\Omega, \mathcal{F}, \mu)$ 是有限测度空间。

若测度空间 $(\Omega, \mathcal{F}, \mu)$ 满足

$$\mu(\Omega) = 1,$$

则称 μ 是概率测度。此时通常把 μ 记作 $\mathbb{P}$ ，并把

$$(\Omega, \mathcal{F}, \mathbb{P})$$

称为概率空间。

所以，概率测度只是测度的一种特殊情形。概率论中的总质量为 1，而一般测度论中的总质量可以是任意非负数，也可以是无穷大。

$$\text{概率空间} = \text{总质量为1的测度空间}.$$

■ 外测度与测度的区别

上一节中的外测度通常定义在所有子集上:

$$\mu^* : 2^\Omega \rightarrow [0, \infty].$$

外测度满足的是可数次可加性, 也就是对任意集合列 $A_1, A_2, \dots \subset \Omega$, 都有

$$\mu^* \left(\bigcup_{n=1}^{\infty} A_n \right) \leq \sum_{n=1}^{\infty} \mu^*(A_n).$$

而测度 μ 定义在一个 σ -代数 $\mathcal{F}$ 上, 并且当 $A_1, A_2, \dots$ 两两不交时, 满足真正的可数可加性:

$$\mu \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mu(A_n).$$

因此, 外测度和测度的区别可以概括为:

外测度: 定义域大, 但只有次可加性;

测度: 定义域经过筛选, 但具有真正的可数可加性。

这一点也解释了 Carathéodory 构造为什么要先筛选可测集。如果强行要求所有子集都可测, 在很多自然情形下会破坏可数可加性; 如果愿意只在一个合适的 σ -代数上工作, 就可以保留严格的加法结构。

■ 测度的基本性质

下面讨论测度的若干基本性质。这些性质本质上都来自可数可加性, 是后面证明积分收敛定理、概率极限定理和条件期望性质时反复使用的工具。

有限可加性. 若 $A_1, \dots, A_n \in \mathcal{F}$ 两两不交, 则

$$\mu \left(\bigcup_{k=1}^n A_k \right) = \sum_{k=1}^n \mu(A_k).$$

证明如下。令

$$A_{n+1} = A_{n+2} = \dots = \emptyset.$$

则 $A_1, A_2, \dots$ 两两不交。由可数可加性,

$$\mu \left(\bigcup_{k=1}^n A_k \right) = \mu \left(\bigcup_{k=1}^{\infty} A_k \right) = \sum_{k=1}^{\infty} \mu(A_k) = \sum_{k=1}^n \mu(A_k).$$

单调性. 若 $A, B \in \mathcal{F}$ 且

$$A \subset B,$$

则

$$\mu(A) \leq \mu(B).$$

因为 $A \subset B$, 所以可以把 B 分解为

$$B = A \cup (B \setminus A),$$

且 A 与 $B \setminus A$ 不交。由有限可加性,

$$\mu(B) = \mu(A) + \mu(B \setminus A).$$

由于测度非负,

$$\mu(B \setminus A) \geq 0.$$

因此

$$\mu(B) \geq \mu(A).$$

单调性的直观含义是: 集合包含的点越多, 其测度不会变小。

差集公式. 若 $A, B \in \mathcal{F}$, $A \subset B$, 并且

$$\mu(A) < \infty,$$

则

$$\mu(B \setminus A) = \mu(B) - \mu(A).$$

由

$$B = A \cup (B \setminus A)$$

且两部分不交, 可得

$$\mu(B) = \mu(A) + \mu(B \setminus A).$$

由于 $\mu(A) < \infty$, 可以在等式两边减去 $\mu(A)$, 于是

$$\mu(B \setminus A) = \mu(B) - \mu(A).$$

这里必须要求 $\mu(A) < \infty$ 。如果 $\mu(A) = \infty$, 表达式

$$\infty - \infty$$

没有定义, 因此不能直接相减。

可数次可加性. 对任意 $A_1, A_2, \dots \in \mathcal{F}$, 不要求两两不交, 都有

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n).$$

定义

$$B_1 = A_1,$$

并且对 $n \geq 2$, 令

$$B_n = A_n \setminus \bigcup_{k=1}^{n-1} A_k.$$

则 $B_1, B_2, \dots$ 两两不交, 并且

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

由可数可加性,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mu(B_n).$$

又因为

$$B_n \subset A_n,$$

由单调性可得

$$\mu(B_n) \leq \mu(A_n).$$

因此

$$\sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n),$$

所以

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n).$$

这说明, 测度不仅对不交并具有加性, 对一般并集也具有次可加性。

■ 测度的连续性

测度还有两个非常重要的连续性性质: 从下连续性和从上连续性。这里的“连续性”不是拓扑意义下的函数连续性, 而是指测度与单调极限之间可以交换。

从下连续性. 若

$$A_1 \subset A_2 \subset A_3 \subset \dots$$

且

$$A = \bigcup_{n=1}^{\infty} A_n,$$

则

$$\mu(A) = \lim_{n \rightarrow \infty} \mu(A_n).$$

令

$$B_1 = A_1,$$

并且对 $n \geq 2$, 定义

$$B_n = A_n \setminus A_{n-1}.$$

则 $B_1, B_2, \dots$ 两两不交, 并且

$$A = \bigcup_{n=1}^{\infty} B_n.$$

同时,

$$A_N = \bigcup_{n=1}^N B_n.$$

由可数可加性,

$$\mu(A) = \sum_{n=1}^{\infty} \mu(B_n),$$

而

$$\mu(A_N) = \sum_{n=1}^N \mu(B_n).$$

令 $N \rightarrow \infty$, 得到

$$\lim_{N \rightarrow \infty} \mu(A_N) = \sum_{n=1}^{\infty} \mu(B_n) = \mu(A).$$

从下连续性的直观含义是: 如果集合越来越大并逼近一个极限集合, 那么它们的测度也会越来越大并逼近极限集合的测度。常记作

$$A_n \uparrow A \implies \mu(A_n) \uparrow \mu(A).$$

从上连续性. 若

$$A_1 \supset A_2 \supset A_3 \supset \cdots$$

且

$$A = \bigcap_{n=1}^{\infty} A_n,$$

并且

$$\mu(A_1) < \infty,$$

则

$$\mu(A) = \lim_{n \rightarrow \infty} \mu(A_n).$$

令

$$B_n = A_1 \setminus A_n.$$

因为

$$A_1 \supset A_2 \supset A_3 \supset \cdots,$$

所以

$$B_1 \subset B_2 \subset B_3 \subset \cdots.$$

并且

$$\bigcup_{n=1}^{\infty} B_n = A_1 \setminus \bigcap_{n=1}^{\infty} A_n = A_1 \setminus A.$$

由从下连续性,

$$\mu(A_1 \setminus A) = \lim_{n \rightarrow \infty} \mu(A_1 \setminus A_n).$$

由于 $A_n \subset A_1$ 且 $\mu(A_1) < \infty$, 由差集公式,

$$\mu(A_1 \setminus A_n) = \mu(A_1) - \mu(A_n).$$

同理,

$$\mu(A_1 \setminus A) = \mu(A_1) - \mu(A).$$

因此

$$\mu(A_1) - \mu(A) = \lim_{n \rightarrow \infty} (\mu(A_1) - \mu(A_n)).$$

由于 $\mu(A_1) < \infty$, 可以消去 $\mu(A_1)$, 得到

$$\mu(A) = \lim_{n \rightarrow \infty} \mu(A_n).$$

从上连续性必须要求 $\mu(A_1) < \infty$. 否则结论可能失败。例如在实数轴上的 Lebesgue 测度中, 令

$$A_n = [n, \infty).$$

则

$$A_1 \supset A_2 \supset A_3 \supset \cdots,$$

并且

$$\bigcap_{n=1}^{\infty} A_n = \emptyset.$$

但是对每个 n , 都有

$$m(A_n) = \infty.$$

所以

$$\lim_{n \rightarrow \infty} m(A_n) = \infty,$$

而

$$m(\emptyset) = 0.$$

因此若没有有限性条件, 从上连续性不一定成立。

■ 容斥公式

若 $A, B \in \mathcal{F}$, 且相关测度有限, 则

$$\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B).$$

证明如下。将 $A \cup B$ 分解为

$$A \cup B = A \cup (B \setminus A),$$

且两部分不交。因此

$$\mu(A \cup B) = \mu(A) + \mu(B \setminus A).$$

另一方面,

$$B = (B \setminus A) \cup (A \cap B),$$

且两部分不交。因此

$$\mu(B) = \mu(B \setminus A) + \mu(A \cap B).$$

所以

$$\mu(B \setminus A) = \mu(B) - \mu(A \cap B).$$

代入前式, 得到

$$\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B).$$

在概率论中, 这正是熟悉的公式:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

■ 重要例子

计数测度. 设 Ω 是任意集合, 取

$$\mathcal{F} = 2^\Omega.$$

定义

$$\mu(A) = \#A.$$

如果 A 是有限集, 则 $\mu(A)$ 是 A 的元素个数; 如果 A 是无限集, 则

$$\mu(A) = \infty.$$

这个测度称为计数测度。计数测度把集合的大小理解为其中元素的个数。

Dirac 测度. 固定一点 $x_0 \in \Omega$ 。定义

$$\delta_{x_0}(A) = \begin{cases} 1, & x_0 \in A, \\ 0, & x_0 \notin A. \end{cases}$$

则 δ_{x_0} 是一个测度, 称为集中在 x_0 的 Dirac 测度。Dirac 测度表示所有质量都集中在一个点上。在概率论中, 它可以表示确定性随机变量:

$$X = x_0 \text{ almost surely.}$$

Lebesgue 测度. 在实数轴 $\mathbb{R}$ 上, Lebesgue 测度 m 满足

$$m((a, b)) = b - a.$$

它把区间的测度解释为长度。Lebesgue 测度是分析和概率论中最重要的测度之一。

概率测度. 若测度 $\mathbb{P}$ 满足

$$\mathbb{P}(\Omega) = 1,$$

则 $\mathbb{P}$ 是概率测度。此时

$$(\Omega, \mathcal{F}, \mathbb{P})$$

称为概率空间。概率测度可以看作总质量为 1 的测度。

■ 与积分和期望的关系

本章后面将进入积分理论。测度之所以重要，是因为积分要写成

$$\int f d\mu.$$

这里的 $d\mu$ 表示我们用测度 μ 来给空间中的不同部分加权。

在概率论中，若 X 是随机变量，则它的期望可以写成

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

因此，期望其实就是以概率测度 $\mathbb{P}$ 为权重的 Lebesgue 积分。

所以本章的逻辑链是：

$$\text{测度} \implies \text{积分} \implies \text{期望}.$$

■ 本节小结

本节的核心内容可以总结如下。首先，测度空间是三元组

$$(\Omega, \mathcal{F}, \mu).$$

其中 Ω 是底层集合， $\mathcal{F}$ 是 σ -代数， μ 是定义在 $\mathcal{F}$ 上的测度。

其次，测度最核心的公理是可数可加性：

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n),$$

其中 $A_1, A_2, \dots$ 两两不交。

再次，测度具有许多基本性质，包括有限可加性、单调性、差集公式、可数次可加性、从下连续性和从上连续性。

最后，概率测度是总质量为 1 的测度。概率空间

$$(\Omega, \mathcal{F}, \mathbb{P})$$

只是测度空间的一个特殊情形。

本节最重要的一句话是：

$\mathcal{F}$ 负责“能不能测”， μ 负责“测出来是多少”。

■ 练习

1. 设 μ 是测度。证明若 $A \subset B$ ，则 $\mu(A) \leq \mu(B)$ 。

2. 设 $A \subset B$ 且 $\mu(A) < \infty$ 。证明

$$\mu(B \setminus A) = \mu(B) - \mu(A).$$

3. 设 $A_1, A_2, \dots \in \mathcal{F}$ 。证明

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n).$$

4. 设

$$A_1 \subset A_2 \subset \dots$$

并且

$$A = \bigcup_{n=1}^{\infty} A_n.$$

证明

$$\mu(A) = \lim_{n \rightarrow \infty} \mu(A_n).$$

5. 设

$$A_1 \supset A_2 \supset \dots$$

并且

$$A = \bigcap_{n=1}^{\infty} A_n.$$

解释为什么从上连续性需要条件 $\mu(A_1) < \infty$ 。

6. 证明 Dirac 测度 δ_{x_0} 是测度。

7. 设 $\Omega = \mathbb{N}$, $\mathcal{F} = 2^{\mathbb{N}}$, μ 是计数测度。求

$$\mu(\{1, 2, 3\}), \quad \mu(2\mathbb{N}), \quad \mu(\emptyset).$$

8. 用一句话解释：为什么概率测度是测度的特殊情形？

9. 用一句话解释： $\mathcal{F}$ 和 μ 在测度空间中分别起什么作用？

10. 说明为什么期望可以看作关于概率测度的积分。

2.3 简单函数与非负可测函数积分

上一节中，我们已经建立了测度空间的基本语言。一个测度空间写作

$$(\Omega, \mathcal{F}, \mu),$$

其中 Ω 是底层空间， $\mathcal{F}$ 是 Ω 上的 σ -代数， μ 是定义在 $\mathcal{F}$ 上的测度。

测度告诉我们如何给集合赋予大小。现在我们进一步希望给函数赋予“总量”。也就是说，我们希望定义

$$\int_{\Omega} f d\mu.$$

这就是积分理论的起点。

Lebesgue 积分的构造思路是：先对最简单的函数定义积分，再用这些简单函数去逼近一般的非负可测函数。因此，本节的核心逻辑是

$$\text{指示函数} \implies \text{简单函数} \implies \text{非负可测函数积分}.$$

■ 指示函数

设 $A \in \mathcal{F}$ 。定义集合 A 的指示函数为

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

指示函数是最基本的可测函数。它只记录样本点是否属于集合 A 。

由于 $\mathbf{1}_A$ 在集合 A 上取值为 1，在补集 A^c 上取值为 0，所以它的积分自然应该等于集合 A 的测度：

$$\int_{\Omega} \mathbf{1}_A d\mu = \mu(A).$$

这说明，测度可以看作指示函数积分的特殊情形。换句话说，积分是测度的推广。集合的大小可以写成

$$\mu(A) = \int_{\Omega} \mathbf{1}_A d\mu.$$

■ 简单函数

在测度论中，简单函数是指只取有限多个值的可测函数。设

$$s : \Omega \rightarrow [0, \infty)$$

是一个非负可测函数。如果 s 只取有限多个非负值，则称 s 是非负简单函数。

若 s 的取值为

$$a_1, \dots, a_n,$$

并令

$$A_i = \{\omega \in \Omega : s(\omega) = a_i\},$$

则每个 $A_i \in \mathcal{F}$ ，并且

$$\Omega = \bigcup_{i=1}^n A_i, \quad A_i \cap A_j = \emptyset, \quad i \neq j.$$

于是 s 可以写成

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}.$$

这种表示称为简单函数的标准表示。

直观地说，简单函数就是一个有限阶梯函数。它把空间 Ω 分成有限多个可测区域，在每个区域上取一个固定高度。后面一般可测函数的积分，正是从这种有限阶梯函数出发构造出来的。

■ 简单函数的积分

设非负简单函数 s 写成

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i},$$

其中

$$a_i \geq 0, \quad A_i \in \mathcal{F},$$

并且 $A_1, \dots, A_n$ 两两不交。定义 s 关于测度 μ 的积分为

$$\int_{\Omega} s d\mu = \sum_{i=1}^n a_i \mu(A_i).$$

这个定义的含义非常清楚：在集合 A_i 上，函数的高度是 a_i ，底部大小是 $\mu(A_i)$ ，因此这一块的贡献是

$$a_i \mu(A_i).$$

把所有块加起来，就得到简单函数的积分。

特别地，如果

$$s = a \mathbf{1}_A,$$

那么

$$\int_{\Omega} s d\mu = a \mu(A).$$

当 $a = 1$ 时，就回到指示函数的情形：

$$\int_{\Omega} \mathbf{1}_A d\mu = \mu(A).$$

■ 简单函数积分的良好定义性

一个简单函数可能有不同的表示。例如，同一个函数可以通过不同的可测分割写出来。因此我们需要说明：简单函数积分的值不依赖于具体表示。

设

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i} = \sum_{j=1}^m b_j \mathbf{1}_{B_j},$$

其中 $\{A_i\}$ 和 $\{B_j\}$ 都是有限可测分割。考虑公共细分

$$C_{ij} = A_i \cap B_j.$$

这些集合两两不交，并且仍然是可测集合。在 C_{ij} 上，函数 s 同时等于 a_i 和 b_j 。因此，只要 $C_{ij} \neq \emptyset$ ，就有

$$a_i = b_j.$$

于是

$$\sum_{i=1}^n a_i \mu(A_i) = \sum_{i,j} a_i \mu(C_{ij}) = \sum_{i,j} b_j \mu(C_{ij}) = \sum_{j=1}^m b_j \mu(B_j).$$

所以简单函数的积分不依赖于具体表示，定义是良好的。

■ 简单函数积分的基本性质

设 s, t 是非负简单函数, $c \geq 0$ 。则简单函数积分满足以下基本性质。

齐次性:

$$\int_{\Omega} cs \, d\mu = c \int_{\Omega} s \, d\mu.$$

加性:

$$\int_{\Omega} (s + t) \, d\mu = \int_{\Omega} s \, d\mu + \int_{\Omega} t \, d\mu.$$

单调性: 若

$$0 \leq s \leq t,$$

则

$$\int_{\Omega} s \, d\mu \leq \int_{\Omega} t \, d\mu.$$

此外, 若 $E \in \mathcal{F}$, 则可以定义在集合 E 上的积分:

$$\int_E s \, d\mu = \int_{\Omega} s \mathbf{1}_E \, d\mu.$$

如果

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i},$$

那么

$$\int_E s \, d\mu = \sum_{i=1}^n a_i \mu(A_i \cap E).$$

■ 非负可测函数的积分

现在设

$$f : \Omega \rightarrow [0, \infty]$$

是非负可测函数。它不一定只取有限多个值, 因此不一定是简单函数。

Lebesgue 积分的思想是: 用所有不超过 f 的非负简单函数从下面逼近 f 。定义

$$\int_{\Omega} f \, d\mu = \sup \left\{ \int_{\Omega} s \, d\mu : 0 \leq s \leq f, s \text{ 是非负简单函数} \right\}.$$

也就是说, f 的积分被定义为所有下方简单函数积分的上确界。

这个定义允许

$$\int_{\Omega} f \, d\mu = \infty.$$

因此, 非负可测函数的积分总是有定义的, 只是可能等于无穷大。

■ 为什么从下面逼近

对非负函数来说，从下面逼近是最自然的。因为若

$$0 \leq s \leq f,$$

则 s 表示 f 下方的一个阶梯近似。所有这样的简单函数给出的积分都是对 f 总量的低估。取这些低估的上确界，就得到 f 的积分。

这与 Riemann 积分中的下和思想类似，但 Lebesgue 积分的区别在于：它不是按照横轴区间切分，而是按照函数值的层次进行切分。因此，Lebesgue 积分的核心直觉是：

函数值 $\times$ 对应层的测度。

■ 简单函数逼近定理

非负可测函数可以由非负简单函数单调逼近。设

$$f : \Omega \rightarrow [0, \infty]$$

是非负可测函数。则存在一系列非负简单函数 $(s_n)_{n \geq 1}$ ，使得

$$0 \leq s_1 \leq s_2 \leq \cdots \leq f,$$

并且对每个 $\omega \in \Omega$ ，有

$$s_n(\omega) \uparrow f(\omega).$$

一种标准构造如下。定义

$$s_n(\omega) = 2^{-n} \lfloor 2^n (f(\omega) \wedge n) \rfloor.$$

其中

$$f(\omega) \wedge n = \min\{f(\omega), n\}.$$

则每个 s_n 都是非负简单函数，并且

$$s_n(\omega) \uparrow f(\omega).$$

这个定理说明，非负可测函数可以看成简单函数的单调极限。因此，简单函数不仅是积分定义的起点，也是理解一般可测函数的基本积木。

■ 例子：有限概率空间中的期望

设

$$\Omega = \{\omega_1, \omega_2, \omega_3\},$$

并且

$$\mathbb{P}(\{\omega_1\}) = 0.2, \quad \mathbb{P}(\{\omega_2\}) = 0.5, \quad \mathbb{P}(\{\omega_3\}) = 0.3.$$

定义随机变量 X 为

$$X(\omega_1) = 1, \quad X(\omega_2) = 4, \quad X(\omega_3) = 10.$$

则 X 是简单函数，并且可以写成

$$X = 1\mathbf{1}_{\{\omega_1\}} + 4\mathbf{1}_{\{\omega_2\}} + 10\mathbf{1}_{\{\omega_3\}}.$$

于是

$$\int_{\Omega} X d\mathbb{P} = 1 \cdot \mathbb{P}(\{\omega_1\}) + 4 \cdot \mathbb{P}(\{\omega_2\}) + 10 \cdot \mathbb{P}(\{\omega_3\}).$$

代入数值，得到

$$\int_{\Omega} X d\mathbb{P} = 1 \cdot 0.2 + 4 \cdot 0.5 + 10 \cdot 0.3 = 5.2.$$

在概率论中，这个积分正是随机变量 X 的期望：

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

■ 例子：计数测度下的积分

设

$$\Omega = \mathbb{N}, \quad \mathcal{F} = 2^{\mathbb{N}},$$

并令 μ 为计数测度。若 $f: \mathbb{N} \rightarrow [0, \infty]$ ，则

$$\int_{\mathbb{N}} f d\mu = \sum_{n=1}^{\infty} f(n).$$

因此，在计数测度下，Lebesgue 积分退化为级数求和。

例如，若

$$f(n) = \frac{1}{n^2},$$

则

$$\int_{\mathbb{N}} f d\mu = \sum_{n=1}^{\infty} \frac{1}{n^2}.$$

■ 例子：Lebesgue 测度下的指示函数积分

在实数轴上，设 m 是 Lebesgue 测度。若

$$A = (a, b),$$

则

$$\int_{\mathbb{R}} \mathbf{1}_{(a,b)} dm = m((a,b)) = b - a.$$

这说明区间长度可以看作指示函数的 Lebesgue 积分。

更一般地, 若

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i},$$

其中 A_i 是 Lebesgue 可测集, 则

$$\int_{\mathbb{R}} s \, dm = \sum_{i=1}^n a_i m(A_i).$$

■ 本节小结

本节建立了 Lebesgue 积分的第一层定义。

首先, 对指示函数有

$$\int_{\Omega} \mathbf{1}_A \, d\mu = \mu(A).$$

其次, 对非负简单函数

$$s = \sum_{i=1}^n a_i \mathbf{1}_{A_i},$$

定义

$$\int_{\Omega} s \, d\mu = \sum_{i=1}^n a_i \mu(A_i).$$

最后, 对一般非负可测函数 f , 定义

$$\int_{\Omega} f \, d\mu = \sup \left\{ \int_{\Omega} s \, d\mu : 0 \leq s \leq f, s \text{ 是非负简单函数} \right\}.$$

因此, 本节的核心思想可以概括为:

Lebesgue 积分就是用简单函数从下面逼近非负可测函数。

在概率论中, 当 $\mu = \mathbb{P}$ 是概率测度时, 非负随机变量的期望就是它关于 $\mathbb{P}$ 的积分:

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

所以, 从本节开始, 测度论中的积分语言和概率论中的期望语言正式统一起来。

■ 练习

1. 设 $A \in \mathcal{F}$ 。证明 $\mathbf{1}_A$ 是可测函数。
2. 设 $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ 是非负简单函数。说明为什么每个集合 $\{s = a_i\}$ 都属于 $\mathcal{F}$ 。
3. 设 s, t 是非负简单函数。证明

$$\int_{\Omega} (s + t) \, d\mu = \int_{\Omega} s \, d\mu + \int_{\Omega} t \, d\mu.$$

4. 设 $0 \leq s \leq t$, 其中 s, t 是非负简单函数。证明

$$\int_{\Omega} s d\mu \leq \int_{\Omega} t d\mu.$$

5. 设 $f: \Omega \rightarrow [0, \infty]$ 是非负可测函数。解释为什么

$$\int_{\Omega} f d\mu$$

允许取值为 ∞ 。

6. 设 $\Omega = \mathbb{N}$, μ 是计数测度。验证

$$\int_{\mathbb{N}} f d\mu = \sum_{n=1}^{\infty} f(n)$$

对非负函数 $f: \mathbb{N} \rightarrow [0, \infty]$ 成立。

7. 在有限概率空间

$$\Omega = \{\omega_1, \omega_2, \omega_3\}$$

上, 若 $\mathbb{P}(\{\omega_1\}) = 0.1$ 、 $\mathbb{P}(\{\omega_2\}) = 0.2$ 、 $\mathbb{P}(\{\omega_3\}) = 0.7$, 并且 $X(\omega_1) = 2$ 、 $X(\omega_2) = 5$ 、 $X(\omega_3) = 8$, 求 $\mathbb{E}[X]$ 。

8. 用一句话解释: 为什么简单函数是构造 Lebesgue 积分的基本积木?

2.4 Lebesgue 积分与可积函数

上一节中, 我们已经定义了非负可测函数的积分。它的核心思想是: 先对指示函数定义积分, 再对非负简单函数定义积分, 最后用非负简单函数从下方逼近一般非负可测函数。也就是说, 上一节的逻辑是

指示函数 $\implies$ 简单函数 $\implies$ 非负可测函数积分。

本节继续推进这个构造。上一节的积分只直接适用于非负可测函数

$$f: \Omega \rightarrow [0, \infty].$$

但在概率论和实际应用中, 我们经常需要处理可以取正值也可以取负值的函数。例如, 随机收益、误差项、回归残差、金融资产的盈亏都可能为正, 也可能为负。因此, 本节的核心问题是:

如果一个可测函数可以取负值, 那么它的 Lebesgue 积分应该如何定义?

答案是: 把函数分解成正部分和负部分, 然后分别对这两个非负函数积分。

■ 正部分与负部分

设 $(\Omega, \mathcal{F}, \mu)$ 是测度空间, $f: \Omega \rightarrow \mathbb{R}$ 是可测函数。定义 f 的正部分为

$$f^+(\omega) = \max\{f(\omega), 0\},$$

定义 f 的负部分为

$$f^-(\omega) = \max\{-f(\omega), 0\}.$$

显然,

$$f^+ \geq 0, \quad f^- \geq 0.$$

因此, f^+ 与 f^- 都是非负函数。并且若 f 是可测函数, 则 f^+ 和 f^- 也都是可测函数。

正部分和负部分满足两个基本恒等式:

$$f = f^+ - f^-,$$

以及

$$|f| = f^+ + f^-.$$

第一个公式说明, 一个一般实值函数可以写成两个非负函数之差。第二个公式说明, 函数的绝对值等于正贡献和负贡献之和。

■ 一般可测函数的积分

由于 f^+ 与 f^- 都是非负可测函数, 根据上一节的定义, 积分

$$\int_{\Omega} f^+ d\mu$$

和

$$\int_{\Omega} f^- d\mu$$

总是有意义的, 但它们可能等于 $+\infty$ 。

自然地, 我们希望定义

$$\int_{\Omega} f d\mu = \int_{\Omega} f^+ d\mu - \int_{\Omega} f^- d\mu.$$

但是这里有一个问题。如果

$$\int_{\Omega} f^+ d\mu = +\infty$$

并且

$$\int_{\Omega} f^- d\mu = +\infty,$$

那么右边会变成

$$+\infty - \infty,$$

这是没有定义的。因此, 我们不能对所有实值可测函数都无条件定义 Lebesgue 积分。

定义. 设 $f : \Omega \rightarrow \mathbb{R}$ 是可测函数。如果

$$\int_{\Omega} f^{+} d\mu < \infty$$

或者

$$\int_{\Omega} f^{-} d\mu < \infty,$$

则称 $\int_{\Omega} f d\mu$ 有定义, 并定义

$$\int_{\Omega} f d\mu = \int_{\Omega} f^{+} d\mu - \int_{\Omega} f^{-} d\mu.$$

换句话说, 只要正部分积分和负部分积分不同时为 $+\infty$, 我们就可以定义 f 的 Lebesgue 积分。此时积分可能是有限实数, 也可能是 $+\infty$ 或 $-\infty$ 。

■ 可积函数

在很多场景中, 我们不仅希望积分有定义, 还希望积分是一个有限实数。这就引出可积函数的概念。

定义. 若 $f : \Omega \rightarrow \mathbb{R}$ 是可测函数, 并且

$$\int_{\Omega} |f| d\mu < \infty,$$

则称 f 是 Lebesgue 可积的, 或简称 f 可积。此时常记作

$$f \in L^1(\mu).$$

由于

$$|f| = f^{+} + f^{-},$$

所以

$$\int_{\Omega} |f| d\mu = \int_{\Omega} f^{+} d\mu + \int_{\Omega} f^{-} d\mu.$$

因此, f 可积当且仅当

$$\int_{\Omega} f^{+} d\mu < \infty$$

并且

$$\int_{\Omega} f^{-} d\mu < \infty.$$

也就是说, 一个函数可积, 意味着它的正贡献和负贡献都不能无限大。

可积函数的核心条件是

$$\int_{\Omega} |f| d\mu < \infty.$$

■ 积分存在与可积的区别

这里需要区分两个概念。

第一，积分有定义。对于一般实值可测函数 f ，只要

$$\int_{\Omega} f^{+} d\mu$$

和

$$\int_{\Omega} f^{-} d\mu$$

不同时为 $+\infty$ ，就可以定义

$$\int_{\Omega} f d\mu.$$

此时积分可能是有限实数，也可能是 $+\infty$ 或 $-\infty$ 。

第二，函数可积。若

$$\int_{\Omega} |f| d\mu < \infty,$$

则 f 可积。此时

$$\int_{\Omega} f d\mu$$

一定是有限实数。

所以：

$$f \in L^1(\mu) \implies \int_{\Omega} f d\mu \text{ 是有限实数.}$$

但反过来，积分有定义并不一定说明 f 可积。

■ 概率论中的解释：期望

若 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间， X 是实值随机变量，则 X 关于概率测度 $\mathbb{P}$ 的积分称为 X 的期望：

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

这里 X 的正部分和负部分分别为

$$X^{+} = \max\{X, 0\},$$

$$X^{-} = \max\{-X, 0\}.$$

于是

$$X = X^{+} - X^{-},$$

并且

$$|X| = X^{+} + X^{-}.$$

如果

$$\mathbb{E}[X^{+}] < \infty$$

或者

$$\mathbb{E}[X^-] < \infty,$$

则可以定义

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

如果进一步有

$$\mathbb{E}[|X|] < \infty,$$

则称 X 是可积随机变量, 记作

$$X \in L^1(\mathbb{P}).$$

在这种情况下, $\mathbb{E}[X]$ 是一个有限实数。

例如在金融中, 如果 X 表示一个策略的收益, 那么 X^+ 表示盈利部分, X^- 表示亏损部分, $\mathbb{E}[X^+]$ 表示平均盈利贡献, $\mathbb{E}[X^-]$ 表示平均亏损贡献, 而

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-]$$

表示净期望收益。如果平均盈利和平均亏损同时都是无穷大, 那么所谓的净期望收益就不是一个良好定义的量。

■ 积分的基本性质

下面列出 Lebesgue 积分最常用的一些基本性质。

线性性. 若 $f, g \in L^1(\mu)$, 且 $a, b \in \mathbb{R}$, 则

$$af + bg \in L^1(\mu),$$

并且

$$\int_{\Omega} (af + bg) d\mu = a \int_{\Omega} f d\mu + b \int_{\Omega} g d\mu.$$

这说明, 在可积函数空间中, 积分是一个线性算子。

单调性. 若 $f, g \in L^1(\mu)$, 并且

$$f \leq g,$$

则

$$\int_{\Omega} f d\mu \leq \int_{\Omega} g d\mu.$$

单调性的意思是: 如果一个函数处处不超过另一个函数, 那么它的积分也不超过另一个函数的积分。

绝对值不等式. 若 $f \in L^1(\mu)$, 则

$$\left| \int_{\Omega} f d\mu \right| \leq \int_{\Omega} |f| d\mu.$$

在概率论中, 这就是

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|].$$

这个不等式说明, 期望的绝对值不会超过绝对值的期望。

几乎处处相等不改变积分. 如果 f, g 是可测函数, 并且

$$f = g \quad \mu\text{-a.e.},$$

则只要其中一个函数可积, 另一个函数也可积, 并且

$$\int_{\Omega} f d\mu = \int_{\Omega} g d\mu.$$

这里 $\mu\text{-a.e.}$ 表示 $\mu\text{-almost everywhere}$, 即除了一个零测集以外处处成立。在概率论中, 若

$$X = Y \quad a.s.,$$

则只要 X 可积, Y 也可积, 并且

$$\mathbb{E}[X] = \mathbb{E}[Y].$$

这说明, Lebesgue 积分不关心零测集上的函数取值。

■ 集合上的积分

若 $E \in \mathcal{F}$, 则可以定义 f 在集合 E 上的积分:

$$\int_E f d\mu = \int_{\Omega} f \mathbf{1}_E d\mu.$$

这里 $\mathbf{1}_E$ 是集合 E 的指示函数。

如果 $f \geq 0$, 则

$$\int_E f d\mu$$

表示函数 f 在集合 E 上的总量。如果 f 是可积函数, 则

$$\int_E f d\mu$$

也一定有定义, 并且

$$\left| \int_E f d\mu \right| \leq \int_E |f| d\mu.$$

特别地, 如果 $f = \mathbf{1}_A$, 那么

$$\int_E \mathbf{1}_A d\mu = \mu(A \cap E).$$

这说明, 测度仍然可以看作指示函数积分的特殊情形。

■ 例子：有限概率空间中的期望

设

$$\Omega = \{\omega_1, \omega_2, \omega_3\},$$

并且

$$\mathbb{P}(\{\omega_1\}) = 0.2, \quad \mathbb{P}(\{\omega_2\}) = 0.5, \quad \mathbb{P}(\{\omega_3\}) = 0.3.$$

定义随机变量 X 为

$$X(\omega_1) = 10, \quad X(\omega_2) = -4, \quad X(\omega_3) = 2.$$

则

$$X^+(\omega_1) = 10, \quad X^+(\omega_2) = 0, \quad X^+(\omega_3) = 2,$$

并且

$$X^-(\omega_1) = 0, \quad X^-(\omega_2) = 4, \quad X^-(\omega_3) = 0.$$

因此

$$\mathbb{E}[X^+] = 10 \cdot 0.2 + 2 \cdot 0.3 = 2.6,$$

并且

$$\mathbb{E}[X^-] = 4 \cdot 0.5 = 2.$$

所以

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-] = 2.6 - 2 = 0.6.$$

也可以直接计算：

$$\mathbb{E}[X] = 10 \cdot 0.2 + (-4) \cdot 0.5 + 2 \cdot 0.3 = 0.6.$$

■ 例子：Lebesgue 测度下的可积性

在实数轴上，令 m 表示 Lebesgue 测度。考虑函数

$$f(x) = \frac{1}{1+x^2}.$$

这是一个非负可测函数，并且

$$\int_{\mathbb{R}} \frac{1}{1+x^2} dx = \pi.$$

因此

$$f \in L^1(m).$$

再考虑函数

$$g(x) = \frac{1}{|x|}, \quad x \in (0, 1).$$

虽然 g 是非负可测函数，但是

$$\int_0^1 \frac{1}{x} dx = +\infty.$$

所以 g 的非负积分有定义，但它不是可积函数。这个例子说明：

$$\int f d\mu \text{ 有定义}$$

和

$$f \in L^1(\mu)$$

是两个不同层次的概念。

■ 例子：计数测度下的可积性

设

$$\Omega = \mathbb{N}, \quad \mathcal{F} = 2^{\mathbb{N}},$$

并令 μ 为计数测度。若 $f: \mathbb{N} \rightarrow \mathbb{R}$ ，则

$$\int_{\mathbb{N}} f d\mu$$

对应于级数求和。

更准确地说，若 f 可积，则

$$\int_{\mathbb{N}} f d\mu = \sum_{n=1}^{\infty} f(n),$$

并且

$$f \in L^1(\mu) \iff \sum_{n=1}^{\infty} |f(n)| < \infty.$$

因此，在计数测度下， L^1 可积性正是绝对可和性。

■ 本节小结

本节把 Lebesgue 积分从非负可测函数推广到了可以取正负值的一般可测函数。

核心构造是正负部分分解：

$$f = f^+ - f^-,$$

其中

$$f^+ = \max\{f, 0\}, \quad f^- = \max\{-f, 0\}.$$

一般可测函数的积分定义为

$$\int_{\Omega} f d\mu = \int_{\Omega} f^+ d\mu - \int_{\Omega} f^- d\mu,$$

前提是右边不出现 $+\infty - \infty$ 。

最重要的可积性条件是

$$\int_{\Omega} |f| d\mu < \infty.$$

此时称

$$f \in L^1(\mu).$$

在概率论中，这对应于随机变量的绝对期望有限：

$$X \in L^1(\mathbb{P}) \iff \mathbb{E}[|X|] < \infty.$$

此时

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}$$

是一个有限且稳定的数学对象。

本节的核心思想可以概括为：

一般函数积分 = 正部分积分 - 负部分积分.

■ 练习

1. 设 $f: \Omega \rightarrow \mathbb{R}$ 是可测函数。证明 f^+ 和 f^- 都是非负可测函数。

2. 证明

$$f = f^+ - f^-, \quad |f| = f^+ + f^-.$$

3. 设 f 是可测函数。证明

$$f \in L^1(\mu) \iff \int_{\Omega} f^+ d\mu < \infty \text{ 且 } \int_{\Omega} f^- d\mu < \infty.$$

4. 设 $f, g \in L^1(\mu)$, $a, b \in \mathbb{R}$ 。证明

$$af + bg \in L^1(\mu).$$

5. 设 $f \in L^1(\mu)$ 。证明

$$\left| \int_{\Omega} f d\mu \right| \leq \int_{\Omega} |f| d\mu.$$

6. 设 $f = g$ μ -a.e.。证明若 $f \in L^1(\mu)$, 则 $g \in L^1(\mu)$, 并且

$$\int_{\Omega} f d\mu = \int_{\Omega} g d\mu.$$

7. 设 X 是实值随机变量。解释为什么

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-]$$

只有在右边不出现 $+\infty - \infty$ 时才有意义。

8. 在有限概率空间

$$\Omega = \{\omega_1, \omega_2, \omega_3\}$$

上, 设

$$\mathbb{P}(\{\omega_1\}) = 0.1, \quad \mathbb{P}(\{\omega_2\}) = 0.4, \quad \mathbb{P}(\{\omega_3\}) = 0.5,$$

并且

$$X(\omega_1) = 3, \quad X(\omega_2) = -2, \quad X(\omega_3) = 6.$$

求 $\mathbb{E}[X^+]$ 、 $\mathbb{E}[X^-]$ 和 $\mathbb{E}[X]$ 。

9. 设 $\Omega = \mathbb{N}$, μ 是计数测度。证明

$$f \in L^1(\mu) \iff \sum_{n=1}^{\infty} |f(n)| < \infty.$$

10. 用一句话解释: 为什么可积性要求

$$\int |f| d\mu < \infty$$

而不是只要求

$$\int f d\mu$$

有定义?

2.5 单调收敛、Fatou 引理与控制收敛

2.6 Fubini-Tonelli 定理

2.7 Radon-Nikodym 定理

2.8 L_p 空间与基本不等式

2.9 测度分解与变换公式

2.10 模块总结: 期望、密度与分布的统一

第 3 章

Kolmogorov 公理与概率空间

3.1 Kolmogorov 概率公理

3.2 随机变量与分布

3.3 事件、独立性与条件概率初步

3.4 乘积概率空间

3.5 无穷乘积与 Kolmogorov 扩张定理

3.6 Borel-Cantelli 引理

3.7 Kolmogorov 零一律

3.8 随机级数与三系定理导论

3.9 分布变换与特征函数初步

3.10 模块总结：从公理到随机对象构造

第 4 章

条件期望、正则条件分布与 Bayes 结构

4.1 条件期望的 Radon-Nikodym 定义

4.2 条件期望作为投影

4.3 塔式性质与条件 Jensen 不等式

4.4 条件独立

4.5 正则条件概率

4.6 Disintegration theorem 入门

4.7 Bayes 反问题的概率结构

4.8 条件期望与 Markov 核

4.9 条件期望的反例与技术边界

4.10 模块总结：条件化作为概率论核心操作

第 5 章

收敛方式与弱收敛语言

5.1 几乎处处收敛与依概率收敛

5.2 L_p 收敛与一致可积性

5.3 依分布收敛

5.4 Portmanteau 定理

5.5 连续映射定理与 Slutsky 定理

5.6 紧性与 Prokhorov 定理

5.7 特征函数与弱收敛

5.8 Wasserstein 距离入门

5.9 随机元素的弱收敛

5.10 模块总结：极限语言与人工智能大极限

第 6 章

大数律、中心极限定理与三角阵列

6.1 弱大数律

6.2 强大数律

6.3 Kolmogorov 最大不等式

6.4 中心极限定理的特征函数证明

6.5 Lindeberg-Feller 中心极限定理

6.6 Lyapunov 条件与 Berry-Esseen 估计

6.7 Poisson 逼近与稀有事件极限

6.8 稳定分布与重尾极限

6.9 不变性原理预告

6.10 模块总结：极限定理作为概率论发动机

第 7 章

鞅理论

7.1 滤过与适应过程

7.2 鞅、下鞅与上鞅

7.3 停时与可选采样

7.4 Doob 分解

7.5 Doob 最大不等式

7.6 鞅收敛定理

7.7 Azuma-Hoeffding 不等式

7.8 Freedman 与 Bernstein 型鞅不等式

7.9 鞅中心极限定理

7.10 模块总结：随机演化中的信息与公平性

第 8 章

Markov 链、概率核与遍历性

8.1 Markov 核与 Chapman-Kolmogorov 方程

8.2 离散时间 Markov 链基础

8.3 不变分布与遍历定理

8.4 可逆性与 detailed balance

8.5 耦合方法

8.6 谱间隙与混合时间

8.7 Harris recurrence 入门

8.8 MCMC 与 Gibbs sampler

8.9 Markov 链大数律与中心极限定理

8.10 模块总结：随机转移与平衡

第 9 章

函数空间弱收敛与 Brownian motion 构造

9.1 $C[0,1]$ 上的随机元素

9.2 $D[0,1]$ 与 Skorokhod 拓扑

9.3 Kolmogorov 连续性定理

9.4 Brownian motion 的定义与构造

9.5 Brownian motion 的基本性质

9.6 Donsker 不变性原理

9.7 紧性判别与模连续性

9.8 Brownian hitting time 与极值分布

9.9 迭代对数律入门

9.10 模块总结：从随机变量到随机函数

第 10 章

Brownian motion 与 Itô calculus

10.1 二次变差

10.2 Itô 积分的构造

10.3 Itô 公式

10.4 指数鞅与 Novikov 条件

10.5 Girsanov 定理

10.6 局部鞅与 localization

10.7 Brownian local time 入门

10.8 鞅表示定理

10.9 随机积分的典型估计

10.10 模块总结：连续时间随机分析语言

第 11 章

SDE、生成元、Markov 半群与 PDE

- 11.1 随机微分方程的定义
- 11.2 存在唯一性定理
- 11.3 强解、弱解与路径唯一性
- 11.4 生成元与 Itô diffusion
- 11.5 Feller 半群与 martingale problem
- 11.6 Feynman-Kac 公式
- 11.7 Ornstein-Uhlenbeck 过程
- 11.8 Langevin diffusion 与不变分布
- 11.9 扩散过程的遍历性
- 11.10 模块总结：随机动力系统与 PDE 互译

第 12 章

Poisson 过程、Lévy 过程与跳过程

12.1 Poisson 过程

12.2 更新过程

12.3 Poisson 随机测度

12.4 复合 Poisson 过程

12.5 无限可分分布

12.6 Lévy-Khintchine 公式

12.7 Lévy-Itô 分解

12.8 稳定过程与重尾跳跃

12.9 分支过程与随机图过程导论

12.10 模块总结：非连续路径与非 Gaussian 世界

第 13 章

大偏差理论

- 13.1 大偏差原理的定义
- 13.2 Cramér 定理
- 13.3 Gärtner-Ellis 定理
- 13.4 Sanov 定理
- 13.5 收缩原理
- 13.6 Laplace 原理
- 13.7 Varadhan 引理
- 13.8 Gibbs 变分原理
- 13.9 经验风险的大偏差视角
- 13.10 模块总结：典型行为与指数小概率

第 14 章

信息论、熵方法与函数不等式

- 14.1 相对熵与互信息
- 14.2 Pinsker 不等式与 data processing
- 14.3 熵方法与 Herbst argument
- 14.4 Poincaré 不等式
- 14.5 Log-Sobolev 不等式
- 14.6 Talagrand transport inequality
- 14.7 Efron-Stein 与方差代理
- 14.8 信息论泛化界
- 14.9 PAC-Bayes 的熵结构
- 14.10 模块总结：熵、几何与学习的统一

第 15 章

集中不等式 I：独立变量与有界差分

- 15.1 Sub-Gaussian 随机变量
- 15.2 Sub-exponential 随机变量
- 15.3 Hoeffding 不等式
- 15.4 Bernstein 与 Bennett 不等式
- 15.5 Chernoff 方法
- 15.6 McDiarmid 有界差分不等式
- 15.7 Self-bounding functions
- 15.8 矩方法与 Rosenthal 型不等式
- 15.9 鞅集中回顾与统一
- 15.10 模块总结：非渐近概率估计的基础工具箱

第 16 章

Gaussian Process 与比较不等式

- 16.1 Gaussian 向量与协方差结构
- 16.2 Isonormal Gaussian process
- 16.3 Cameron-Martin 空间
- 16.4 Slepian 引理
- 16.5 Sudakov-Fernique 不等式
- 16.6 Borell-TIS 不等式
- 16.7 Gaussian isoperimetry
- 16.8 Dudley entropy integral
- 16.9 Gaussian width
- 16.10 模块总结: Gaussian 极限与神经网络初始化

第 17 章

Generic Chaining 与 Majorizing Measure

- 17.1 Chaining 思想的历史动机
- 17.2 Admissible sequence 与 γ_2 泛函
- 17.3 Majorizing measure theorem 陈述
- 17.4 Generic chaining 上界
- 17.5 Sudakov minoration 与下界
- 17.6 Bernoulli process 入门
- 17.7 局部复杂度与多尺度泛化
- 17.8 随机矩阵中的 chaining
- 17.9 深度网络类复杂度预告
- 17.10 模块总结：随机过程上确界的精细工具

第 18 章

经验过程理论

- 18.1 经验测度与经验过程
- 18.2 Symmetrization 技术
- 18.3 Rademacher complexity
- 18.4 Contraction principle
- 18.5 VC dimension 与 Sauer 引理
- 18.6 覆盖数与 bracketing entropy
- 18.7 Glivenko-Cantelli 类
- 18.8 Donsker 类
- 18.9 Multiplier process
- 18.10 模块总结: uniform law 的概率论版本

第 19 章

高维概率与非渐近随机矩阵

- 19.1 高维随机向量
- 19.2 epsilon-net 方法
- 19.3 随机矩阵算子范数
- 19.4 奇异值非渐近界
- 19.5 Hanson-Wright 不等式
- 19.6 Matrix Bernstein 不等式
- 19.7 Matrix Chernoff 与协方差集中
- 19.8 Johnson-Lindenstrauss 与随机投影
- 19.9 Restricted isometry property
- 19.10 模块总结：高维随机结构的非渐近控制

第 20 章

随机矩阵极限、谱分布与 Free Probability 入门

20.1 经验谱分布

20.2 Wigner 矩阵与半圆律

20.3 Marchenko-Pastur 定理

20.4 Resolvent method

20.5 Spiked covariance model

20.6 BBP transition

20.7 Local law 概念

20.8 Universality 思想

20.9 Free convolution 入门

20.10 模块总结：谱极限与高维学习风险

第 21 章

高维统计与 Minimax 理论

- 21.1 统计决策理论
- 21.2 Le Cam 方法
- 21.3 Fano 不等式
- 21.4 Assouad 引理
- 21.5 稀疏线性回归
- 21.6 压缩感知
- 21.7 低秩矩阵估计
- 21.8 协方差估计
- 21.9 非参数估计与有效维数
- 21.10 模块总结：统计极限与可估计性边界

第 22 章

统计学习理论的纯数学版本

- 22.1 经验风险最小化
- 22.2 PAC learning 基础
- 22.3 VC 理论再解释
- 22.4 Rademacher 泛化界
- 22.5 Localized complexity 与 fast rates
- 22.6 Algorithmic stability
- 22.7 PAC-Bayes 理论
- 22.8 Compression bound
- 22.9 Uniform convergence 的失败
- 22.10 模块总结：泛化误差的多种数学机制

第 23 章

RKHS、Kernel Methods 与 Random Features

23.1 正定核与 Mercer 定理

23.2 RKHS 的构造

23.3 Representer theorem

23.4 Kernel ridge regression

23.5 Gaussian process regression

23.6 Random features

23.7 Nyström approximation

23.8 Kernel ridgeless interpolation

23.9 Spectral bias 与 effective dimension

23.10 模块总结：从 kernel 到神经网络极限

第 24 章

随机优化、SGD 与隐式正则化

- 24.1 Robbins-Monro 随机逼近
- 24.2 ODE method
- 24.3 SGD 作为随机递推
- 24.4 Gradient flow 与连续时间极限
- 24.5 Langevin dynamics 与采样
- 24.6 凸优化中的 SGD 收敛
- 24.7 非凸优化基本概率工具
- 24.8 线性回归中的隐式偏置
- 24.9 Logistic 回归中的 max-margin 偏置
- 24.10 模块总结：优化轨迹与泛化机制耦合

第 25 章

统计物理、Spin Glass、AMP 与 State Evolution

25.1 Gibbs 测度与配分函数

25.2 Curie-Weiss 模型

25.3 Sherrington-Kirkpatrick 模型入门

25.4 Replica 方法的数学边界

25.5 Cavity method 直观

25.6 TAP 方程

25.7 Approximate message passing

25.8 State evolution

25.9 Planted models 与检测相变

25.10 模块总结：高维推断中的物理概率语言

第 26 章

Double Descent、Ridgeless Regression 与 Benign Overfitting

- 26.1 经典偏差-方差分解再审视
- 26.2 插值阈值与 double descent 现象
- 26.3 最小范数插值解
- 26.4 各向同性 Gaussian 设计下的精确风险
- 26.5 有噪声线性模型的 ridgeless regression
- 26.6 Spiked covariance 下的风险
- 26.7 Benign overfitting 的谱条件
- 26.8 Random feature double descent
- 26.9 Kernel ridgeless 与无限维插值
- 26.10 模块总结：过参数泛化的第一个可解模型

第 27 章

无限宽神经网络、Gaussian Process、NTK 与 Tensor Programs

27.1 随机初始化神经网络

27.2 NNGP 极限

27.3 Neural tangent kernel 的定义

27.4 NTK 极限与 lazy training

27.5 Kernel gradient flow

27.6 有限宽修正

27.7 深度对信号传播的影响

27.8 Tensor programs 入门

27.9 架构依赖极限

27.10 模块总结：神经网络训练的核极限图像

第 28 章

Mean-field Neural Networks 与 Wasserstein Gradient Flow

28.1 两层网络的 mean-field scaling

28.2 Propagation of chaos

28.3 参数分布的非线性 PDE

28.4 Wasserstein gradient flow

28.5 全局收敛问题

28.6 Feature learning 与 lazy training 的差别

28.7 有限粒子涨落

28.8 多层 mean-field 理论导论

28.9 Mean-field 与 scaling exponent

28.10 模块总结：从核学习到特征学习

第 29 章

Scaling Laws 的数学化

- 29.1 Scaling laws 的经验形式
- 29.2 模型规模、数据规模与计算预算
- 29.3 风险分解框架
- 29.4 幂律的谱来源
- 29.5 非参数回归中的学习曲线
- 29.6 Kernel 与 random feature scaling
- 29.7 NTK 模型中的 scaling laws
- 29.8 优化误差与 compute-optimal tradeoff
- 29.9 Scaling exponent 的可识别性
- 29.10 模块总结：把经验幂律变成定理问题

第 30 章

Diffusion、Score Models 与 AI 理论研究入口

30.1 生成建模的概率论表述

30.2 Denoising diffusion probabilistic models

30.3 Score matching

30.4 Score-based SDE

30.5 扩散模型中的误差分解

30.6 Scaling laws 与生成模型

30.7 Transformer 理论接口导论

30.8 最终专题一：Double descent 研究提案

30.9 最终专题二：Scaling laws 研究提案

30.10 最终总结：从 AI 现象到概率定理